

quantcrim

Een open-web handboek voor kwantitatief criminologisch onderzoek

Joost Jansen

Gijs Custers

2026-10-08

Table of contents

1	Voorwoord	4
	Voorwoord	5
1.1	Voor we verder gaan..	5
2	Vorbereiding	6
	Vorbereidingen	7
I	Data beschrijven	8
3	Data	9
3.1	Wat zijn data?	9
3.1.1	Missende waarden	10
4	Meetniveaus en visualisaties	11
4.1	Kwalitatieve variabelen	11
4.1.1	Staaftiaqram	11
4.1.2	Simpele tabel	13
4.1.3	Nominale variabele	13
4.1.4	Taartdiagram	14
4.1.5	Ordinale variabele	16
4.2	Kwantitatieve variabelen	17
4.2.1	Interval en ratio variabelen	17
4.2.2	Histogram	18
4.3	Meetniveau bepalen	19
4.4	Samenvatting	21
5	Centrum- en spreidingsmaten	22
5.1	Centrummaten	22
5.1.1	Gemiddelde	22
5.1.2	Mediaan	23
5.1.3	Modus	24
5.2	Spreidingsmaten	24
5.2.1	Bereik, minimum en maximum	24

5.2.2	Variantie	25
5.2.3	Standaarddeviatie	27
5.3	Toepassing op de dataset	28
5.3.1	Doosdiagram	29
6	Relaties tussen variabelen	32
6.1	Kwalitatief vs. kwalitatief	32
6.1.1	Nominaal vs. nominaal	32
6.1.2	Nominaal vs. ordinaal	35
6.2	Kwalitatief vs. kwantitatief	37
6.3	Kwantitatief vs. kwantitatief	38
6.4	Tot slot	41
II	Kans en steekproeven	42
7	Steekproeven	43
8	Kans	44
III	Hypotheses	45
IV	Samenhang tussen variabelen	46
V	Colleges	47
9	Collegeslides	48
VI	Opdrachten	49
10	Opdrachten	50
	Appendices	51
A	Symbolen en formules	51
A.1	Belangrijke symbolen en formules	51

1 Voorwoord

Voorwoord

Welkom bij het **quanterim handboek** Criminologie. Hier ga je leren hoe je kwantitatieve data kan analyseren met R. Het boek is ontworpen en beschikbaar gesteld door docenten en onderzoekers van de opleiding Criminologie aan de Erasmus Universiteit. Het boek is bedoeld voor zowel bachelor- als masterstudenten.

Hieronder vind je een voorbeeld van hoe makkelijk het is om data in te laden, een regressiemodel te schatten en de resultaten ervan te presenteren in een plot.¹

```
# test
```

1.1 Voor we verder gaan..

We hopen dat je dit boek handig vindt om mee te werken. In het kader van Open Science hebben we geprobeerd dit boek volledig transparant en reproduceerbaar te ontwikkelen. De broncode is beschikbaar via <https://github.com/joostjansen/quanterim>. Als je vragen, suggesties of aanpassingen hebt, aarzel niet deze te stellen.²

¹We gaan in een later hoofdstuk zien wat een regressiemodel precies is.

²Het beste is om dit via GitHub te doen in onze Repository.

2 Voorbereiding

Vorbereidingen

Voor we tijdens de lessen aan de slag kunnen met het verrichten van kwantitatief onderzoek, moet de vereiste software geïnstalleerd worden. We gaan werken met R (spreek uit op z'n Engels). R is een programmeertaal die veel statistici gebruiken om hun analyses mee te doen. De omgeving waarin je met R kan werken, heet RStudio. Zowel R als RStudio moeten apart geïnstalleerd worden. Je vindt de installatielinks hieronder:

1. [R](#)
2. [RStudio](#)

Na installatie van de benodigde software moeten we R gereed maken door de juiste packages (ook wel: libraries) te installeren. Veel databewerkingen en analyses vergen namelijk speciaal daarvoor software. Een package waarmee je mooie visualisaties kan maken van je data heet bijvoorbeeld ggplot. Je installeert zo'n package door RStudio te openen en in je console de volgende code te typen en dan te 'runnen':

```
# install.packages("ggplot2")
```

Als je het package geïnstalleerd hebt (eenmalig) laad je in het vervolg aan het begin van elke sessie het package in. Let op: in tegenstelling tot bij het installeren van een package, gebruik je bij het laden ervan geen aanhalingstekens. R is zeer gevoelig voor het verkeerd gebruik van leestekens. Wees daar dus scherp op.

```
library(ggplot2)
```

Hieronder vind je een lijst met alle packages die je tijdens dit vak nodig hebt.

```
#  
# install.packages()  
# install.packages()  
  
# laden packages  
library(readr)  
library(ggplot2)  
library(tidyverse)
```

Part I

Data beschrijven

3 Data

3.1 Wat zijn data?

In de criminologie zijn we geïnteresseerd in diverse vragen die we kunnen beantwoorden aan de hand van statistisch onderzoek. Denk aan de volgende vragen:

- Hoeveel inbraken vinden er jaarlijks plaats in Kralingen?
- Wat is het gemiddelde geldbedrag waarvoor Nederlandse banken hebben geschikt in witwaszaken in 2025?
- Hoeveel misdaadjournalisten zijn er vermoord het afgelopen decennium?
- Wat is de associatie tussen drugsverslaving en delinquentie?
- In hoeverre leidt seksuele straatintimidatie tot het vermijden van bepaalde plekken?

Om deze vragen te kunnen beantwoorden, werken we met **datasets**. Een set is in de wiskunde een verzameling van dingen. Een dataset is dus een verzameling van data. Het woord **data** is afkomstig uit het Latijnse ‘datum’ wat letterlijk ‘gegeven’ betekent. Een dataset is dus een verzameling gegevens. Dit kan gaan over gegevens van mensen (bijvoorbeeld hun lengte of geslacht), maar bijvoorbeeld ook over andere dingen zoals organisaties, steden of landen. Hetgene waar de data informatie over verschaffen (mensen, organisaties, steden, landen) noemen we de **analyse-eenheid**.

In deze cursus werken we steeds met dezelfde dataset. Dit is gebaseerd op een onderzoek onder uitgaande jongeren, [Het Grote Uitgaansonderzoek](#) van het [Trimbos Instituut](#). In dit onderzoek wordt onder andere gekeken hoe vaak jongeren uitgaan, wat voor soort feesten en gelegenheden ze bezoeken, wat voor middelen ze gebruiken (bijvoorbeeld alcohol of andere drugs) en hoe ze denken over drugsgebruik. Om de data te verzamelen is een online enquête afgenomen via een gerichte wervingscampagne.

Laten we eerst kijken hoe zo’n dataset eruitziet. Dat doen we met behulp van R. Zoals aangegeven in de introductie van dit online boek, het is niet erg als je nog niet snapt hoe dit werkt. Daarvoor volg je uiteraard deze cursus :)

```
# laden van de voorbeeld data
voorbeeld_data <- read_rds("data/voorbeeld_data.rds")

# data inspecteren
head(voorbeeld_data) # head() voor bekijken bovenste rijen
```

	geslacht	leeftijd	opleidingsniveau	alcohol_ooit	alcohol_laatste_jaar
1	vrouw	30	midden	ja	ja
2	man	21	laag	ja	ja
3	vrouw	35	midden	ja	nee
4	man	16	hoog	ja	ja
5	man	26	<NA>	ja	ja
6	vrouw	18	laag	ja	ja

Hierboven staat een ‘sneak preview’ van de dataset. Waar kijken we nu eigenlijk naar? De dataset verschaft informatie die we verzameld hebben over jongeren die hebben meegedaan aan de enquête. Elke rij representeert een respondent: een jongere die de enquête heeft ingevuld. De rijen zijn onze **observaties**.

Elke kolom bevat de waarde van die respondent met betrekking tot een kenmerk, de waarde die hoort bij een antwoord dat een respondent gaf op een in de enquête gestelde vraag. De waarden van respondenten op kenmerken kunnen variëren van respondent tot respondent. Niet iedereen is even oud, gebruikt even vaak drugs, heeft dezelfde opleiding etc. De variatie in een bepaald kenmerk meten we met behulp van **variabelen**. Deze zien we terug in de kolommen. De kern van statistiek is dat we alle variatie in kenmerken gaan gebruiken om onderzoeksvragen zoals die hierboven te kunnen beantwoorden.

We kunnen bijvoorbeeld zien dat de eerste respondent een vrouw is, 30 jaar oud, en een middelbaar opleidingsniveau heeft.

De vierde en vijfde kolom geven aan of iemand ooit alcohol heeft gedronken of in het afgelopen jaar. De voorbeeld data toont dat vijf respondenten het afgelopen jaar alcohol hebben gedronken en één respondent niet.

3.1.1 Missende waarden

Wat je misschien ook is opgevallen, is dat in de vijfde rij bij opleidingsniveau ‘NA’ staat. Dit staat voor Not Available en geeft aan dat er geen valide waarde is voor deze respondent op dit kenmerk. Van deze persoon weten we het opleidingsniveau dus niet. Dit noemen we een **missende waarde**.

Missende waarden komen vaak voor in onderzoek om diverse redenen. Zo kunnen mensen een vraag verkeerd invullen, een vraag per ongeluk overslaan, of een vraag niet willen beantwoorden. Dit laatste zien we vaker bij gevoelige vragen, bijvoorbeeld over gedrag dat maatschappelijk wordt afgekeurd (druggebruik!).

Missende waarden hoeven niet altijd een probleem te zijn. Dit hangt af van de aard van missende waarden en de hoeveelheid. In de practica besteden we hier meer aandacht aan.

4 Meetniveaus en visualisaties

Op de vorige pagina heb je gezien wat een dataset is, en dat deze bestaat uit observaties (de rijen) en variabelen (de kolommen). In de basis zijn er vier manieren om variabelen meetbaar te maken (ook wel: operationaliseren). We noemen deze manieren **meetniveaus**. Elk meetniveau verschaft een ander soort informatie. We bespreken hier de vier meetniveaus en daarbij gaan we meteen in op hoe we de informatie die de variabelen verschaffen het beste visueel kunnen presenteren.

Doorgaans maken we onderscheid tussen **kwalitatieve** en **kwantitatieve** variabelen.


4.1 Kwalitatieve variabelen

Kwalitatieve variabelen bestaan uit categorieën die een kwalitatieve eigenschap van een observatie beschrijven. Deze eigenschappen zijn niet direct in cijfers uit te drukken, zoals bij kwantitatieve variabelen. Een belangrijk aspect is dat de categorieën *discreet* zijn: ze moeten elkaar uitsluiten.

4.1.1 Staafdiagram


Laten we naar een voorbeeld kijken: geslacht. Stel dat we willen weten hoeveel mannen, vrouwen of anders-identificerenden er in de dataset zitten. Daarvoor kunnen we **staafdiagram** maken met *ggplot()*.

```
# staafdiagram maken
ggplot(data_uitgaan, aes(x = geslacht)) + # data en variabele selecteren
  geom_bar() # staafdiagram
```



De staafdiagram geeft een visuele presentatie van het aantal mannen, vrouwen en anders-identificerenden in de dataset. Het mooie aan R is dat we de figuur visueel nog wat aantrekkelijker kunnen maken. Hiermee ga je meer oefenen tijdens de cursus.

```
# staafdiagram met betere visualisatie
ggplot(data_uitgaan, aes(x = geslacht)) +
  geom_bar() +
  theme_bw() + # witte achtergrond
  ylab("aantal") # label voor y-as
```



De figuur heeft nu een witte achtergrond en de y-as heeft een Nederlandstalig label.

4.1.2 Simpele tabel

Als je wilt weten hoeveel respondenten er precies in elke categorie zitten, kun je ook een simpele tabel maken met de functie `table()`.

```
# tabel van geslacht  
table(data_uitgaan$geslacht)
```

```
man  vrouw anders  
178   170     2
```

De dataset bevat in totaal dus xxx mannen, xxx vrouwen en xxx in de categorie “anders”.

4.1.3 Nominale variabele

Geslacht is een voorbeeld van een **nominale** variabele. Dit is een kwalitatieve variabele waarin geen rangorde bestaat tussen de categorieën. Mannen hebben niet intrinsiek meer waarde dan vrouwen, of andersom. De variabele bestaat uit discrete categorieën die elkaar uitsluiten, maar je kunt niet zeggen dat de ene categorie ‘hoger’ of ‘lager’ is dan de ander.


4.1.4 Taartdiagram

Een andere manier om een nominale variabele te presenteren, is via een **taartdiagram**. Een taartdiagram kan snel een overzicht geven van de verhouding tussen categorieën binnen een bepaalde variabele. Doorgaans werkt een taartdiagram het beste als er een beperkt aantal categorieën zijn.

Hieronder staat een voorbeeld van taartdiagram van de variabele `manier_verkrijgen_drugs`. Dit gaat over de wijze waarop uitgaande jongeren meestal aan hun drugs komen.

```
# samenvatten van de relevante data
drugs_verkrijgen <- data_uitgaan |>
  filter(!is.na(manier_verkrijgen_drugs)) |> # missende waarden verwijderen
  group_by(manier_verkrijgen_drugs) |> # groeperen op variabele
  summarise(n = n()) |> # aantal respondenten per categorie berekenen
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal


# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  # percentages (y) en categorieën (fill) selecteren
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) + # optie voor taartdiagram
  theme_void() # achtergrond weghalen
```



Je kan zien dat er best wat regels code nodig zijn om deze taartdiagram te maken. Hoe dat precies in zijn werk gaat, wat elke regel doet, gaan we tijdens de practica behandelen.

De taartdiagram weergeeft het aandeel per categorie van hoe jongeren doorgaans aan hun drugs komen. We kunnen de presentatie van de taartdiagram echter nog verbeteren.

```
# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  geom_bar(stat = "identity", width = 1, colour = "white") + # witte randen toevoegen
  coord_polar("y", start = 0) +
  theme_void() +
  geom_text(aes(label = perc), position = position_stack(vjust = 0.5)) + # percentages als labels
  labs(fill = "Manieren van drugs verkrijgen (%)") # titel voor legenda
```



We hebben nu een duidelijk inzicht in hoe jongeren die drugs gebruiken hier aan komen. Zo zien we bijvoorbeeld dat ongeveer xx procent dit via een dealer koopt, en ongeveer een kwart het koopt via vrienden/kennissen en een kwart het van deze krijgt.


Dit toont meteen een relevante bevinding uit de literatuur over drugsgebruik onder jongeren, namelijk dat de helft van de jongeren hun drugs verkrijgen via “*sorting*” (zie [Parker et al., 2002](#)). Dat wil zeggen, dat een bekende uit een vrienden- of kennissenkring iemand van drugs voorziet eerder dan een dealer.

4.1.5 Ordinale variabele

Een kwalitatieve variabele waarbij er *wel* een bepaalde rangorde (hiërarchie) tussen de categorieën is, noemen we een **ordinale** variabele.

Laten we weer naar een voorbeeld kijken. In de enquête is gevraagd hoe jongeren hun eigen gezondheid over het algemeen beoordelen. Voor een ordinale variabele maken we in principe altijd een staafdiagram.

```
# staafdiagram van ervaren gezondheid
ggplot(data_uitgaan, aes(x = ervaren_gezondheid)) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab("ervaren gezondheid")
```



De staafdiagram toont dat het grootste deel hun gezondheid als “goed” beoordeelt. Een relatief klein deel van de jongeren beoordeelt hun gezondheid als “matig” of zelfs “slecht”.

Dit voorbeeld illustreert een relevant kenmerk van ordinale variabelen: er is een bepaalde rangorde tussen de categorieën, maar de afstand ertussen is niet per se gelijk. Zo is de stap van “matig” naar “goed” bijvoorbeeld kwalitatief anders dan de stap van “zeer goed” naar “uitstekend”. Hierin verschilt een ordinale variabele doorgaans van een kwantitatieve variabele, bij de laatste is de afstand tussen waarden (1-2-3 etc.) in principe altijd gelijk.

Bij een ordinale variable kan het echter ook zijn dat de afstand tussen categorieën als gelijk wordt gezien. Als je bijvoorbeeld een antwoord op een stelling meet met de volgende antwoord-categorieën:

- helemaal mee oneens
- mee oneens
- niet mee oneens / niet mee eens
- mee eens
- helemaal mee eens

Dan wordt vaak aangenomen dat de afstand tussen de categorieën gelijk is. Zie verderop onder het kopje Section 4.3 meer uitleg hierover.

4.2 Kwantitatieve variabelen

Kwantitatieve variabelen zijn numeriek en bestaan dus uit cijfers. De afstand tussen waarden is altijd gelijk en er zit een rangorde in. Bijvoorbeeld bij een rapportcijfer van 1 t/m 10 is de afstand tussen 2 en 3 hetzelfde als de afstand tussen 7 en 8. Kwantitatieve variabelen worden soms ook wel lineaire of continue variabelen genoemd.

4.2.1 Interval en ratio variabelen


Er zijn twee types kwantitatieve variabelen: **interval** en **ratio**. Het verschil tussen deze twee types is dat een interval variabele geen *absoluut nulpunt* kent en een ratio variabele wel. Een absoluut nulpunt is wanneer de laagste waarde van een variabele nul is en het niet mogelijk is dat er een nog logische waarde daaronder bestaat.

Leeftijd is bijvoorbeeld een ratio variabele, je kunt namelijk niet jonger dan 0 jaar zijn. Geboortjaar, aan de andere kant, is weer een interval variabele. De christelijke jaartelling begint bij het jaar 0, maar dat is eigenlijk arbitrair omdat de jaren daarvoor ook geteld worden. Het specifieke karakter van de variabele bepaalt dus het meetniveau.

(nog een voorbeeld hier?)

Voor een lineaire variabele met relatief weinig unieke waarden gebruiken we meestal een staafdiagram. Zie hieronder een voorbeeld van de variabele leeftijd.

```
# staafdiagram van leeftijd
ggplot(data_uitgaan, aes(x = as.factor(leeftijd))) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab ("leeftijd")
```




De staafdiagram toont dat relatief veel respondenten tussen 21 en 24 jaar zijn, een leeftijd waarop jongeren veel uitgaan.

4.2.2 Histogram

Voor een lineaire variabele met juist relatief veel unieke waarden gebruiken we meestal een histogram. Bij een histogram worden bepaalde waarden gegroepeerd tot één staaf, waardoor de presentatie overzichtelijk blijft. Dit is hieronder weergegeven voor de variabele `gemoed_dinsdag_na_xtc`. Dit is een score tussen de 0 en 100 die respondenten hebben gegeven hoe zich voelen op de dinsdag na xtc-gebruik in het weekend, waarbij 0 voor negatief staat en 100 voor positief.

```
# histogram van gemoedstoestand op dinsdag na XTC gebruik
ggplot(data_uitgaan, aes(x = gemoed_dinsdag_na_xtc)) +
  geom_histogram(bins = 50) +
  theme_bw() +
  ylab("aantal") +
  xlab("gemoedstoestand (negatief - positief)") +
  xlim(0, 100)
```



4.3 Meetniveau bepalen

Het kan soms lastig zijn om het meetniveau te bepalen als je hier nog weinig ervaring mee hebt. Het belangrijkste is altijd om goed te blijven nadenken over de criteria die een meetniveau bepalen en hoe die van toepassing zijn op een variabele. Daarbij kun je jezelf steeds vragen stellen als:

- Bestaat deze variabele uit cijfers (numeriek/kwantitatief) of kwalitatieve categorieën?
- Is er een rangorde of hiërarchie tussen de categorieën? En in hoeverre is er een gelijke afstand tussen de waarden (1-2-3 ... of, slecht - matig - goed)?
- Heeft de variabele een absoluut nulpunt?

Belangrijk om te onthouden is dat veel variabelen geen inherent meetniveau hebben. Het hangt af van de keuzes van de onderzoeker. Dat wil zeggen dat *hoe* ze worden gemeten leidend is voor welk meetniveau een variabele heeft.

Leeftijd kun je bijvoorbeeld meten door respondenten hun leeftijd als cijfer te laten invullen bij de vragenlijst (bijvoorbeeld 18, 24 of 33). Dan krijg je een ratio variabele. Je kunt als antwoordopties in een vragenlijst echter ook leeftijdscategorieën geven: 1) 16-20 jaar 2) 21-25 jaar 3) 26-30 jaar, etc. In dat geval meet je leeftijd als een ordinale variabele, omdat de deze nu uit categorieën bestaat met een rangorde waarvan de afstand tussen categorieën gelijk is.

Om het nog wat ingewikkelder te maken: je kunt variabelen ook aanpassen in R waardoor het meetniveau verandert. Dit kan middels hercoderen, iets waarmee je verder gaat oefenen in deze cursus.

Om dat met een kort voorbeeld te illustreren. Hieronder staan de eerste zes observaties op de variabele leeftijd.

```
# inspecteren eerste observaties leeftijd
head(data_uitgaan$leeftijd)
```

```
[1] 22 23 18 28 19 18
```

Je kunt zien dat de eerste respondent 22 jaar is, de tweede 23 jaar, de derde 18 jaar, etc. Leeftijd is hier gemeten als kwantitatieve variabele.

Nu hercoderen we deze leeftijden naar categorieën zoals hierboven aangegeven.

```
# hercoderen variabele leeftijd (van numeriek naar categorieën)
data_uitgaan$leeftijd_cat <- recode_values(data_uitgaan$leeftijd,
                                           16:20 ~ "16-20 jaar",
                                           21:25 ~ "21-25 jaar",
                                           26:30 ~ "26-30 jaar",
                                           31:35 ~ "31-35 jaar")
# nieuwe variabele leeftijd_cat inspecteren
head(data_uitgaan$leeftijd_cat)
```

```
[1] "21-25 jaar" "21-25 jaar" "16-20 jaar" "26-30 jaar" "16-20 jaar"
[6] "16-20 jaar"
```

Je ziet dat elke respondent nu in een categorie valt die hoort bij zijn of haar leeftijd. De eerste respondent valt bijvoorbeeld in de categorie ‘21-25 jaar’ en de derde in categorie ‘16-20 jaar’. We hebben zojuist van een ratio variabele een ordinale variabele gemaakt!

Let op dat de transformatie andersom niet mogelijk is: je kunt niet zomaar van een ordinale variabele een kwantitatieve variabele maken. Van respondenten in de categorie ‘16-20 jaar’ weet je bijvoorbeeld niet hun exacte leeftijd op basis van de informatie van deze variabele.

Ten slotte zul je onderzoek vaker **dichotome** (ook wel: binaire) **variabelen** tegenkomen. Dit is een variabele die uitsluitend uit twee antwoordmogelijkheden of waarden bestaat. Dit kunnen in principe zowel nominale als ordinale variabelen zijn. Bijvoorbeeld:

- Nominaal: alcohol gedronken laatste jaar (ja/nee)
- Ordinaal: leeftijd gemeten in twee categorieën (jonger dan 18 jaar/18 jaar of ouder)

In sommige gevallen worden de antwoordcategorieën van dichotome variabelen ook als 0/1 weergegeven, waardoor het in principe numerieke waarden worden maar kwalitatieve variabelen blijven. Dit is handig om mee te rekenen, bijvoorbeeld als je het aandeel respondenten wil berekenen dat alcohol heeft gedronken het laatste jaar ('0' voor nee en '1' voor ja). Hier komen we in de practica op terug.

4.4 Samenvatting

Het meetniveau gaat over het type variabele en wat voor soort informatie deze bevat. Zoals we later zullen zien, is dit belangrijk om te weten wat voor soort statistische toets we kunnen uitvoeren. We onderscheiden de volgende meetniveaus (tussenhaakjes staat welke figuur we meestal gebruiken):

- nominaal (staaf- of taartdiagram)
- ordinaal (staafdiagram)
- interval (staafdiagram of histogram)
- ratio (staafdiagram of histogram)

5 Centrum- en spreidingsmaten

Inmiddels zijn we bekend met datasets, observaties, variabelen, meetniveaus en figuren. We hebben ook benoemd dat statistiek draait om het analyseren van *variatie* met behulp van de variabelen die in onze dataset zitten. Denk aan: variatie in drugsgebruik, uitgaansgedrag, leeftijden en opleidingsniveau. Om de variatie te analyseren maken we gebruik van diverse centrum- en spreidingsmaten. De meeste hiervan zul je herkennen van eerdere wiskundelessen die je hebt gehad.

5.1 Centrummaten

5.1.1 Gemiddelde

Het gemiddelde $\bar{x}$ berekenen we simpelweg door voor de variabele x alle observaties bij elkaar op te tellen $\sum_{i=1}^n x_i$ en dan te delen door het aantal observaties n . Dit gaat middels de volgende formule.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Formules berekenen en statistische toetsen uitvoeren kunnen we ook handmatig in R doen. Dit is leerzaam, omdat het intuïtie creëert voor hoe je statistisch onderzoek moet uitvoeren.

Stel we nemen vijf respondenten uit de dataset en bekijken hun leeftijd. We vinden de volgende observaties voor leeftijd: 16, 22, 22, 28 en 33.

Hieronder berekenen we in R de gemiddelde leeftijd van deze vijf respondenten.

```
# handmatig gemiddelde berekenen  
(16 + 22 + 22 + 28 + 33) / 5
```

```
[1] 24.2
```

De gemiddelde leeftijd van deze vijf respondenten is dus 24,2. In plaats een handmatige berekening kun je het ook berekenen middels de functie *mean()* in R:

```
# vector aanmaken
x <- c(16, 22, 22, 28, 33)
print(x)
```

```
[1] 16 22 22 28 33
```

```
# gemiddelde berekenen
mean(x)
```

```
[1] 24.2
```

Eerst hebben we een vector, of eigenlijk een variabele, aangemaakt met de vijf observaties. Via de functie *mean()* bereken je vervolgens het gemiddelde.

5.1.2 Mediaan

De mediaan is het getal waar het midden van het aantal observaties is bereikt (50%), oftewel de middelste observatie.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar.

Bij een even aantal cijfers zoals (16, 22, 22, 25, 28, 33) neem je het midden van de middelste twee getallen. In dit geval is dat 23,5 (tussen 22 en 25 jaar).

In R bereken je de mediaan via de functie *median()*.

```
# oneven aantal observaties
median(x)
```

```
[1] 22
```

```
# even aantal observaties
y <- c(16, 22, 22, 25, 28, 33)
print(y)
```

```
[1] 16 22 22 25 28 33
```

```
median(y)
```

```
[1] 23.5
```

5.1.3 Modus

De modus is de waarde die het vaakst voorkomt in een variabele.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar omdat deze leeftijd tweemaal voorkomt en de rest slechts één keer.

In R bereken je de modus via de functie `mfv()`.

```
# modus berekenen  
mfv(x)
```

```
[1] 22
```

5.2 Spreidingsmaten

Tekst toevoegen over belang spreiding => Joost

5.2.1 Bereik, minimum en maximum

Het bereik R van een variabele is de afstand tussen de laagste (minimum: x_{min}) en hoogste (maximum: x_{max}) waarde. Dit bereken je eenvoudig door de hoogste waarde minus de laagste waarde te nemen:

$$R = x_{max} - x_{min}$$

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is het minimum 16 en het maximum 33. Het bereik is dus $R = x_{max} - x_{min} = 33 - 16 = 17$

```
# handmatig bereik berekenen  
33 - 16
```

```
[1] 17
```

Je kunt in R het minimum en maximum opvragen met de functies `min()` en `max()`. Ook kun je allebei tegelijk krijgen met de functie `range()`

```
# minimum opvragen  
min(x)
```

[1] 16

```
# maximum opvragen  
max(x)
```

[1] 33

```
# minimum en maximum opvragen  
range(x)
```

[1] 16 33

De functie *range()* geeft je alleen het minimum en maximum. Als je het bereik wilt weten, moet je zelf het minimum van het maximum aftrekken:

```
# bereik berekenen  
max(x) - min(x)
```

[1] 17

5.2.2 Variantie

De variantie is een maat voor de spreiding van een variabele die aangeeft hoeveel de waarden onderling van elkaar verschillen. In de statistiek van de sociale wetenschappen zijn er twee soorten variantie: de populatievariantie en steekproefvariantie. Hier komen we later op terug, we rekenen nu voorlopig verder met de steekproefvariantie. De formule daarvoor is:

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

De steekproefvariantie S^2 kun je bereken in een aantal stappen.

Dit doen we aan de hand van de leeftijdsreeks (16, 22, 22, 28, 33) en het gemiddelde hiervan $\bar{x} = 24,2$

Eerst berekenen we voor elke observatie de afstand tot het gemiddelde (de deviatie):

x_i	$x_i - \bar{x}$
16	16 - 24,2 = -8,2
22	22 - 24,2 = -2,2

x_i	$x_i - \bar{x}$
22	$22 - 24,2 = -2,2$
28	$28 - 24,2 = 3,8$
33	$33 - 24,2 = 8,8$

De optelsom van alle deviaties moet altijd nul zijn: $-8,2 + -2,2 + -2,2 + 3,8 + 8,8 = 0$

In de volgende stap kwadrateren we alle deviaties:

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
16	$16 - 24,2 = -8,2$	$(-8,2)^2 = 67,24$
22	$22 - 24,2 = -2,2$	$(-2,2)^2 = 4,84$
22	$22 - 24,2 = -2,2$	$(-2,2)^2 = 4,84$
28	$28 - 24,2 = 3,8$	$3,8^2 = 14,44$
33	$33 - 24,2 = 8,8$	$8,8^2 = 77,44$

Daarvan nemen we de som der kwadraten $\sum_{i=1}^n (x_i - \bar{x})^2$: $67,24 + 4,84 + 4,84 + 14,44 + 77,44 = 168,8$

In de laatste stap delen we de som der kwadraten door het aantal observaties minus één ($n - 1$):

$$168,8 / (5-1) = 42,2$$

De steekproefvariantie van de leeftijd van vijf respondenten is dus 42,2.

Deze stappen kunnen we ook in R uitvoeren.

```
# deviatie voor elke leeftijd
x_deviatie <- x - mean(x) # voor elke waarde van x minus het gemiddelde
print(x_deviatie)
```

```
[1] -8.2 -2.2 -2.2  3.8  8.8
```

```
# kwadrateren van deviaties
x_deviatie_kwa <- x_deviatie^2 # voor elke deviatie het kwadraat nemen
print(x_deviatie_kwa)
```

```
[1] 67.24  4.84  4.84 14.44 77.44
```

```
# som der kwadraten
sum(x_deviatie_kwa) # sum() neemt de som van een vector
```

```
[1] 168.8
```

```
# steekproefvariantie berekenen
variantie_stkpr <- sum(x_deviatie_kwa) / (length(x) - 1) # length() berekent het aantal rijen
print(variantie_stkpr)
```

```
[1] 42.2
```

In R kun je met de functie *var()* de steekproefvariantie ook direct berekenen

```
# steekproefvariantie
var(x)
```

```
[1] 42.2
```

5.2.3 Standaarddeviatie

De variantie is een handig getal om mee te rekenen, maar heeft meestal op zichzelf niet zoveel betekenis. Daarom wordt in onderzoek gebruik gemaakt van de standaarddeviatie (ook wel standaardafwijking genoemd). In combinatie met het gemiddelde en het bereik, geeft de standaarddeviatie meestal een redelijke indicatie van de spreiding van een lineaire variabele (hier komen we later weer op terug). Hoewel wiskundig niet helemaal correct, wordt de standaarddeviatie ook wel gezien als ‘de gemiddelde afstand tot het gemiddelde’.

De standaarddeviatie is de wortel van de steekproefvariantie:

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

De standaarddeviatie van ons voorbeeld met de leeftijd van vijf respondenten is:

$$S = \sqrt{42,2} = 6,50$$

Je zou dus kunnen zeggen dat een willekeurige persoon van de vijf respondenten ‘gemiddeld’ 6,5 jaar afwijkt van de gemiddelde leeftijd van 24,2 jaar.

```
# standaarddeviatie berekenen  
sqrt(variantie_stkpr) # sqrt() berekent de wortel over een getal/vector
```

```
[1] 6.496153
```

Je kunt de standaarddeviatie ook direct in R krijgen met *sd()*

```
# standaarddeviatie  
sd(x)
```

```
[1] 6.496153
```

5.3 Toepassing op de dataset

We hebben hierboven middels een eenvoudig voorbeeld laten zien hoe de centrum- en spreidingsmaten berekend worden. In onderzoek willen we deze informatie voor variabelen in de hele dataset weten, zodat we snel kunnen zien hoe onze data in elkaar zit.

We vragen hier het gemiddelde, de mediaan en de modus op voor leeftijd in de complete dataset.

```
# centrummaten opvragen  
mean(data_uitgaan$leeftijd) # gemiddelde
```

```
[1] 23.52
```

```
median(data_uitgaan$leeftijd) # mediaan
```

```
[1] 23
```

```
mfv(data_uitgaan$leeftijd) # modus
```

```
[1] 22
```

De gemiddelde leeftijd is 23,5 jaar, de mediaan is 23 jaar en de modus is 22 jaar. Deze waarden liggen dus dicht bij elkaar.

We kunnen ook het minimum, maximum, bereik en de standaarddeviatie berekenen.

```
# spreidingsmaten opvragen
range(data_uitgaan$leeftijd) # minimum en maximum
```

```
[1] 16 35
```

```
max(data_uitgaan$leeftijd) - min(data_uitgaan$leeftijd) # bereik
```

```
[1] 19
```

```
sd(data_uitgaan$leeftijd) #standaarddeviatie
```

```
[1] 4.782178
```

De minimumleeftijd is 16 jaar, de maximumleeftijd is 35 jaar en het leeftijdsbereik is 19 jaar. De standaarddeviatie is 4,8 jaar.

Veel van deze statistieken (min., max., mediaan, gemiddelde) kun je ook in één keer bekijken middels de functie *summary()*

```
# meerdere statistieken tegelijkertijd opvragen
summary(data_uitgaan$leeftijd)
```


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
16.00	20.00	23.00	23.52	27.00	35.00

Je ziet dat de *summary()* functie ook de waardes voor 1st Qu. en 3rd Qu. geeft. Dit zijn het eerste en derde kwartiel, de grenzen waarbij respectievelijk 25% (Q1) en 75% (Q3) van de data ligt. In dit geval dus 20,0 en 27,0 jaar. Het tweede kwartiel (Q2) is de mediaan, dit is op de grens van 50% van de data.

5.3.1 Doosdiagram


Ten slotte is er ook een manier om de spreiding van een lineaire variabele te visualiseren. Dit is via een **doosdiagram**.

```
# doosdiagram maken
ggplot(data_uitgaan, aes(x = leeftijd)) +
  geom_boxplot() # doosdiagram
```



Zoals we inmiddels hebben gezien, kan de presentatie van de figuur kan nog verbeterd worden.

```
# doosdiagram maken
ggplot(data_uitgaan, aes(x = leeftijd)) +
  geom_boxplot() + # doosdiagram
  theme_bw() +
  scale_x_continuous(breaks = seq(16, 35, by = 1)) + # aanpassen labels x-as, van 16 tot 35
  scale_y_continuous(breaks = NULL) # verwijderen labels y-as (hebben geen betekenis hier)
```



Een doosdiagram weergeeft de spreiding van een variabele en bevat het minimum en maximum, en de grenzen van het 1ste kwartiel (Q1), mediaan (Q2) en 3de kwartiel (Q3). De afstand tussen het 1ste en 3de kwartiel wordt ook wel de **interkwartielafstand** genoemd.

Je kunt aan bovenstaande figuur bijvoorbeeld zien dat alle waarden tussen het 1ste kwartiel en mediaan tussen de 20 en 23 jaar liggen. Het hoogste kwartiel (Q4) omvat relatief veel leeftijden, van 27 tot 35 jaar.

Vergelijk deze doosdiagram met de staafdiagram van leeftijd uit het vorige hoofdstuk. Je ziet dat er verschillende manieren zijn om data te visualiseren.

Nog toe te voegen aan formuleblad:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{N}$$

$$z = \frac{x - \bar{x}}{S}$$

$$s.e. = \frac{S}{\sqrt{n}}$$

6 Relaties tussen variabelen

We hebben tot nu toe gekeken naar wat voor verschillende variabelen er zijn (meetniveaus), hoe we de onderliggende data kunnen visualiseren, en met welke statistische maten we deze variabelen kunnen beschrijven. In onderzoek zijn we niet alleen geïnteresseerd in variabelen zelf, maar nog meer in de **relaties** daartussen. Voor onze dataset zouden we bijvoorbeeld de volgende vragen kunnen stellen:

- Wat is het verschil tussen mannen en vrouwen in drugsgebruik?
- In hoeverre denken gebruikers anders over de acceptatie van drugs dan niet-gebruikers?
- Wat is de relatie tussen verschillende soorten drugsgebruik?

Om dergelijke vragen te beantwoorden, moeten we data van verschillende variabelen met elkaar combineren. Daarbij moeten we ons steeds afvragen hoe we deze relaties inzichtelijk willen maken. Het is goed om te realiseren dat hier niet altijd één juist antwoord voor is. Er zijn meerdere manieren om data en relaties te presenteren, waarbij de creativiteit van de onderzoeker ertoe doet. Over het algemeen zijn er wel gebaande paden die we kunnen volgen.

We letten bij het onderzoeken van relaties tussen variabelen vooral op hun meetniveau. Hebben we bijvoorbeeld te maken met twee kwalitatieve variabelen, één kwalitatief en één kwantitatief, of twee kwantitatieve variabelen? Daaruit kunnen we vaak afleiden wat de handigste manier is om een relatie te presenteren. Denk dus altijd eerst goed na wat het meetniveau van een variabele is.

6.1 Kwalitatief vs. kwalitatief

6.1.1 Nominaal vs. nominaal

Als we de relatie tussen twee nominale variabelen willen presenteren, kunnen we een eenvoudige kruistabel maken in R. We kijken in dit voorbeeld naar de relatie tussen geslacht (man/vrouw/anders) en of men heeft gevapet in het afgelopen jaar (ja/nee). We gaan er hier vanuit dat er geen rangorde bestaat tussen wel of niet vaperen en het dus een nominale variabele betreft.

In hoofdstuk xxx hebben we al een tabel gemaakt voor geslacht. We kunnen aan het commando `table()` een variabele (`vapen_laatste_jaar`) toevoegen om een kruistabel te krijgen.

```
# kruistabel tussen geslacht en vaper laatste jaar
table(data_uitgaan$vaper_laatste_jaar, data_uitgaan$geslacht) # vaper in de rijen,
```

	man	vrouw	anders
nee	85	73	0
ja	93	97	2


```
# geslacht in de kolommen
```

We zien in bovenstaande tabel hoe vaak personen van een bepaald geslacht hebben gevapt het afgelopen jaar. Zo kun je zien dat 73 vrouwen niet hebben gevapt en 97 wel.

Visueel krijgen we vaak een beter inzicht in de verdeling van variabelen en de relaties daartussen. We kunnen de verdeling voor vaper_laatste_jaar uitgesplitst naar geslacht daarom apart weergeven in een figuur. De meest gangbare manier om de relatie tussen twee variabelen visueel te weergeven is een staafdiagram. We laten voor eenvoud de categorie ‘anders’ even buiten beschouwing hier.

```
# samenvatten van de relevante data
geslacht_vaper <- data_uitgaan |>
  filter(geslacht != "anders") |> # categorie 'anders' eruit laten
  group_by(geslacht, vaper_laatste_jaar) |> # groeperen op variabelen
  summarise(n = n()) # aantal respondenten per categorie berekenen

# staafdiagram maken voor relatie geslacht en vaper
ggplot(geslacht_vaper, aes(x = geslacht, y = n, fill = vaper_laatste_jaar)) +
  geom_col(position = "dodge") +
  theme_bw() +
  ylab("aantal") +
  labs(fill = "Vaper laatste jaar")
```



We zien nu in een oogopslag wat de verschillen zijn in aantallen tussen mannen en vrouwen die vapeden het laatste jaar.

De absolute aantallen geven slechts gedeeltelijk inzicht in wat verhoudingen zijn binnen de relatie tussen geslacht en vaperen. Daarom is het handig ook de kolompercentages te berekenen. Dit doen we door `prop.table()` toe te voegen aan de kruistabel.

```
# kolompercentages voor kruistabel
table(data_uitgaan$vapen_laatste_jaar, data_uitgaan$geslacht) |>
  prop.table(2) # 2 voor kolompercentages (1 voor rijpercentages)
```

	man	vrouw	anders
nee	0.4775281	0.4294118	0.0000000
ja	0.5224719	0.5705882	1.0000000

We zien nu dat 57,1% van de vrouwen heeft gevaped en 42,9% niet. Bij de mannen ligt dit percentage iets lager (52,2% vs. 47,8%). Je zou dus al (voorzichtig) kunnen concluderen dat vrouwen relatief meer vaperen dan mannen.

6.1.2 Nominaal vs. ordinaal

De werkwijze bij het onderzoeken van een relatie tussen nominaal en ordinaal is in principe hetzelfde. We nemen hier de relatie tussen volgende twee variabelen: `xtc_laatste_jaar` en `acceptatie_xtc_vrienden`. De eerste variabele meet of respondenten het laatste jaar xtc hebben gebruikt en de tweede variabele meet in hoeverre respondenten het eens zijn met de stelling dat het gebruik van xtc onder vrienden geaccepteerd is.

We bekijken eerst weer de aantallen in een kruistabel.

```
# kruistabel tussen xtc gebruik en acceptatie onder vrienden
table(data_uitgaan$acceptatie_xtc_vrienden, data_uitgaan$xtc_laatste_jaar)
```

	nee	ja
helemaal mee oneens	28	2
mee oneens	19	4
niet mee eens of oneens	20	4
mee eens	65	32
helemaal mee eens	23	153
weet niet	0	0

Vervolgens kijken we naar de kolompercentages

```
# kolompercentages voor kruistabel
table(data_uitgaan$acceptatie_xtc_vrienden, data_uitgaan$xtc_laatste_jaar) |>
  prop.table(2)
```


	nee	ja
helemaal mee oneens	0.18064516	0.01025641
mee oneens	0.12258065	0.02051282
niet mee eens of oneens	0.12903226	0.02051282
mee eens	0.41935484	0.16410256
helemaal mee eens	0.14838710	0.78461538
weet niet	0.00000000	0.00000000

Hier tekent zich al een duidelijk patroon af: onder jongeren die xtc hebben gebruikt, is de acceptatie onder vrienden ook hoog. Bijna alle respondenten in de rechterkolom geven aan het eens (16,4%) of helemaal mee eens (78,5%) met de stelling te zijn. Bij jongeren die niet hebben gebruikt is de acceptatie wat meer verdeeld, al geeft een meerderheid aan dat het gebruik van xtc is geaccepteerd onder hun vrienden (eens: 41,9%, helemaal mee eens: 14,8%).

Als we deze relatie willen visualiseren, kunnen we het beste voor een zogenaamde gestapelde staafdiagram kiezen. Hierin worden de antwoordcategorieën op een variabele als het ware gestapeld binnen een staaf. We kunnen zo'n gestapelde staafdiagram maken voor de kolompercentages.

```
# samenvatten van de relevante data
xtc_gebruik_acceptatie <- data_uitgaan |>
  group_by(xtc_laatste_jaar, acceptatie_xtc_vrienden) |>
  summarise(n = n()) |>
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal

# staafdiagram maken voor relatie geslacht en vaper
ggplot(xtc_gebruik_acceptatie,
       aes(x = xtc_laatste_jaar, y = perc,
           fill = acceptatie_xtc_vrienden)) +
  geom_col() + #
  theme_bw() +
  ylab("percentage") +
  xlab("xtc gebruik laatste jaar") +
  labs(fill = "Acceptatie xtc gebruik \n door vrienden ") +
  scale_fill_brewer(palette = 1) # kleur bepalen van licht naar donkerblauw
```



Wederom krijgen we direct een indruk van de relatie tussen deze twee variabelen. Acceptatie van

xtc gebruik is over het algemeen hoog onder vrienden, maar relatief veel meer bij vrienden van jongeren die zelf xtc gebruiken.

Kruistabellen en (gestapelde) staafdiagrammen zijn ook goed toepasbaar voor het onderzoeken van de relatie tussen twee ordinale variabelen (dit behandelen we niet verder hier). Alleen als je variabelen heel veel categorieën hebben, moet je wellicht nadenken over een alternatief.

6.2 Kwalitatief vs. kwantitatief

We beschikken over verschillende opties wanneer we de relatie tussen een kwalitatieve en kwantitatieve variabele willen onderzoeken. De meest eenvoudige optie is om naar het verschil in gemiddeldes te kijken. Als voorbeeld kijken we hier naar geslacht en het aantal sigaretten dat men rookt tijdens het uitgaan (sigaretten_uitgaansdag). Let op dat hier alleen gaat over jongeren die minimaal één sigaret roken tijdens het uitgaan (rokers).

We berekenen het gemiddelde door de data eerst te groeperen en daarna het gemiddelde per groep te berekenen. Hoe je dat moet doen, leer je in het practicum.


```
# gemiddelde berekenen van van aantal sigaretten voor geslacht
data_uitgaan |> group_by(geslacht) |>
  filter(!is.na(sigaretten_uitgaansdag)) |> # respondenten die niet roken eruit laten
  summarise(gem_sigaretten = mean(sigaretten_uitgaansdag)) # summarise() en mean() voor gemi
```

```
# A tibble: 3 x 2
  geslacht gem_sigaretten
  <fct>      <dbl>
1 man         11.1
2 vrouw       11.2
3 anders      20
```

Je ziet dat zowel mannen als vrouwen gemiddeld zo'n 11 sigaretten per uitgaansdag roken. Er is dus niet echt een verschil tussen deze groepen. Bij de anders-identificerenden ligt dit aantal hoger (20), maar dit is een kleine groep wat betekent dat het meer afhankelijk is van wie er toevallig in de dataset zit.

Het verschil in gemiddeldes geeft nog niet zoveel inzicht in de distributie van verschillende groepen. Het kan zijn dat er onderling variatie is in het rookgedrag tussen mannen en vrouwen. Je kunt een doosdiagram voor beide groepen maken om hier meer inzicht in te krijgen.

```
# doosdiagram met aantal sigaretten naar geslacht
ggplot(data_uitgaan, aes(x = geslacht, y = sigaretten_uitgaansdag)) +
  geom_boxplot() +
  theme_bw() +
  ylab("aantal sigaretten uitgaansdag")
```



Deze doosdiagrammen zien er wat anders uit dan in hoofdstuk xxx, omdat we hier met meer extreme waarden te maken hebben. Zo geeft de bovenste punt bij de mannen aan dat één respondent meer dan 100 sigaretten heeft gerookt. Gelet op de spreiding, is de afstand tussen Q1, Q2 en Q3 wat groter bij vrouwen dan mannen. Het lijkt er dus op dat bij de mannen meer extreme waarden voorkomen, terwijl bij de vrouwen er in het midden van de verdeling (interkwartielafstand) wat meer spreiding is.

Ook hier geldt weer: het onderzoeken van een beschrijvende relatie tussen ordinaal vs. kwantitatief kan doorgaans op dezelfde wijze als bij nominaal vs. kwantitatief.


6.3 Kwantitatief vs. kwantitatief

Als laatste onderzoeken we de relatie tussen twee kwantitatieve variabelen. Het makkelijkst is om deze relatie direct te visualiseren (later in de cursus kijken we naar correlatie, een associatiemaat voor de sterkte van de relatie). We nemen de relatie tussen het aantal glazen alcohol op een uitgaansdag (`glazen_alcohol_uitgaansdag`) en het aantal gerookte sigaretten.

Het gaat hier om jongeren die dus zowel alcohol drinken als roken tijdens het uitgaan. Verder zijn dit twee ratio variabelen (bedenk waarom).

Om de relatie te visualiseren, maken we eerst gebruik van een spreidingsdiagram.


```
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point() +
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag")
```



Elke punt vertegenwoordigd een respondent in deze diagram, die laat zien hoe ze scoren op aantal glazen alcohol (x-as) en aantal sigaretten (y-as) tijdens het uitgaan. Er komt hier nog niet een heel duidelijk patroon uit naar voren. Zowel bij jongeren die relatief weinig drinken ($10 < \text{glazen}$) zijn er wat uitschieters naar boven qua roken (> 30 sigaretten), maar ook bij jongeren die relatief veel drinken. De dichtste concentratie van punten zit linksonder, wat betekent dat de meeste respondenten rond de 5-15 glazen alcohol drinken en 1-15 sigaretten roken.


We kunnen de spreidingsdiagram nog wat aanpassen om beter inzicht te krijgen in de relatie. Sommige punten zijn nu niet goed te zien omdat ze dicht op elkaar zitten. Met die optie “*jitter*” wordt de puntenwolk wat meer uitgespreid.

```
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point(position = "jitter") + # jitter toevoegen
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag")
```



Je ziet nu iets beter waar de concentratie van datapunten zit. Verder kun je kijken in hoeverre er een (lineair) verband is tussen aantal glazen alcohol en aantal sigaretten. Je kunt een zogenoemde regressielijn ‘fitten’ op de data met *stat_smooth()*.

```
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point(position = "jitter") +
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag") +
  stat_smooth(method = loess, se = FALSE)
```



De lijn toont dat er geen duidelijk verband is tussen aantal glazen alcohol en aantal sigaretten. Over het algemeen blijft deze vrij vlak en gaat niet duidelijk één richting op.

6.4 Tot slot

Dit hoofdstuk heeft geïllustreerd hoe je relaties tussen variabelen kan beschrijven, zowel door tabellen en visualisaties. Daarbij is het belangrijk om het meetniveau van beide variabelen te weten. Besteed ook aandacht aan de interpretatie: waaraan kun je aflezen hoe een bepaalde relatie in elkaar zit? Daarvan zijn enkele voorbeelden gegeven. Zo weet je na dit hoofdstuk bijvoorbeeld:

- Dat vrouwen iets vaker vaperen dan mannen
- Acceptatie onder vrienden van xtc hoger is onder gebruikers dan niet-gebruikers
- Mannen en vrouwen gemiddeld evenveel roken, maar de onderlinge variatie net wat anders is
- Er geen duidelijke relatie is tussen het aantal glazen alcohol dat men drinkt en aantal sigaretten dat men rookt op een uitgaansdag

Part II

Kans en steekproeven

7 Steekproeven

8 Kans

Part III

Hypotheses

Part IV

Samenhang tussen variabelen

Part V

Colleges

9 Collegeslides

Week 1: [College 1](#)

Part VI

Opdrachten

10 Opdrachten

Deze week gaan jullie aan de slag met ...

A Symbolen en formules

A.1 Belangrijke symbolen en formules

Hier vind je een overzicht van alle belangrijke symbolen en formules die we gebruiken.

Symbool	Betekenis
$\sum_{i=1}^n$	Griekse hoofdletter sigma, staat voor ‘sommatie’: alles bij elkaar optellen. De i betekent dat je begint met tellen bij de eerste waarneming, de n dat je stopt bij de laatste.
α	Alpha, het significantieniveau
μ	Mu, het gemiddelde in de <i>populatie</i> (vaak onbekend)
σ	Sigma, de standaarddeviatie in een <i>populatie</i> (vaak onbekend)
σ^2	Sigma kwadraat, de variantie in een <i>populatie</i>
$\sigma_{\bar{x}}$	Sigma mean, standaardfout vna het gemiddelde