

quantcrim

Een open-web handboek voor kwantitatief criminologisch onderzoek

Joost Jansen

Gijs Custers

2026-09-22

Table of contents

1	Voorwoord	4
	Voorwoord	5
1.1	Voor we verder gaan..	5
I	Vorbereiding	6
2	Vorbereiding	7
	Vorbereidingen	8
II	Data beschrijven	9
3	Data	10
3.1	Wat zijn data?	10
4	Meetniveaus en visualisaties	12
4.1	Kwalitatieve variabelen	12
4.1.1	Staafdiagram	12
4.1.2	Simpele tabel	14
4.1.3	Nominale variabele	14
4.1.4	Taartdiagram	15
4.1.5	Ordinale variabele	17
4.2	Kwantitatieve variabelen	18
4.2.1	Interval en ratio variabelen	18
4.2.2	Histogram	19
4.3	Samenvatting	20
5	Centrum- en spreidingsmaten	21
5.1	Centrummaten	21
5.1.1	Gemiddelde	21
5.1.2	Mediaan	22
5.1.3	Modus	22

III	Kans en steekproeven	24
6	Steekproeven	25
7	Kans	26
IV	Hypotheses	27
V	Samenhang tussen variabelen	28
VI	Colleges	29
8	Collegeslides	30
VII	Opdrachten	31
9	Opdrachten	32

1 Voorwoord

Voorwoord

Welkom bij het **quanterim handboek** Criminologie. Hier ga je leren hoe je kwantitatieve data kan analyseren met R. Het boek is ontworpen en beschikbaar gesteld door docenten en onderzoekers van de opleiding Criminologie aan de Erasmus Universiteit. Het boek is bedoeld voor zowel bachelor- als masterstudenten.

Hieronder vind je een voorbeeld van hoe makkelijk het is om data in te laden, een regressiemodel te schatten en de resultaten ervan te presenteren in een plot.¹

```
# test
```

1.1 Voor we verder gaan..

We hopen dat je dit boek handig vindt om mee te werken. In het kader van Open Science hebben we geprobeerd dit boek volledig transparant en reproduceerbaar te ontwikkelen. De broncode is beschikbaar via <https://github.com/joostjansen/quanterim>. Als je vragen, suggesties of aanpassingen hebt, aarzel niet deze te stellen.²

¹We gaan in een later hoofdstuk zien wat een regressiemodel precies is.

²Het beste is om dit via GitHub te doen in onze Repository.

Part I

Voorbereiding

2 Voorbereiding

Vorbereidingen

Voor we tijdens de lessen aan de slag kunnen met het verrichten van kwantitatief onderzoek, moet de vereiste software geïnstalleerd worden. We gaan werken met R (spreek uit op z'n Engels). R is een programmeertaal die veel statistici gebruiken om hun analyses mee te doen. De omgeving waarin je met R kan werken, heet RStudio. Zowel R als RStudio moeten apart geïnstalleerd worden. Je vindt de installatielinks hieronder:

1. [R](#)
2. [RStudio](#)

Na installatie van de benodigde software moeten we R gereed maken door de juiste packages (ook wel: libraries) te installeren. Veel databewerkingen en analyses vergen namelijk speciaal daarvoor software. Een package waarmee je mooie visualisaties kan maken van je data heet bijvoorbeeld ggplot. Je installeert zo'n package door RStudio te openen en in je console de volgende code te typen en dan te 'runnen':

```
# install.packages("ggplot2")
```

Als je het package geïnstalleerd hebt (eenmalig) laad je in het vervolg aan het begin van elke sessie het package in. Let op: in tegenstelling tot bij het installeren van een package, gebruik je bij het laden ervan geen aanhalingstekens. R is zeer gevoelig voor het verkeerd gebruik van leestekens. Wees daar dus scherp op.

```
library(ggplot2)
```

Hieronder vind je een lijst met alle packages die je tijdens dit vak nodig hebt.

```
#  
# install.packages()  
# install.packages()
```

Part II

Data beschrijven

3 Data

3.1 Wat zijn data?

In de criminologie zijn we geïnteresseerd in diverse vragen die we kunnen beantwoorden aan de hand van statistisch onderzoek. Denk aan de volgende vragen:

- Hoeveel inbraken vinden er jaarlijks plaats in Kralingen?
- Wat is het gemiddelde geldbedrag waarvoor Nederlandse banken hebben geschikt in witwaskassen in 2025?
- Hoeveel misdaadjournalisten zijn er vermoord het afgelopen decennium?
- Wat is de associatie tussen drugsverslaving en delinquentie?
- In hoeverre leidt seksuele straatintimidatie tot het vermijden van bepaalde plekken?

Om deze vragen te kunnen beantwoorden, werken we met **datasets**. Een set is in de wiskunde een verzameling van dingen. Een dataset is dus een verzameling van data. Het woord **data** is afkomstig uit het Latijnse ‘datum’ wat letterlijk ‘gegeven’ betekent. Een dataset is dus een verzameling gegevens. Dit kan gaan over gegevens van mensen (bijvoorbeeld hun lengte of geslacht), maar bijvoorbeeld ook over andere dingen zoals organisaties, steden of landen. Hetgene waar de data informatie over verschaffen (mensen, organisaties, steden, landen) noemen we de **analyse-eenheid**.

In deze cursus werken we steeds met dezelfde dataset. Dit is gebaseerd op een onderzoek onder uitgaande jongeren, gebaseerd op het [Het Grote Uitgaansonderzoek](#) van het [Trimbos Instituut](#). In dit onderzoek wordt onder andere gekeken hoe vaak jongeren uitgaan, naar wat soort feesten en gelegenheden, wat voor middelen ze gebruiken (bijvoorbeeld alcohol of andere drugs) en hoe ze denken over drugsgebruik. Om de data te verzamelen is een online enquête afgenomen via een gerichte wervingscampagne.

Laten we eerst kijken hoe zo’n dataset eruitziet. Dat doen we met behulp van R. Zoals aangegeven in de introductie van dit online boek, het is niet erg als je nog niet snapt hoe dit werkt. Daarvoor volg je uiteraard deze cursus :)

```
# laden packages
library(readr)
library(gt)

# laden van de data
```

Voorbeeld van de data

geslacht	leeftijd	opleidingsniveau	alcohol_ooit	alcohol_laatste_jaar
man	22	hoog	1	1
vrouw	23	hoog	1	1
vrouw	18	midden	1	0
vrouw	28	hoog	1	1
man	19	hoog	1	1

```
data <- read_rds("data/middelengebruik_uitgaanders.rds")

# data inspecteren
head(data[1:5,2:6]) |> # eerste 5 rijen en kolommen
gt() |>
  tab_header(title = "Voorbeeld van de data") |> # titel geven aan output
  opt_stylize(style = 6, color = "blue") # lay-out bepalen
```

Hierboven staat een ‘sneak preview’ van de dataset. Waar kijken we nu eigenlijk naar? De dataset weergeeft de informatie die we hebben over jongeren die hebben meegedaan aan de enquête. Elke rij representeert een respondent: een jongere die de enquête heeft ingevuld. De rijen zijn onze **observaties**. Elke kolom bevat de waarde van die respondent met betrekking tot een kenmerk, een vraag die is gesteld in de enquête. De kolommen zijn daarbij onze **variabelen**.

We kunnen bijvoorbeeld zien dat de eerste respondent een xxx is, xx jaar oud, en een xxx opleidingsniveau heeft.

De vierde en vijfde kolom geven aan of iemand ooit alcohol heeft gedronken of in het afgelopen jaar. Hier staat een ‘1’ voor ja en een ‘0’ voor nee. Dit zul je vaker tegenkomen in het werken met datasets, dat cijfers worden gebruikt om kwalitatieve informatie uit te drukken. Hier komen we later nog meer op terug. De voorbeeld data toont dat vier respondenten het afgelopen jaar alcohol hebben gedronken en één respondent niet.

4 Meetniveaus en visualisaties

Op de vorige pagina heb je gezien wat een dataset is, en dat deze bestaat uit observaties (de rijen) en variabelen (de kolommen). In de sociale wetenschappen zijn er verschillende type variabelen, die ook wel **meetniveaus** worden genoemd. Deze bespreken we hier en daarbij gaan we meteen in op hoe we de data van deze variabelen het beste visueel kunnen presenteren.

Doorgaans maken we onderscheid tussen **kwalitatieve** en **kwantitatieve** variabelen.

4.1 Kwalitatieve variabelen

Kwalitatieve variabelen bestaan uit categorieën die een kwalitatieve eigenschap van een observatie beschrijven. Deze eigenschappen zijn niet direct in cijfers uit te drukken, zoals bij kwantitatieve variabelen. Een belangrijk aspect is dat de categorieën *discreet* zijn: ze moeten elkaar uitsluiten.


4.1.1 Staafdiagram

Laten we naar een voorbeeld kijken: geslacht. Stel dat we willen weten hoeveel mannen, vrouwen of anders-identificerenden er in de dataset zitten. Daarvoor kunnen we **staafdiagram** maken.

```
# laden packages
library(readr)
library(ggplot2)
library(tidyverse)


# laden van de data
data <- read_rds("data/middelengebruik_uitgaanders.rds")

# staafdiagram maken
ggplot(data, aes(x = geslacht)) + # data en variabele selecteren
  geom_bar() # staafdiagram
```



De staafdiagram geeft een visuele presentatie van het aantal mannen, vrouwen en anders-identificerenden in de dataset. Het mooie aan R is dat we de figuur visueel nog wat aantrekkelijker kunnen maken. Hiermee ga je meer oefenen tijdens de cursus.

```
# staafdiagram met betere visualisatie
ggplot(data, aes(x = geslacht)) +
  geom_bar() +
  theme_bw() + # witte achtergrond
  ylab("aantal") # label voor y-as
```



De figuur heeft nu een witte achtergrond en de y-as heeft een Nederlandstalig label.

4.1.2 Simpele tabel

Als je wilt weten hoeveel respondenten er precies in elke categorie zitten, kun je ook een simpele tabel maken.

```
# tabel van geslacht  
table(data$geslacht)
```

```
man  vrouw anders  
178   170     2
```

De dataset bevat in totaal dus xxx mannen, xxx vrouwen en xxx in de categorie “anders”.

4.1.3 Nominale variabele

Geslacht is een voorbeeld van een **nominale** variabele. Dit is een kwalitatieve variabele waarin geen rangorde bestaat tussen de categorieën. De variabele bestaat uit kwalitatieve eigenschappen die van elkaar verschillen, maar je kunt niet zeggen dat de ene categorie intrinsiek ‘hoger’ of ‘lager’ is dan de ander.


4.1.4 Taartdiagram

Een andere manier om een nominale variabele te presenteren, is via een **taartdiagram**. Een taartdiagram kan snel een overzicht geven van de verhouding tussen categorieën binnen een bepaalde variabele. Doorgaans werkt een taartdiagram het beste als er een beperkt aantal categorieën zijn.

Hieronder staat een voorbeeld van taartdiagram van de variabele *manier_verkrijgen_drugs*. Dit gaat over de wijze waarop uitgaande jongeren meestal aan hun drugs komen.

```
# samenvatten van de relevante data
drugs_verkrijgen <- data |>
  filter(!is.na(manier_verkrijgen_drugs)) |> # missende waarden verwijderen
  group_by(manier_verkrijgen_drugs) |> # groeperen op variabele
  summarise(n = n()) |> # aantal respondenten per categorie berekenen
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal


# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  # percentages (y) en categorieën (fill) selecteren
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) + # optie voor taartdiagram
  theme_void() # achtergrond weghalen
```



De taartdiagram weergeeft het aandeel per categorie van hoe jongeren doorgaans aan hun drugs komen. We kunnen de presentatie van taartdiagram echter nog verbeteren.

```
# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  geom_bar(stat = "identity", width = 1, colour = "white") + # witte randen toevoegen
  coord_polar("y", start = 0) +
  theme_void() +
  geom_text(aes(label = perc), position = position_stack(vjust = 0.5)) + # percentages als labels
  labs(fill = "Manieren van drugs verkrijgen") + # titel voor legenda
  ggtitle("Taartdiagram met manieren van drugs verkrijgen (%)") # titel voor figuur
```

Taartdiagram met manieren van drugs verkrijgen (%)



We hebben nu een duidelijk inzicht in hoe jongeren die drugs gebruiken hier aan komen. Zo zien we bijvoorbeeld dat ongeveer 40 procent dit via een dealer koopt, en ongeveer een kwart het koopt via vrienden/kennissen en een kwart het van deze krijgt.


Dit toont meteen een relevante bevinding uit de literatuur over drugsgebruik onder jongeren, namelijk dat de helft van de jongeren hun drugs verkrijgen via “*sorting*” (zie [Parker et al., 2002](#)). Dat wil zeggen, dat een bekende uit een vrienden- of kennissenkring iemand van drugs voorziet eerder dan een dealer.

4.1.5 Ordinale variabele

Een kwalitatieve variabele waarbij er *wel* een bepaalde rangorde (hiërarchie) tussen de categorieën is, noemen we een **ordinaire** variabele.

Laten we weer naar een voorbeeld kijken. In de enquête is gevraagd hoe jongeren hun eigen gezondheid over het algemeen beoordelen. Voor een ordinale variabele maken we in principe altijd een staafdiagram.

```
# staafdiagram van ervaren gezondheid
ggplot(data, aes(x = ervaren_gezondheid)) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab("ervaren gezondheid")
```



De staafdiagram toont dat het grootste deel hun gezondheid als “goed” beoordeelt. Een relatief klein deel van de jongeren beoordeelt hun gezondheid als “matig” of zelfs “slecht”.

Dit voorbeeld illustreert een relevant kenmerk van ordinale variabelen: er is een bepaalde rangorde tussen de categorieën, maar de afstand ertussen is niet per se gelijk. Zo is de stap van “matig” naar “goed” bijvoorbeeld kwalitatief anders dan de stap van “zeer goed” naar “uitstekend”. Hierin verschilt een ordinale variabele van een kwantitatieve variabele, bij de laatste is de afstand tussen waarden (1-2-3 etc.) in principe altijd gelijk.

4.2 Kwantitatieve variabelen

Kwantitatieve variabelen zijn numeriek en bestaan dus uit cijfers. De afstand tussen waarden is altijd gelijk en er zit een rangorde in. Bijvoorbeeld bij een rapportcijfer van 1 t/m 10 is de afstand tussen 2 en 3 hetzelfde als de afstand tussen 7 en 8. Kwantitatieve variabelen worden soms ook wel lineaire of continue variabelen genoemd.


4.2.1 Interval en ratio variabelen

Er zijn twee types kwantitatieve variabelen: **interval** en **ratio**. Het verschil tussen deze twee types is dat een interval variabele geen *absoluut nulpunt* kent en een ratio variabele wel.

Leeftijd is bijvoorbeeld een ratio variabele, je kunt namelijk niet jonger dan 0 jaar zijn. Geboortejaar, aan de andere kant, is weer een interval variabele. De christelijke jaartelling begint bij het jaar 0, maar dat is eigenlijk arbitrair omdat de jaren daarvoor ook geteld worden. Het specifieke karakter van de variabele bepaalt dus het meetniveau.

Voor een lineaire variabele met relatief weinig unieke waarden gebruiken we meestal een staafdiagram. Zie hieronder een voorbeeld van de variabele leeftijd.

```
# staafdiagram van leeftijd
ggplot(data, aes(x = as.factor(leeftijd))) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab ("leeftijd")
```




De staafdiagram toont dat relatief veel respondenten tussen 21 en 24 jaar zijn, een leeftijd waarop jongeren veel uitgaan.

4.2.2 Histogram

Voor een lineaire variabele met juist relatief veel unieke waarden gebruiken we meestal een histogram. Bij een histogram worden bepaalde waarden gegroepeerd tot één staaf, waardoor de presentatie overzichtelijk blijft. Dit is hieronder weergegeven voor de variabele *gemoed_dinsdag_na_xtc*. Dit is een score tussen de 0 en 100 die respondenten hebben gegeven hoe zich voelen op de dinsdag na xtc-gebruik in het weekend, waarbij 0 voor negatief staat en 100 voor positief.

```
# histogram van gemoedstoestand op dinsdag na XTC gebruik
ggplot(data, aes(x = gemoed_dinsdag_na_xtc)) +
  geom_histogram(bins = 50) +
  theme_bw() +
  ylab("aantal") +
  xlab("gemoedstoestand (negatief - positief)") +
  xlim(0, 100)
```



4.3 Samenvatting

Het meetniveau gaat over het type variabele en wat voor soort informatie deze bevat. Zoals we later zullen zien, is dit belangrijk om te weten wat voor soort statistische toets we kunnen uitvoeren. We onderscheiden de volgende meetniveaus (tussenhaakjes staat welke figuur we meestal gebruiken):

- nominaal (staaf- of taartdiagram)
- ordinaal (staafdiagram)
- interval (staafdiagram of histogram)
- ratio (staafdiagram of histogram)

5 Centrum- en spreidingsmaten

Inmiddels zijn we bekend met datasets, observaties, variabelen, meetniveaus en figuren. Om data te beschrijven maken we verder gebruik van diverse centrum- en spreidingsmaten. De meeste hiervan zul je herkennen van eerdere wiskundelessen die je hebt gehad.

5.1 Centrummaten

5.1.1 Gemiddelde

Het gemiddelde van een variabele is simpelweg het optellen van alle waarden, gedeeld door het aantal observaties. Dit gaat middels de volgende formule.

formule

Formules berekenen en statistische toetsen uitvoeren kunnen we ook handmatig in R doen. Dit is leerzaam, omdat het intuïtie creëert voor hoe je statistisch onderzoek moet uitvoeren. In onderstaand voorbeeld berekenen we in R het gemiddelde van een cijferreeks.

```
(3 + 5 + 5 + 7 + 10) / 5
```

```
[1] 6
```

Het gemiddelde van deze cijferreeks met 5 getallen is dus 6. In plaats van handmatig kun je het ook door een functie in R doen:

```
# vector aanmaken  
x <- c(3, 5, 5, 7, 10)  
print(x)
```

```
[1] 3 5 5 7 10
```

```
# gemiddelde berekenen  
mean(x)
```

```
[1] 6
```

Eerst hebben we een vector, of eigenlijk een variabele, aangemaakt met de vijf waarden. Via de functie *mean()* bereken je het gemiddelde.

5.1.2 Mediaan

De mediaan is het getal waar het midden van het aantal observaties is bereikt (50%), oftewel de middelste observatie.

Bij de cijferreeks (3, 5, 5, 7, 10) is dit 5.

Bij een even aantal cijfers zoals (3, 5, 5, 6, 7, 10) neem je het midden van de middelste twee getallen. In dit geval is dat 5,5 (tussen 5 en 6).

In R bereken je de mediaan via de functie *median()*.

```
# oneven aantal observaties  
median(x)
```

```
[1] 5
```

```
# even aantal observaties  
y <- c(3, 5, 5, 6, 7, 10)  
print(y)
```

```
[1] 3 5 5 6 7 10
```

```
median(y)
```

```
[1] 5.5
```

5.1.3 Modus

De modus is de waarde of categorie die het vaakst voorkomt in een variabele.

Bij de cijferreeks (3, 5, 5, 7, 10) is dit 5 omdat deze tweemaal voorkomt en de rest slechts een keer.

In R bereken je de modus via de functie *mfv()*.

```
# package laden  
library(modeest)  
  
# modus berekenen  
mfv(x)
```

```
[1] 5
```

Part III

Kans en steekproeven

6 Steekproeven

7 Kans

Part IV

Hypotheses

Part V

Samenhang tussen variabelen

Part VI

Colleges

8 Collegeslides

Week 1: [College 1](#)

Part VII

Opdrachten

9 Opdrachten

Deze week gaan jullie aan de slag met ...