

quantcrim

Een open-web handboek voor kwantitatief criminologisch onderzoek

Joost Jansen

Gijs Custers

2026-10-05

Table of contents

1	Voorwoord	4
	Voorwoord	5
1.1	Voor we verder gaan..	5
2	Vorbereiding	6
	Vorbereidingen	7
I	Data beschrijven	8
3	Data	9
3.1	Wat zijn data?	9
3.1.1	Missende waarden??	10
4	Meetniveaus en visualisaties	11
4.1	Kwalitatieve variabelen	11
4.1.1	Staaftiaqram	11
4.1.2	Simpele tabel	13
4.1.3	Nominale variabele	13
4.1.4	Taartdiagram	14
4.1.5	Ordinale variabele	16
4.2	Kwantitatieve variabelen	17
4.2.1	Interval en ratio variabelen	17
4.2.2	Histogram	18
4.3	Opties in meetniveaus en transformaties	19
4.4	Samenvatting	20
5	Centrum- en spreidingsmaten	21
5.1	Centrummaten	21
5.1.1	Gemiddelde	21
5.1.2	Mediaan	22
5.1.3	Modus	23
5.2	Spreidingsmaten	23
5.2.1	Bereik, minimum en maximum	23

5.2.2	Variantie	24
5.2.3	Standaarddeviatie	26
5.3	Toepassing op de dataset	27
5.3.1	Doosdiagram	29
6	Relaties tussen variabelen	31
6.0.1	Kwalitatief vs. kwalitatief	31
II	Kans en steekproeven	36
7	Steekproeven	37
8	Kans	38
III	Hypotheses	39
IV	Samenhang tussen variabelen	40
V	Colleges	41
9	Collegeslides	42
VI	Opdrachten	43
10	Opdrachten	44
	Appendices	45
A	Symbolen en formules	45
A.1	Belangrijke symbolen en formules	45

1 Voorwoord

Voorwoord

Welkom bij het **quanterim handboek** Criminologie. Hier ga je leren hoe je kwantitatieve data kan analyseren met R. Het boek is ontworpen en beschikbaar gesteld door docenten en onderzoekers van de opleiding Criminologie aan de Erasmus Universiteit. Het boek is bedoeld voor zowel bachelor- als masterstudenten.

Hieronder vind je een voorbeeld van hoe makkelijk het is om data in te laden, een regressiemodel te schatten en de resultaten ervan te presenteren in een plot.¹

```
# test
```

1.1 Voor we verder gaan..

We hopen dat je dit boek handig vindt om mee te werken. In het kader van Open Science hebben we geprobeerd dit boek volledig transparant en reproduceerbaar te ontwikkelen. De broncode is beschikbaar via <https://github.com/joostjansen/quanterim>. Als je vragen, suggesties of aanpassingen hebt, aarzel niet deze te stellen.²

¹We gaan in een later hoofdstuk zien wat een regressiemodel precies is.

²Het beste is om dit via GitHub te doen in onze Repository.

2 Voorbereiding

Vorbereidingen

Voor we tijdens de lessen aan de slag kunnen met het verrichten van kwantitatief onderzoek, moet de vereiste software geïnstalleerd worden. We gaan werken met R (spreek uit op z'n Engels). R is een programmeertaal die veel statistici gebruiken om hun analyses mee te doen. De omgeving waarin je met R kan werken, heet RStudio. Zowel R als RStudio moeten apart geïnstalleerd worden. Je vindt de installatielinks hieronder:

1. [R](#)
2. [RStudio](#)

Na installatie van de benodigde software moeten we R gereed maken door de juiste packages (ook wel: libraries) te installeren. Veel databewerkingen en analyses vergen namelijk speciaal daarvoor software. Een package waarmee je mooie visualisaties kan maken van je data heet bijvoorbeeld ggplot. Je installeert zo'n package door RStudio te openen en in je console de volgende code te typen en dan te 'runnen':

```
# install.packages("ggplot2")
```

Als je het package geïnstalleerd hebt (eenmalig) laad je in het vervolg aan het begin van elke sessie het package in. Let op: in tegenstelling tot bij het installeren van een package, gebruik je bij het laden ervan geen aanhalingstekens. R is zeer gevoelig voor het verkeerd gebruik van leestekens. Wees daar dus scherp op.

```
library(ggplot2)
```

Hieronder vind je een lijst met alle packages die je tijdens dit vak nodig hebt.

```
#  
# install.packages()  
# install.packages()
```

Part I

Data beschrijven

3 Data

3.1 Wat zijn data?

In de criminologie zijn we geïnteresseerd in diverse vragen die we kunnen beantwoorden aan de hand van statistisch onderzoek. Denk aan de volgende vragen:

- Hoeveel inbraken vinden er jaarlijks plaats in Kralingen?
- Wat is het gemiddelde geldbedrag waarvoor Nederlandse banken hebben geschikt in witwaszaken in 2025?
- Hoeveel misdaadjournalisten zijn er vermoord het afgelopen decennium?
- Wat is de associatie tussen drugsverslaving en delinquentie?
- In hoeverre leidt seksuele straatintimidatie tot het vermijden van bepaalde plekken?

Om deze vragen te kunnen beantwoorden, werken we met **datasets**. Een set is in de wiskunde een verzameling van dingen. Een dataset is dus een verzameling van data. Het woord **data** is afkomstig uit het Latijnse ‘datum’ wat letterlijk ‘gegeven’ betekent. Een dataset is dus een verzameling gegevens. Dit kan gaan over gegevens van mensen (bijvoorbeeld hun lengte of geslacht), maar bijvoorbeeld ook over andere dingen zoals organisaties, steden of landen. Hetgene waar de data informatie over verschaffen (mensen, organisaties, steden, landen) noemen we de **analyse-eenheid**.

In deze cursus werken we steeds met dezelfde dataset. Dit is gebaseerd op een onderzoek onder uitgaande jongeren, [Het Grote Uitgaansonderzoek](#) van het [Trimbos Instituut](#). In dit onderzoek wordt onder andere gekeken hoe vaak jongeren uitgaan, wat voor soort feesten en gelegenheden ze bezoeken, wat voor middelen ze gebruiken (bijvoorbeeld alcohol of andere drugs) en hoe ze denken over drugsgebruik. Om de data te verzamelen is een online enquête afgenomen via een gerichte wervingscampagne.

Laten we eerst kijken hoe zo’n dataset eruitziet. Dat doen we met behulp van R. Zoals aangegeven in de introductie van dit online boek, het is niet erg als je nog niet snapt hoe dit werkt. Daarvoor volg je uiteraard deze cursus :)

```
# laden packages
library(readr)
library(gt)

# laden van de data
```

```
data <- read_rds("data/middelengebruik_uitgaanders.rds")
```

```
# data inspecteren  
head(data[1:5,2:6])
```

	geslacht	leeftijd	opleidingsniveau	alcohol_ooit	alcohol_laatste_jaar
1	man	22	hoog	ja	ja
2	vrouw	23	hoog	ja	ja
3	vrouw	18	midden	ja	nee
4	vrouw	28	hoog	ja	ja
5	man	19	hoog	ja	ja

```
#|> # eerste 5 rijen en kolommen  
#gt() |>  
#tab_header(title = "Voorbeeld van de data") |> # titel geven aan output  
#opt_stylize(style = 6, color = "blue") # lay-out bepalen
```

Hierboven staat een ‘sneak preview’ van de dataset. Waar kijken we nu eigenlijk naar? De dataset verschaft informatie die we verzameld hebben over jongeren die hebben meegedaan aan de enquête. Elke rij representeert een respondent: een jongere die de enquête heeft ingevuld. De rijen zijn onze **observaties**.

Elke kolom bevat de waarde van die respondent met betrekking tot een kenmerk, bijvoorbeeld de waarde die hoort bij een antwoord dat een respondent gaf op een in de enquête gestelde vraag. De waarden van respondenten op kenmerken kunnen variëren van respondent tot respondent. Niet iedereen is even oud, gebruikt even vaak drugs, heeft dezelfde opleiding etc. De variatie in een bepaald kenmerk meten we met behulp van **variabelen**. Deze zien we terug in de kolommen. De kern van statistiek is dat we alle variatie in kenmerken gaan gebruiken om vragen zoals die hierboven te kunnen beantwoorden.

We kunnen bijvoorbeeld zien dat de eerste respondent een xxx is, xx jaar oud, en een xxx opleidingsniveau heeft.

De vierde en vijfde kolom geven aan of iemand ooit alcohol heeft gedronken of in het afgelopen jaar. Hier staat een ‘1’ voor ja en een ‘0’ voor nee. Dit zul je vaker tegenkomen in het werken met datasets, dat cijfers worden gebruikt om kwalitatieve informatie uit te drukken. Hier komen we later nog meer op terug. De voorbeeld data toont dat vier respondenten het afgelopen jaar alcohol hebben gedronken en één respondent niet.

3.1.1 Missende waarden??

4 Meetniveaus en visualisaties

Op de vorige pagina heb je gezien wat een dataset is, en dat deze bestaat uit observaties (de rijen) en variabelen (de kolommen). In de basis zijn er vier manieren om variabelen meetbaar te maken (ook wel: **operationaliseren**). We noemen deze manieren **meetniveaus**. Elk meetniveau verschaft een ander soort informatie. We bespreken hier de vier meetniveaus en daarbij gaan we meteen in op hoe we de informatie die de variabelen verschaffen het beste visueel kunnen presenteren.

Doorgaans maken we onderscheid tussen **kwalitatieve** en **kwantitatieve** variabelen.

4.1 Kwalitatieve variabelen

Kwalitatieve variabelen bestaan uit categorieën die een kwalitatieve eigenschap van een observatie beschrijven. Deze eigenschappen zijn niet direct in cijfers uit te drukken, zoals bij kwantitatieve variabelen. Een belangrijk aspect is dat de categorieën *discreet* zijn: ze moeten elkaar uitsluiten.


4.1.1 Staafdiagram

Laten we naar een voorbeeld kijken: geslacht. Stel dat we willen weten hoeveel mannen, vrouwen of anders-identificerenden er in de dataset zitten. Daarvoor kunnen we **staafdiagram** maken.

```
# laden packages
library(readr)
library(ggplot2)
library(tidyverse)


# laden van de data
data <- read_rds("data/middelengebruik_uitgaanders.rds")

# staafdiagram maken
ggplot(data, aes(x = geslacht)) + # data en variabele selecteren
  geom_bar() # staafdiagram
```



De staafdiagram geeft een visuele presentatie van het aantal mannen, vrouwen en anders-identificerenden in de dataset. Het mooie aan R is dat we de figuur visueel nog wat aantrekkelijker kunnen maken. Hiermee ga je meer oefenen tijdens de cursus.

```
# staafdiagram met betere visualisatie
ggplot(data, aes(x = geslacht)) +
  geom_bar() +
  theme_bw() + # witte achtergrond
  ylab("aantal") # label voor y-as
```



De figuur heeft nu een witte achtergrond en de y-as heeft een Nederlandstalig label.

4.1.2 Simpele tabel

Als je wilt weten hoeveel respondenten er precies in elke categorie zitten, kun je ook een simpele tabel maken met de functie `table()`.

```
# tabel van geslacht  
table(data$geslacht)
```

```
man  vrouw anders  
178   170     2
```

De dataset bevat in totaal dus xxx mannen, xxx vrouwen en xxx in de categorie “anders”.

4.1.3 Nominale variabele

Geslacht is een voorbeeld van een **nominale** variabele. Dit is een kwalitatieve variabele waarin geen rangorde bestaat tussen de categorieën. De variabele bestaat uit kwalitatieve eigenschappen die van elkaar verschillen, maar je kunt niet zeggen dat de ene categorie intrinsiek ‘hoger’ of ‘lager’ is dan de ander.

4.1.4 Taartdiagram


Een andere manier om een nominale variabele te presenteren, is via een **taartdiagram**. Een taartdiagram kan snel een overzicht geven van de verhouding tussen categorieën binnen een bepaalde variabele. Doorgaans werkt een taartdiagram het beste als er een beperkt aantal categorieën zijn.

Hieronder staat een voorbeeld van taartdiagram van de variabele *manier_verkrijgen_drugs*. Dit gaat over de wijze waarop uitgaande jongeren meestal aan hun drugs komen.

(komen later op terug op alle stappen hieronder)

```
# samenvatten van de relevante data
drugs_verkrijgen <- data |>
  filter(!is.na(manier_verkrijgen_drugs)) |> # missende waarden verwijderen
  group_by(manier_verkrijgen_drugs) |> # groeperen op variabele
  summarise(n = n()) |> # aantal respondenten per categorie berekenen
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal


# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  # percentages (y) en categorieën (fill) selecteren
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) + # optie voor taartdiagram
  theme_void() # achtergrond weghalen
```



De taartdiagram weergeeft het aandeel per categorie van hoe jongeren doorgaans aan hun drugs komen. We kunnen de presentatie van de taartdiagram echter nog verbeteren.

```
# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  geom_bar(stat = "identity", width = 1, colour = "white") + # witte randen toevoegen
  coord_polar("y", start = 0) +
  theme_void() +
  geom_text(aes(label = perc), position = position_stack(vjust = 0.5)) + # percentages als labels
  labs(fill = "Manieren van drugs verkrijgen") + # titel voor legenda
  ggtitle("Taartdiagram met manieren van drugs verkrijgen (%)") # titel voor figuur
```

Taartdiagram met manieren van drugs verkrijgen (%)



We hebben nu een duidelijk inzicht in hoe jongeren die drugs gebruiken hier aan komen. Zo zien we bijvoorbeeld dat ongeveer xx procent dit via een dealer koopt, en ongeveer een kwart het koopt via vrienden/kennissen en een kwart het van deze krijgt.


Dit toont meteen een relevante bevinding uit de literatuur over drugsgebruik onder jongeren, namelijk dat de helft van de jongeren hun drugs verkrijgen via “*sorting*” (zie [Parker et al., 2002](#)). Dat wil zeggen, dat een bekende uit een vrienden- of kennissenkring iemand van drugs voorziet eerder dan een dealer.

4.1.5 Ordinale variabele

Een kwalitatieve variabele waarbij er *wel* een bepaalde rangorde (hiërarchie) tussen de categorieën is, noemen we een **ordinaire** variabele.

Laten we weer naar een voorbeeld kijken. In de enquête is gevraagd hoe jongeren hun eigen gezondheid over het algemeen beoordelen. Voor een ordinaire variabele maken we in principe altijd een staafdiagram.

```
# staafdiagram van ervaren gezondheid
ggplot(data, aes(x = ervaren_gezondheid)) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab ("ervaren gezondheid")
```

De staafdiagram toont dat het grootste deel hun gezondheid als “goed” beoordeelt. Een relatief klein deel van de jongeren beoordeelt hun gezondheid als “matig” of zelfs “slecht”.

Dit voorbeeld illustreert een relevant kenmerk van ordinale variabelen: er is een bepaalde rangorde tussen de categorieën, maar de afstand ertussen is niet per se gelijk. Zo is de stap van “matig” naar “goed” bijvoorbeeld kwalitatief anders dan de stap van “zeer goed” naar “uitstekend”. Hierin verschilt een ordinale variabele van een kwantitatieve variabele, bij de laatste is de afstand tussen waarden (1-2-3 etc.) in principe altijd gelijk.

4.2 Kwantitatieve variabelen

Kwantitatieve variabelen zijn numeriek en bestaan dus uit cijfers. De afstand tussen waarden is altijd gelijk en er zit een rangorde in. Bijvoorbeeld bij een rapportcijfer van 1 t/m 10 is de afstand tussen 2 en 3 hetzelfde als de afstand tussen 7 en 8. Kwantitatieve variabelen worden soms ook wel lineaire of continue variabelen genoemd.


4.2.1 Interval en ratio variabelen

Er zijn twee types kwantitatieve variabelen: **interval** en **ratio**. Het verschil tussen deze twee types is dat een interval variabele geen *absoluut nulpunt* kent en een ratio variabele wel.

Leeftijd is bijvoorbeeld een ratio variabele, je kunt namelijk niet jonger dan 0 jaar zijn. Geboortjaar, aan de andere kant, is weer een interval variabele. De christelijke jaartelling begint bij het jaar 0, maar dat is eigenlijk arbitrair omdat de jaren daarvoor ook geteld worden. Het specifieke karakter van de variabele bepaalt dus het meetniveau.

Voor een lineaire variabele met relatief weinig unieke waarden gebruiken we meestal een staafdiagram. Zie hieronder een voorbeeld van de variabele leeftijd.

```
# staafdiagram van leeftijd
ggplot(data, aes(x = as.factor(leeftijd))) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab("leeftijd")
```




De staafdiagram toont dat relatief veel respondenten tussen 21 en 24 jaar zijn, een leeftijd waarop jongeren veel uitgaan.

4.2.2 Histogram

Voor een lineaire variabele met juist relatief veel unieke waarden gebruiken we meestal een histogram. Bij een histogram worden bepaalde waardes gegroepeerd tot één staaf, waardoor

de presentatie overzichtelijk blijft. Dit is hieronder weergegeven voor de variabele *gemoed_dinsdag_na_xtc*. Dit is een score tussen de 0 en 100 die respondenten hebben gegeven hoe zich voelen op de dinsdag na xtc-gebruik in het weekend, waarbij 0 voor negatief staat en 100 voor positief.

```
# histogram van gemoedstoestand op dinsdag na XTC gebruik
ggplot(data, aes(x = gemoed_dinsdag_na_xtc)) +
  geom_histogram(bins = 50) +
  theme_bw() +
  ylab("aantal") +
  xlab("gemoedstoestand (negatief - positief)") +
  xlim(0, 100)
```



4.3 Opties in meetniveaus en transformaties

Stuk tekst over dat variabele niet per se meetniveau bepaalt (bijv leeftijd)

Over variabelen in elkaar omgezet kunnen worden, dus in andere meetniveaus

En nog nadenken over plek dichotome variabele.

Niet ieder meetniveau geeft even veel informatie. Als we informatie willen over de leeftijden van onze respondenten, kunnen we dit op verschillende manieren uitvragen. We kunnen direct

vragen naar hun leeftijd, maar we kunnen ze ook indelen in leeftijdscategorieën (bijv.: jonger dan 18 en 18 jaar en ouder).

4.4 Samenvatting

Het meetniveau gaat over het type variabele en wat voor soort informatie deze bevat. Zoals we later zullen zien, is dit belangrijk om te weten wat voor soort statistische toets we kunnen uitvoeren. We onderscheiden de volgende meetniveaus (tussenhaakjes staat welke figuur we meestal gebruiken):

- nominaal (staaf- of taartdiagram)
- ordinaal (staafdiagram)
- interval (staafdiagram of histogram)
- ratio (staafdiagram of histogram)

5 Centrum- en spreidingsmaten

Inmiddels zijn we bekend met datasets, observaties, variabelen, meetniveaus en figuren. We hebben ook benoemd dat statistiek draait om het analyseren van *variatie* met behulp van de variabelen die in onze dataset zitten. Denk aan: variatie in drugsgebruik, uitgaansgedrag, leeftijden en opleidingsniveau. Om de variatie te analyseren maken we gebruik van diverse centrum- en spreidingsmaten. De meeste hiervan zul je herkennen van eerdere wiskundelessen die je hebt gehad.

5.1 Centrummaten

5.1.1 Gemiddelde

Het gemiddelde $\bar{x}$ berekenen we simpelweg door voor de variabele x alle observaties bij elkaar op te tellen $\sum_{i=1}^n x_i$ en dan te delen door het aantal observaties n . Dit gaat middels de volgende formule.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Formules berekenen en statistische toetsen uitvoeren kunnen we ook handmatig in R doen. Dit is leerzaam, omdat het intuïtie creëert voor hoe je statistisch onderzoek moet uitvoeren.

Stel we nemen vijf respondenten uit de dataset en bekijken hun leeftijd. We vinden de volgende observaties voor leeftijd: 16, 22, 22, 28 en 33.

Hieronder berekenen we in R de gemiddelde leeftijd van deze vijf respondenten.

```
# handmatig gemiddelde berekenen  
(16 + 22 + 22 + 28 + 33) / 5
```

```
[1] 24.2
```

De gemiddelde leeftijd van deze vijf respondenten is dus 24,2. In plaats een handmatige berekening kun je het ook berekenen middels de functie *mean()* in R:

```
# vector aanmaken
x <- c(16, 22, 22, 28, 33)
print(x)
```

```
[1] 16 22 22 28 33
```

```
# gemiddelde berekenen
mean(x)
```

```
[1] 24.2
```

Eerst hebben we een vector, of eigenlijk een variabele, aangemaakt met de vijf observaties. Via de functie *mean()* bereken je vervolgens het gemiddelde.

5.1.2 Mediaan

De mediaan is het getal waar het midden van het aantal observaties is bereikt (50%), oftewel de middelste observatie.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar.

Bij een even aantal cijfers zoals (16, 22, 22, 25, 28, 33) neem je het midden van de middelste twee getallen. In dit geval is dat 23,5 (tussen 22 en 25 jaar).

In R bereken je de mediaan via de functie *median()*.

```
# oneven aantal observaties
median(x)
```

```
[1] 22
```

```
# even aantal observaties
y <- c(16, 22, 22, 25, 28, 33)
print(y)
```

```
[1] 16 22 22 25 28 33
```

```
median(y)
```

```
[1] 23.5
```

5.1.3 Modus

De modus is de waarde die het vaakst voorkomt in een variabele.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar omdat deze leeftijd tweemaal voorkomt en de rest slechts één keer.

In R bereken je de modus via de functie *mfv()*.

```
# package laden
library(modeest)

# modus berekenen
mfv(x)
```

```
[1] 22
```

5.2 Spreidingsmaten

Tekst toevoegen over belang spreiding

5.2.1 Bereik, minimum en maximum

Het bereik R van een variabele is de afstand tussen de laagste (minimum: x_{min}) en hoogste (maximum: x_{max}) waarde. Dit bereken je eenvoudig door de hoogste waarde minus de laagste waarde te nemen:

$$R = x_{max} - x_{min}$$

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is het minimum 16 en het maximum 33. Het bereik is dus $R = x_{max} - x_{min} = 33 - 16 = 17$

```
# handmatig bereik berekenen
33 - 16
```

```
[1] 17
```

Je kunt in R het minimum en maximum opvragen met de functies *min()* en *max()*. Ook kun je allebei tegelijk krijgen met de functie *range()*

```
# minimum opvragen  
min(x)
```

```
[1] 16
```

```
# maximum opvragen  
max(x)
```

```
[1] 33
```

```
# minimum en maximum opvragen  
range(x)
```

```
[1] 16 33
```

De functie *range()* geeft je alleen het minimum en maximum. Als je het bereik wilt weten, moet je zelf het minimum van het maximum aftrekken:

```
# bereik berekenen  
max(x) - min(x)
```

```
[1] 17
```

5.2.2 Variantie

De variantie is een maat voor de spreiding van een variabele die aangeeft hoeveel de waarden onderling van elkaar verschillen. In de statistiek van de sociale wetenschappen zijn er twee soorten variantie: de populatievariantie en steekproefvariantie. Hier komen we later op terug, we rekenen nu voorlopig verder met de steekproefvariantie. De formule daarvoor is:

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

De steekproefvariantie S^2 kun je bereken in een aantal stappen.

Dit doen we aan de hand van de leeftijdsreeks (16, 22, 22, 28, 33) en het gemiddelde hiervan $\bar{x} = 24,2$

Eerst berekenen we voor elke observatie de afstand tot het gemiddelde (de deviatie):

x_i	$x_i - \bar{x}$
16	16 - 24,2 = -8,2
22	22 - 24,2 = -2,2
22	22 - 24,2 = -2,2
28	28 - 24,2 = 3,8
33	33 - 24,2 = 8,8

De optelsom van alle deviaties moet altijd nul zijn: $-8,2 + -2,2 + -2,2 + 3,8 + 8,8 = 0$

In de volgende stap kwadrateren we alle deviaties:

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
16	16 - 24,2 = -8,2	$(-8,2)^2 = 67,24$
22	22 - 24,2 = -2,2	$(-2,2)^2 = 4,84$
22	22 - 24,2 = -2,2	$(-2,2)^2 = 4,84$
28	28 - 24,2 = 3,8	$3,8^2 = 14,44$
33	33 - 24,2 = 8,8	$8,8^2 = 77,44$

Daarvan nemen we de som der kwadraten $\sum_{i=1}^n (x_i - \bar{x})^2 : 67,24 + 4,84 + 4,84 + 14,44 + 77,44 = 168,8$

In de laatste stap delen we de som der kwadraten door het aantal observaties minus één ($n - 1$):

$$168,8 / (5-1) = 42,2$$

De steekproefvariantie van de leeftijd van vijf respondenten is dus 42,2.

Deze stappen kunnen we ook in R uitvoeren.

```
# deviatie voor elke leeftijd
x_deviatie <- x - mean(x) # voor elke waarde van x minus het gemiddelde
print(x_deviatie)
```

```
[1] -8.2 -2.2 -2.2  3.8  8.8
```

```
# kwadrateren van deviaties
x_deviatie_kwa <- x_deviatie^2 # voor elke deviatie het kwadraat nemen
print(x_deviatie_kwa)
```

```
[1] 67.24  4.84  4.84 14.44 77.44
```

```
# som der kwadraten
sum(x_deviatie_kwa) # sum() neemt de som van een vector
```

```
[1] 168.8
```

```
# steekproefvariantie berekenen
variantie_stkpr <- sum(x_deviatie_kwa) / (length(x) - 1) # length() berekent het aantal rijen
print(variantie_stkpr)
```

```
[1] 42.2
```

In R kun je met de functie *var()* de steekproefvariantie ook direct berekenen

```
# steekproefvariantie
var(x)
```

```
[1] 42.2
```

5.2.3 Standaarddeviatie

De variantie is een handig getal om mee te rekenen, maar heeft meestal op zichzelf niet zoveel betekenis. Daarom wordt in onderzoek gebruik gemaakt van de standaarddeviatie (ook wel standaardafwijking genoemd). In combinatie met het gemiddelde en het bereik, geeft de standaarddeviatie meestal een redelijke indicatie van de spreiding van een lineaire variabele (hier komen we later weer op terug). Hoewel wiskundig niet helemaal correct, wordt de standaarddeviatie ook wel gezien als ‘de gemiddelde afstand tot het gemiddelde’.

De standaarddeviatie is de wortel van de steekproefvariantie:

$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

De standaarddeviatie van ons voorbeeld met de leeftijd van vijf respondenten is:

$$S = \sqrt{42,2} = 6,50$$

Je zou dus kunnen zeggen dat een willekeurige persoon van de vijf respondenten ‘gemiddeld’ 6,5 jaar afwijkt van de gemiddelde leeftijd van 24,2 jaar.

```
# standaarddeviatie berekenen  
sqrt(variantie_stkpr) # sqrt() berekent de wortel over een getal/vector
```

```
[1] 6.496153
```

Je kunt de standaarddeviatie ook direct in R krijgen met *sd()*

```
# standaarddeviatie  
sd(x)
```

```
[1] 6.496153
```

5.3 Toepassing op de dataset

We hebben hierboven middels een eenvoudig voorbeeld laten zien hoe de centrum- en spreidingsmaten berekend worden. In onderzoek willen we deze informatie voor variabelen in de hele dataset weten, zodat we snel kunnen zien hoe onze data in elkaar zit.

We vragen hier het gemiddelde, de mediaan en de modus op voor leeftijd in de complete dataset.

```
# laden package  
library(readr)  
  
# laden van de data  
data <- read_rds("data/middelengebruik_uitgaanders.rds")  
  
# centrummaten opvragen  
mean(data$leeftijd) # gemiddelde
```

```
[1] 23.52
```

```
median(data$leeftijd) # mediaan
```

```
[1] 23
```

```
mfv(data$leeftijd) # modus
```

```
[1] 22
```

De gemiddelde leeftijd is 23,5 jaar, de mediaan is 23 jaar en de modus is 22 jaar. Deze waarden liggen dus dicht bij elkaar.

We kunnen ook het minimum, maximum, bereik en de standaarddeviatie berekenen.

```
# spreidingsmaten opvragen  
range(data$leeftijd) # minimum en maximum
```

```
[1] 16 35
```

```
max(data$leeftijd) - min(data$leeftijd) # bereik
```

```
[1] 19
```

```
sd(data$leeftijd) #standaarddeviatie
```

```
[1] 4.782178
```

De minimumleeftijd is 16 jaar, de maximumleeftijd is 35 jaar en het leeftijdsbereik is 19 jaar. De standaarddeviatie is 4,8 jaar.

Veel van deze statistieken (min., max., mediaan, gemiddelde) kun je ook in één keer bekijken middels de functie *summary()*

```
# meerdere statistieken tegelijkertijd opvragen  
summary(data$leeftijd)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
16.00	20.00	23.00	23.52	27.00	35.00


Je ziet dat de *summary()* functie ook de waardes voor 1st Qu. en 3rd Qu. geeft. Dit zijn het eerste en derde kwartiel, de grenzen waarbij respectievelijk 25% (Q1) en 75% (Q3) van de data ligt. In dit geval dus 20,0 en 27,0 jaar. Het tweede kwartiel (Q2) is de mediaan, dit is op de grens van 50% van de data.

5.3.1 Doosdiagram

Ten slotte is er ook een manier om de spreiding van een lineaire variabele te visualiseren. Dit is via een **doosdiagram**.


```
# laden package
library(ggplot2)

# doosdiagram maken
ggplot(data, aes(x = leeftijd)) +
  geom_boxplot() # doosdiagram
```



Zoals we inmiddels hebben gezien, kan de presentatie van de figuur kan nog verbeterd worden.

```
# doosdiagram maken
ggplot(data, aes(x = leeftijd)) +
  geom_boxplot() + # doosdiagram
  theme_bw() +
  scale_x_continuous(breaks = seq(16, 35, by = 1)) + # aanpassen labels x-as, van 16 tot 35
  scale_y_continuous(breaks = NULL) # verwijderen labels y-as (hebben geen betekenis hier)
```



Een doosdiagram weergeeft de spreiding van een variabele en bevat het minimum en maximum, en de grenzen van het 1ste kwartiel, mediaan en 3de kwartiel.

Je kunt aan bovenstaande figuur bijvoorbeeld zien dat alle waarde tussen het 1ste kwartiel en mediaan tussen de 20 en 23 jaar liggen. Het hoogste kwartiel (Q4) omvat relatief veel leeftijden, van 27 tot 35 jaar.

Vergelijk deze doosdiagram met de staafdiagram van leeftijd uit het vorige hoofdstuk. Je ziet dat er verschillende manieren zijn om data te visualiseren.

Nog toe te voegen aan formuleblad:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{N}$$

$$z = \frac{x - \bar{x}}{S}$$

$$s.e. = \frac{S}{\sqrt{n}}$$

6 Relaties tussen variabelen

We hebben tot nu toe gekeken naar wat voor verschillende variabelen er zijn (meetniveaus), hoe we de onderliggende data kunnen visualiseren, en met welke statistische maten we deze variabelen kunnen beschrijven. In onderzoek zijn we niet alleen geïnteresseerd in variabelen zelf, maar nog meer in de **relaties** daartussen. Voor onze dataset zouden we bijvoorbeeld de volgende vragen kunnen stellen:

- Wat is het verschil tussen mannen en vrouwen in drugsgebruik?
- Wat is de relatie tussen leeftijd en drugsgebruik?
- Wat is de relatie tussen leeftijd en acceptatie van drugsgebruik?

Om dergelijke vragen te beantwoorden, moeten we data van verschillende variabelen met elkaar combineren. Daarbij moeten we ons steeds afvragen hoe we deze relaties inzichtelijk willen maken. Het is goed om te realiseren dat hier niet altijd één juist antwoord voor is. Er zijn meerdere manieren om data en relaties te presenteren, waarbij de creativiteit van de onderzoeker relevant is. Over het algemeen zijn er wel gebaande paden die we kunnen volgen.

We letten bij het onderzoeken van relaties tussen variabelen vooral op hun meetniveau. Hebben we bijvoorbeeld te maken met twee kwalitatieve variabelen, één kwalitatief en één kwantitatief, of twee kwantitatieve variabelen? Daaruit kunnen we vaak afleiden wat de handigste manier is om een relatie te presenteren. Denk dus altijd eerst goed na wat het meetniveau van een variabele is.

6.0.1 Kwalitatief vs. kwalitatief

6.0.1.1 nominaal vs. nominaal

Als we de relatie tussen twee nominale variabelen willen presenteren, kunnen we een eenvoudige kruistabel maken in R. We kijken in dit voorbeeld naar de relatie tussen geslacht (man/vrouw/anders) en of men heeft gevapet in het afgelopen jaar (ja/nee). We gaan er hier vanuit dat er geen intrinsieke rangorde bestaat tussen wel of niet vaperen en het dus een nominale variabele betreft.

In hoofdstuk xxx hebben we al een tabel gemaakt voor geslacht. We kunnen aan het commando `table()` een variabele (*vapen_laatste_jaar*) toevoegen om een kruistabel te krijgen.

```
# laden packages
library(readr)
library(tidyverse)
library(ggplot2)

# laden van de data
data <- read_rds("data/middelengebruik_uitgaanders.rds")

# kruistabel tussen geslacht en vaper laatste jaar
table(data$vaper_laatste_jaar, data$geslacht) # vaper in de rijen,
```

	man	vrouw	anders
nee	85	73	0
ja	93	97	2

```
# geslacht in de kolommen
```

We zien in bovenstaande tabel hoe vaak personen van een bepaald geslacht hebben gevaperd het afgelopen jaar. Zo kun je zien dat 73 vrouwen niet hebben gevaperd en 97 wel.


Visueel krijgen we vaak een beter gevoel voor de verhoudingen. We kunnen de verdeling op vaper daarom apart weergeven in een figuur voor geslacht.

Dit doen we hier stapgewijs door eerst de relatie

filter op 'anders'

```
# samenvatten van de relevante data
geslacht_vaper <- data |>
  filter(geslacht != "anders") |> # categorie 'anders' eruit laten
  group_by(geslacht, vaper_laatste_jaar) |> # groeperen op variabelen
  summarise(n = n()) # aantal respondenten per categorie berekenen

# staafdiagrammen maken voor
ggplot(geslacht_vaper, aes(x = geslacht, y = n, fill = vaper_laatste_jaar)) +
  geom_col(position = "dodge")
```

Alleen de absolute aantallen geven niet zo veel inzicht in wat precies de relatie is tussen geslacht en vaper. Daarom is het handiger op de kolompercentages te bereken. Dit doen we *prop.table()* toe te voegen.

```
# kolompercentages voor kruistabel
table(data$vapen_laatste_jaar, data$geslacht) |>
  prop.table(2) # 2 voor kolompercentages (1 voor rijpercentages)
```

	man	vrouw	anders
nee	0.4775281	0.4294118	0.0000000
ja	0.5224719	0.5705882	1.0000000


We zien nu dat 57,1% van de vrouwen wel heeft gevaperd en 42,9% niet. Bij de mannen ligt dit percentage iets lager (52,2% vs. 47,8%). Je zou dus al (voorzichtig) kunnen concluderen dat vrouwen iets meer vaper dan mannen.

```
# vaper frequentie
table(data$vapen_frequentie, data$geslacht) |>
  prop.table(2) # 2 voor kolompercentages (1 voor rijpercentages)
```

	man	vrouw	anders
een keer	0.08602151	0.12371134	0.00000000
minder dan maandelijks	0.39784946	0.28865979	0.00000000
eens per maand	0.12903226	0.10309278	0.00000000
een paar keer per maand	0.06451613	0.20618557	0.00000000
eens per week	0.07526882	0.08247423	0.50000000
een paar keer per week	0.08602151	0.11340206	0.50000000
(bijna) elke dag	0.16129032	0.08247423	0.00000000

```
#
geslacht_vapen_freq <- data |>
filter(geslacht != "anders" &
       !is.na(vapen_frequentie)) |> # categorie 'anders' eruit laten
group_by(geslacht, vapen_frequentie) |> # groeperen op variabelen
summarise(n = n()) |> # aantal respondenten per categorie berekenen
mutate(perc = round(n/sum(n) * 100, 1))

# staafdiagrammen maken voor
ggplot(geslacht_vapen_freq, aes(x = geslacht, y = perc, fill = vapen_frequentie)) +
  geom_col()
```



6.0.1.2 nominaal vs. ordinaal

(principes voor ordinaal vs. ordinaal kan ook)

Part II

Kans en steekproeven

7 Steekproeven

8 Kans

Part III

Hypotheses

Part IV

Samenhang tussen variabelen

Part V

Colleges

9 Collegeslides

Week 1: [College 1](#)

Part VI

Opdrachten

10 Opdrachten

Deze week gaan jullie aan de slag met ...

A Symbolen en formules

A.1 Belangrijke symbolen en formules

Hier vind je een overzicht van alle belangrijke symbolen en formules die we gebruiken.

Symbool	Betekenis
$\sum_{i=1}^n$	Griekse hoofdletter sigma, staat voor ‘sommatie’: alles bij elkaar optellen. De i betekent dat je begint met tellen bij de eerste waarneming, de n dat je stopt bij de laatste.
α	Alpha, het significantieniveau
μ	Mu, het gemiddelde in de <i>populatie</i> (vaak onbekend)
σ	Sigma, de standaarddeviatie in een <i>populatie</i> (vaak onbekend)
σ^2	Sigma kwadraat, de variantie in een <i>populatie</i>
$\sigma_{\bar{x}}$	Sigma mean, standaardfout vna het gemiddelde