quantcrim

Een open-web handboek voor kwantitatief criminologisch onderzoek

Joost Jansen Gijs Custers

2026-11-09

Table of contents

1 Voorwoord **6**

Voorwoord **7**
1.1 Voor we verder gaan.. 8

I Voorbereiding **10**

2 Installatie en introductie R **11**

Voorbereidingen **12**
2.1 Codecademy 12
2.2 R installeren 12
2.2.1 Packages installeren 13
2.3 Computervaardigheden 14

3 Praktische zaken M&T I **15**
3.1 Docenten M&T I 2026-2027 15
3.2 Onderwijsgroepen, practica en colleges 15
3.2.1 Onderwijsgroepen 15
3.2.2 Practica 15
3.2.3 Colleges 16
3.3 Tentamen 17
3.4 Overzicht stof per week 17

II Data beschrijven **18**

4 Data **19**
4.1 **Wat zijn data?** 19
4.1.1 Missende waarden 20

5 Meetniveaus en visualisaties **22**
5.1 Kwalitatieve variabelen 22
5.1.1 Staafdiagram 22
5.1.2 Simpele tabel 24

5.1.3 Nominale variabele . . . 24
5.1.4 Taartdiagram . . . 25
5.1.5 Ordinale variabele . . . 27
5.2 Kwantitatieve variabelen . . . 29
5.2.1 Interval en ratio variabelen . . . 29
5.2.2 Histogram . . . 30
5.3 Meetniveau bepalen . . . 31
5.4 Samenvatting . . . 33

6 Centrum- en spreiding **34**
6.1 Centrummaten . . . 34
6.1.1 Gemiddelde . . . 34
6.1.2 Mediaan . . . 35
6.1.3 Modus . . . 36
6.2 Spreidingsmaten . . . 36
6.2.1 Bereik, minimum en maximum . . . 36
6.2.2 Variantie . . . 38
6.2.3 Standaarddeviatie . . . 40
6.3 Toepassing op de dataset . . . 40
6.3.1 Doosdiagram . . . 42
6.4 Normale verdeling . . . 43
6.5 Z-score . . . 45

7 Relaties tussen variabelen **47**
7.1 Kwalitatief vs. kwalitatief . . . 47
7.1.1 Nominaal vs. nominaal . . . 47
7.1.2 Nominaal vs. ordinaal . . . 50
7.2 Kwalitatief vs. kwantitatief . . . 52
7.3 Kwantitatief vs. kwantitatief . . . 53
7.4 Tot slot . . . 56

III Steekproeven en betrouwbaarheidsinterval **57**

8 Inferentie en steekproeven **58**
8.1 Populatie en steekproef . . . 58
8.2 Steekproevenverdeling en centrale limietstelling . . . 59
8.3 Één steekproef en de standaardfout . . . 64
8.4 Assumpties (the mother of all…) . . . 66
8.4.1 Willekeurige en systematische fouten . . . 66
8.4.2 Willekeurige selectie . . . 67
8.4.3 De constante populatieparameter . . . 67
8.5 Samenvatting . . . 68

9 Betrouwbaarheidsinterval **69**
9.1 Betrouwbaarheidsinterval voor proporties . . . 69
9.1.1 Denkbeeldig voorbeeld . . . 69
9.1.2 Reëel voorbeeld . . . 72
9.1.3 Reëel voorbeeld #2 . . . 76
9.2 Betrouwbaarheidsinterval voor gemiddeldes . . . 78
9.3 Interpretatie betrouwbaarheidsinterval . . . 79
9.4 Samenvatting . . . 81

IV Hypotheses toetsen **82**

10 Hypothesetoetsing **83**
10.1 Wie drinkt er meer? . . . 84
10.2 Statistische significantie . . . 85
10.2.1 1) Hypothese opstellen . . . 85
10.2.2 2) Bepalen significantieniveau . . . 86
10.2.3 3) Overschrijdingskans . . . 86
10.2.4 4) Vergelijken significantieniveau en overschrijdingskans . . . 89
10.3 Wat nog meer... . . . 90
10.4 Beperkingen statistische significantie . . . 91
10.5 Betrouwbaarheidsinterval voor hypothesetoetsing . . . 92
10.6 Samenvatting . . . 94

11 Aspecten van hypothesetoetsing **96**
11.1 T-verdeling . . . 96
11.1.1 Bhi op basis van t-verdeling . . . 98
11.2 Hypotheses formuleren . . . 100
11.3 Tweezijdig/eenzijdig toetsen . . . 102
11.4 Type-I en type-II fouten . . . 104
11.5 Samenvatting . . . 105

12 T-toets afhankelijke groepen **106**
12.1 Beetje pips van de dips . . . 107
12.1.1 Hypothese opstellen . . . 108
12.1.2 Handmatige berekening . . . 108
12.1.3 Computerberekening . . . 110
12.1.4 Interpretatie en conclusie . . . 111
12.2 Samenvatting . . . 111

V Colleges en practica **112**

13 Collegeslides **113**

14 Opdrachten **114**

Appendices **115**

A Symbolen en formules **115**

1 Voorwoord

Voorwoord

Welkom bij het **quantcrim handboek**! Hier ga je leren hoe je allerlei vormen van kwantitatieve data kan analyseren met R en welke principes daaraan ten grondslag liggen. Het boek is ontworpen en *open-access* beschikbaar gesteld door docenten en onderzoekers van de opleiding Criminologie aan de Erasmus Universiteit Rotterdam. Het boek is bedoeld voor zowel bachelor-, master als oud-studenten en iedereen met interesse in kwantitatief criminologisch onderzoek. Ons streven is om de studiematerialen van de vakken Methoden en Technieken I & II en Research Labs in dit boek te verwerken.

Waarom een apart boek voor onze opleiding? Daarvoor zijn meerdere redenen. Allereerst denken we dat er behoefte is aan een handboek dat de theorie, uitvoering en praktische implicaties van kwantitatieve analysemethoden meer met elkaar intergreert. Een andere reden is dat statistiek en kwantitatieve methodenvakken worden vaak beschouwd als een vastomlijnde set aan technieken die neerkomen op het volgen van een geheel aan 'juiste' stappen. Hoewel we inderdaad vaak stappen volgen, is er binnen de sociale wetenschappen in toenemende mate discussie over wat dan de juiste stappen zijn. Die onenigheid komt meestal niet aan bod in het doorsnee statistiekboek. Enerzijds is dat begrijpelijk; over statistiek leren is vaak al spannend genoeg! Anderzijds vinden wij het echter belangrijk - zeker in een tijd waarin data een steeds belangrijkere rol spelen in processen van bedrijfs- en besluitvorming en beleidsontwikkeling! - om te weten dat ook het doen van kwantitatief onderzoek omgeven is met allerlei complexiteit. Dat vergt ook een zekere nederigheid vanuit de onderzoekers. Statistieken vormen namelijk een krachtig hulpmiddel om allerlei vraagstukken mee van duiding te kunnen voorzien, maar kunnen in de verkeerde handen ook misbruikt worden voor allerlei dubieuze ideologische doeleinden.[1]

We denken dat het belangrijk is om open en transparant te zijn over de aannames die we doen over de werkelijkheid, de stand van onze kennis daarover en de toepasbaarheid en zeggingskracht van onze analysemethodes. Met dit *open-access* boek proberen we aan deze visie zelf ook uitdrukking te geven. We willen niet dat jullie straks afgestudeerd zijn en denken dat statistiek alleen bestaat uit het bepalen of een resultaat significant is, en dat daarmee de kous af is. We hopen wat meer ruimte te bieden aan alle complexiteit rondom het doen van kwantitatieve analyses, zonder daarmee het belang en nut van het analyseren van cijfers en statistieken uit het zicht te willen verliezen! Wij denken dat het voor criminologen heel belangrijk is 'datageletterd' te zijn. Onze visie op wat je over kwantitatief onderzoek zou moeten leren is een product van alle kennis en ervaring die we de afgelopen jaren hebben opgedaan als onderzoekers en docenten, maar ook van wat we achteraf zelf graag geleerd hadden willen hebben als student.

[1] Niet voor niets luidt een bekende uitspraak: *"There are three kinds of lies: lies, damned lies, and statistics."*

We denken dat dit boek handig is omdat:

- Het boek laat zien dat er diverse manieren zijn om kwantitatieve onderzoeksvraagstukken te benaderen, en dat er bij al die manieren aannames komen kijken waarover we expliciet moeten zijn als we over de resultaten communiceren;
- Het boek uitleg en voorbeelden integreert met werken in R. Daarmee verbinden we theorie en praktijk;
- Het boek nadruk de ligt op de presentatie en visualisatie van data. Dit draagt bij aan wat tegenwoordig 'datageletterdheid' heet: het beschikken over de kennis en vaardigheden om - met behulp van allerlei databronnen - vraagstukken in het werkveld te kunnen duiden;
- Het gebruik maakt van criminologische voorbeelden, waardoor we hopen dat je in gaat zien dat het spelen met en analyseren van kwantitatieve data bovenal ook leuk is;
- Het een boek over R is, gemaakt met R .

1.1 Voor we verder gaan..

In het kader van Open Science hebben we geprobeerd dit boek volledig transparant en reproduceerbaar te ontwikkelen. De broncode is beschikbaar via GitHub. Als je vragen, suggesties of aanpassingen hebt, aarzel niet deze te stellen.[2]

Net als alle wetenschappers, staan wij op de schouders van reuzen. De inhoud van dit boek is onder andere gebaseerd op de volgende bronnen:

Clayton, A. (2021). *Bernoulli's fallacy: Statistical illogic and the crisis of modern science.* Columbia University Press.

Favero, N. (2026). *Statistics minus the math: An introduction for the social sciences* (2nd ed.). https://minusthemath.com/2e/

Hespanhol, L., Vallio, C. S., Costa, L. M., & Saragiotto, B. T. (2019). Understanding and interpreting confidence and credible intervals around effect estimates. *Brazilian Journal of Physical Therapy*, *23*(4), 290-301.

Lambert, B. (2018). *A student's guide to Bayesian statistics.* SAGE Publications Ltd.

Martin, J. L. (2018). *Thinking through statistics.* Chicago: University of Chicago Press.

McElreath, R. (2018). *Statistical rethinking: A Bayesian course with examples in R and Stan.* CRC Press.

Navarro, D.J. (2024). *Learning statistics with R: A tutorial for psychology students and other beginners.* University of New South Wales.

Spiegelhalter, D. (2019). *The art of statistics.* Basic Books.

[2]Het beste is om dit via GitHub te doen in onze Repository.

van Groenestijn, P., & Visser, M. (2023). *Statistiek als hulpmiddel: Een overzicht van gangbare toepassingen in de sociale wetenschappen* (4e herz. dr.). Uitgeverij Koninklijke Van Gorcum.

Wasserstein, R. L., Schirm, A. L., & Lazar, N. A. (2019). Moving to a world beyond "p< 0.05". *The American Statistician*, *73*(sup1), 1-19.

Part I

Voorbereiding

2 Installatie en introductie R

Voorbereidingen

Voor aanvang van het eerste kwantitatieve practicum dien je drie dingen te hebben gedaan: het bestuderen van de stof van de eerste week (zie ook Praktische zaken), een online cursus voor R en R installeren. De laatste twee dingen zul je sowieso 4 tot 6 uur mee bezig zijn. Begin hier dus op tijd mee zodat je niet op de avond voor het practicum R nog aan de praat moet krijgen.

We gaan dus werken met R.[1] R is een programmeertaal die veel statistici en sociale wetenschappers gebruiken om hun analyses mee te doen. Het is een superhandig programma, maar voor beginners ook uitdagend. Vooral als je geen ervaring hebt met programmeren en computeren in het algemeen. Het is normaal dat je paniek, frustratie en onzekerheid zult ervaren. Ga dus niet meteen bij de pakken neerzitten. R heeft een steile leercurve. Op het begin lijkt het hocus pocus; na 4 weken zul je versteld staan van wat je allemaal kan. Ons advies is: blijf kalm en stop niet met oefenen totdat het wel lukt.

2.1 Codecademy

Om een zachte introductie in de programmeertaal R te hebben, moet je van tevoren een online cursus doen. Zonder deze cursus zul je niet het basisniveau hebben om de practicumopdrachten te maken.

De gratis cursus is van Codecademy. Je moet een gratis account aanmaken om de cursus te kunnen volgen, via Sign Up (je kunt alle bedrijfs- en persoonlijke informatie skippen). Vervolgens doorloop je **de eerste twee modules** van de cursus: Introduction en Data Frames. De rest hoef je niet te doen (ook niet de opties waar je voor moet betalen). De website van Codecademy spreekt voor zichzelf. De link naar de cursus kun je hier vinden. Wederom: deze cursus kost je wel een aantal uur, begin dus op tijd!

2.2 R installeren

Om op je eigen laptop te kunnen werken tijdens de practica, moet je eerst R installeren. Dit is zeer aan te raden. Je kunt in principe ook op de PCs werken in de computerzalen, maar dan

[1] Je spreekt het uit op z'n Engels, als een piraat: "arrrrh". Als je meer een type bent voor Hollandse verbastering kun je "errr" zeggen.

kun je thuis niet oefenen.

R bestaat uit twee programma's: R and RStudio. Je moet beide programma's apart downloaden en installeren. Rstudio is het programma waar je uiteindelijk in werkt. R draait daarbij op de achtergrond. Rstudio werkt niet zonder dat je R hebt geïnstalleerd.

Je vindt de installatielinks hieronder:

1. R

Klik op "Download R..." voor jouw besturingssysteem (Windows of Mac voor de meesten). Klik vervolgens op de link bij "install R for the first time". Open het bestand en volg de instructies voor installatie.

2. RStudio

Klik op "Download installer". Open het bestand en volg de instructies voor installatie.

2.2.1 Packages installeren

Na installatie moeten we R gereed maken voor de practica door de relevante packages (ook wel: libraries) te installeren. Veel databewerkingen en analyses vergen namelijk speciaal daarvoor ontwikkelde software. Je installeert zo'n package door RStudio te openen en in je console code te typen (`install.packages("jouw package")`) en dan te 'runnen'. Of je opent een nieuw R script in RStudio waarbij je hetzelfde doet. Hieronder staat de code met de juiste packages. Dit is een kwestie van deze code kopiëren in R en het te runnen. Dit moet je dus doen voordat je aan de eerste practicumopdracht begint, anders zal R niet op de juiste manier werken.

```
# installeren packages
install.packages("tidyverse")
install.packages("modeest")
install.packages("plotrix")
install.packages("rmarkdown")
tinytex::install_tinytex()
install.packages("knitr")
```

Als je de packages hebt geïnstalleerd, laad je in het vervolg aan het begin van elke sessie de packages in via het commando `library()`.[2] Let op: in tegenstelling tot bij het installeren van een package, gebruik je bij het laden ervan geen aanhalingstekens. R is zeer gevoelig voor het verkeerd gebruik van leestekens en ook hoofd- en kleine letters. Wees daar dus scherp op.

Hieronder vind je een lijst met alle packages die je tijdens dit vak nodig hebt. Deze code wordt al het begin van elk practicum gegeven.

[2]Het installeren van de packages via `install_packages()` hoef je slechts eenmalig te doen.

```
# laden packages
library(tidyverse)
library(modeest)
library(plotrix)
library(rmarkdown)
library(knitr)
```

2.3 Computervaardigheden

We willen ten slotte duidelijkheid scheppen over wat we verwachten van jullie op computervlak. We hebben de laatste jaren gemerkt dat een deel van de studenten steeds minder vaardig is als het gaat om wat we vroeger 'computeren' noemden. Dat is niet gek; tegenwoordig kan je zo'n beetje alles via je smartphone of tablet doen. Als je niet zo goed bent met computeren is dat niet meteen jouw schuld. Voor dit vak, voor je gehele studie, en later voor je carrière zul je echter toch enige basis computervaardigheden moeten hebben. Daaronder verstaan wij dingen als bestanden kunnen opslaan/openen/verplaatsen in File Explorer, een programma kunnen downloaden en installeren, een vastgelopen programma afsluiten via Taakbeheer (ctrl+alt+del), weten hoe je een bijlage verstuurt via email en zelfstandig oplossingen kunnen vinden via zoekmachines. Zonder dergelijke vaardigheden wordt het lastig om je studie te halen, laat staan met R leren werken.

Wij zijn verder docenten die je met de inhoud van de cursus helpen, geen IT-helpdesk. Mocht je merken dat je moeite hebt deze basisvaardigheden, dan is nu het moment om je computerskills te gaan upgraden door te oefenen, oefenen, en nogmaals te oefenen. We gaan uit van een zekere mate van zelfstandigheid. Je kunt altijd een beroep doen Google[3], je medestudenten, vrienden of familie. Mocht je dan alsnog helemaal vastlopen, dan kun je ons aanspreken.

[3] Al verkiezen wij DuckDuckGo.

3 Praktische zaken M&T I

Hier volgt een korte beschrijving met informatie en wat er van je wordt verwacht voor het kwanti-deel van het vak M&T I.

3.1 Docenten M&T I 2026-2027

Gijs Custers - blokcoördinator en practicumdocent. Email: custers@law.eur.nl

Zoë van Wingerden - practicumdocent. Email: z.p.vanwingerden@law.eur.nl

3.2 Onderwijsgroepen, practica en colleges

3.2.1 Onderwijsgroepen

In de onderwijsgroepen leer je over methodologische aspecten die relevant zijn voor kwantitatief onderzoek. Denk hierbij aan zaken als validiteit, betrouwbaarheid, operationaliseren en causaliteit. De kennis die je hier op doet zul je weer toepassen in de practica en colleges, en vice versa.

3.2.2 Practica

Tijdens de practica ga je aan de slag met de stof van die week. Je gaat opgaven maken die zich richten op het werken met data en beschrijvende en inferentiële technieken. Bij aanvang van het practicum kun je de practicumopdracht van die week downloaden bij Opdrachten. Dit is een R markdown file waarin opdrachten en instructies staan.

Je kunt tijdens de practica op je eigen laptop werken of op een pc in de computerzaal. Je bent zelf verantwoordelijk voor het goed opslaan en inleveren van je opdracht.

Tijdens de practica kun je vragen stellen aan de docenten over de opdracht. Als de docenten druk zijn, kan het wat langer duren voordat je wordt geholpen. Je kunt ook mede-studenten vragen om hulp. Wees lief en heb een beetje geduld (zo zijn wij ook).

Na de deadline voor de inspanningsverplichting worden de uitwerkingen van de opdrachten gepubliceerd onder Opdrachten.

3.2.2.1 Voorbereiding

Om de opdrachten goed te kunnen maken, is het noodzakelijk dat je de stof van die week *voorafgaand* aan het practicum hebt bestudeerd. Dit betekent alles (meerdere malen) goed doorlezen, aantekeningen maken en zelfstandig dingen op- en nazoeken. Verwacht vooral ook niet dat alles in één keer duidelijk kan en moet zijn. Als wij (als docenten) nieuwe analysetechnieken leren of wiskundige formules willen begrijpen, hebben we daar ook tijd voor nodig en gaat dat ook dikwijls met hoofdpijn gepaard.

Zonder voorbereiding kun je de practicumopdracht niet maken. Dan ga je vervolgens niet voldoen aan de inspanningsverplichting en uiteindelijk het vak het niet halen. Bespaar jezelf die stress en bereid je gewoon goed voor.

3.2.2.2 Aanwezigheids- en inspanningsverplichting

De **aanwezigheidsplicht** betekent, zoals het woord al zegt, dat je bij elk practicum verplicht aanwezig moet zijn. Bij overmacht dien je *voorafgaand* aan het practicum Zoë via email (z.p.vanwingerden@law.eur.nl) te informeren over jouw afwezigheid met een geldige reden. Slappe smoesjes achteraf zijn we niet van gediend.

De **inspanningsverplichting** betekent dat je de practicumopdracht van die week op tijd, volledig en op niveau inlevert. Dit om te laten zien dat je serieus aan de opdracht hebt gewerkt. De deadline is standaard **vrijdag 23:59** na het desbetreffende practicum. Je kunt de opdracht als pdf-bestand inleveren via een uploadbox in Canvas. De opdracht wordt beoordeeld als complete (volledig en op niveau) of incomplete. Bij een incomplete heb je niet aan de inspanningsverplichting voldaan. Een complete zegt daartegen niks over of de inhoudelijke antwoorden juist zijn. Dat moet je zelf later via de uitwerkingen checken.

Bij afwezigheid dien je nog steeds aan de inspanningsverplichting te voldoen, behalve in het geval van overmacht.

Je dient aan beide verplichtingen te voldoen om recht te hebben op je cijfer van het kwanti-tentamen, en daarmee je eindcijfer. Het is *niet* mogelijk de aanwezigheids- en inspanningsverplichting te compenseren via vervangende opdrachten. Als je niet voldoet aan de verplichtingen, moet je bij Gijs op het matje komen die over jouw lot beslist. Dat wil je natuurlijk voorkomen.

3.2.3 Colleges

De colleges dienen zowel ter verdieping als herhaling van de stof. Week 5 is een inhoudelijk college waarin meer wordt uitgelegd over onderzoeksontwerpen en surveyonderzoek. In week 6 t/m 8 gaan we verder oefenen met opdrachten in R, waarin we steeds de stof van de week

daarvoor herhalen. We zullen een aantal nieuwe oefeningen samen doorlopen in R. Dit is een vorm van *live-coding* waarin jullie actief meedoen. Zorg dus dat je je laptop meeneemt!

3.3 Tentamen

Het kwanti-tentamen zal een mix zijn van vragen over de stof uit de onderwijsgroepen, practica en colleges. Met name de problemen 4, 5 en 6 zijn relevant. Ook is de kennis uit problemen 1 en 2 nodig om de vragen überhaupt te begrijpen. Ongeveer 50% van de vragen zullen gaan over methodologische en inhoudelijke aspecten, en 50% is concreet werken met R. De tentamenvragen over R hebben dezelfde vorm als in de practica, je kunt dus oefenen met de practicum- en collegeopdrachten.

3.4 Overzicht stof per week

Week	**Voorbereiding en practicum**	**College**
4	Data beschrijven	-
5	Steekproeven en betrouwbaarheidsinterval	Verdieping onderzoeksontwerp en steekproeven
6	Hypotheses toetsen	Herhaling stof week 4-5
7	Bayes fator, Chi^2 en correlatie	Herhaling stof week 4-6
8	Geen practicum	Herhaling stof week 4-7 & responsie

Part II

Data beschrijven

4 Data

4.1 Wat zijn data?

In de criminologie zijn we geïnteresseerd in diverse vragen die we kunnen beantwoorden aan de hand van statistisch onderzoek. Denk aan de volgende vragen:

- Hoeveel inbraken vinden er jaarlijks plaats in Kralingen?
- Wat is het gemiddelde geldbedrag waarvoor Nederlandse banken hebben geschikt in witwaszaken in 2025?
- Hoeveel misdaadjournalisten zijn er vermoord het afgelopen decennium?
- Wat is de associatie tussen drugsverslaving en delinquentie?
- In hoeverre leidt seksuele straatintimidatie tot het vermijden van bepaalde plekken?

Om deze vragen te kunnen beantwoorden, werken we met **datasets**. Een set is in de wiskunde een verzameling van dingen. Een dataset is dus een verzameling van data. Het woord **data** is afkomstig uit het Latijnse 'datum' wat letterlijk 'gegeven' betekent. Een dataset is dus een verzameling gegevens. Dit kan gaan over gegevens van mensen (bijvoorbeeld hun lengte of geslacht), maar bijvoorbeeld ook over andere dingen zoals organisaties, steden of landen. Hetgene waar de data informatie over verschaffen (mensen, organisaties, steden, landen) noemen we de **analyse-eenheid**.

In deze cursus werken we steeds met dezelfde dataset. Deze is gebaseerd op een onderzoek onder uitgaande jongeren, Het Grote Uitgaansonderzoek van het Trimbos Instituut.[1] In dit onderzoek wordt onder andere gekeken hoe vaak jongeren uitgaan, wat voor soort feesten en gelegenheden ze bezoeken, wat voor middelen ze gebruiken (bijvoorbeeld alcohol of andere drugs) en hoe ze denken over drugsgebruik. Om de data te verzamelen is een online enquête afgenomen via een gerichte wervingscampagne.

Laten we eerst kijken hoe zo'n dataset eruitziet. Dat doen we met behulp van R. Het is niet erg als je nog niet snapt hoe dit werkt. Daarvoor volg je uiteraard deze cursus :)

```
# laden van de voorbeeld data
voorbeeld_data <- read_rds("data/voorbeeld_data.rds")
```

[1] De data is synthetisch, wat betekent dat het geen echte data is, maar gesimuleerd op basis van de statistieken in het originele onderzoek.

```r
# data inspecteren
head(voorbeeld_data) # head() voor bekijken bovenste rijen
```

```
  geslacht leeftijd opleidingsniveau alcohol_ooit alcohol_laatste_jaar
1    vrouw       30           midden          ja                   ja
2      man       21             laag          ja                   ja
3    vrouw       35           midden          ja                  nee
4      man       16             hoog          ja                   ja
5      man       26             <NA>          ja                   ja
6    vrouw       18             laag          ja                   ja
```

Hierboven staat een 'sneak preview' van de dataset. Waar kijken we nu eigenlijk naar? De dataset verschaft informatie die we verzameld hebben over jongeren die hebben meegedaan aan de enquête. Elke rij representeert een **respondent**: een jongere die de enquête heeft ingevuld. De rijen zijn onze **observaties**.

Elke kolom bevat de waarde van die respondent met betrekking tot een kenmerk, de waarde die hoort bij een antwoord dat een respondent gaf op een in de enquête gestelde vraag. De waarden van respondenten op kenmerken kunnen variëren van respondent tot respondent. Niet iedereen is even oud, gebruikt even vaak drugs, heeft dezelfde opleiding etc. De variatie in een bepaald kenmerk meten we met behulp van **variabelen**. Deze zien we terug in de kolommen. De kern van statistiek is dat we alle variatie in kenmerken gaan gebruiken om onderzoeksvragen zoals die hierboven te kunnen beantwoorden.

We kunnen bijvoorbeeld zien dat de eerste respondent een vrouw is, 30 jaar oud, en een middelbaar opleidingsniveau heeft.

De vierde en vijfde kolom geven aan of iemand ooit alcohol heeft gedronken of in het afgelopen jaar. De voorbeeld data toont dat vijf respondenten het afgelopen jaar alcohol hebben gedronken en één respondent niet.

4.1.1 Missende waarden

Wat je misschien ook is opgevallen, is dat in de vijfde rij bij opleidingsniveau 'NA' staat. Dit staat voor Not Available en geeft aan dat er geen valide waarde is voor deze respondent op dit kenmerk. Van deze persoon weten we het opleidingsniveau dus niet. Dit noemen we een **missende waarde**.

Missende waarden komen vaak voor in onderzoek om diverse redenen. Zo kunnen mensen een vraag verkeerd invullen, een vraag per ongeluk overslaan, of een vraag niet willen beantwoorden. Dit laatste zien we vaker bij gevoelige vragen, bijvoorbeeld over gedrag dat maatschappelijk wordt afgekeurd (drugsgebruik!).

Missende waarden hoeven niet altijd een probleem te zijn. Dit hangt af van de de aard van missende waarden en de hoeveelheid. In de practica besteden we hier meer aandacht aan.

5 Meetniveaus en visualisaties

Op de vorige pagina heb je gezien wat een dataset is, en dat deze bestaat uit observaties (de rijen) en variabelen (de kolommen). In de basis zijn er vier manieren om variabelen meetbaar te maken (ook wel: operationaliseren). We noemen deze manieren **meetniveaus.** Elk meetniveau verschaft een ander soort informatie. We bespreken hier de vier meetniveaus en daarbij gaan we meteen in op hoe we de informatie die de variabelen verschaffen het beste visueel kunnen presenteren.

Doorgaans maken we onderscheid tussen **kwalitatieve** en **kwantitatieve** variabelen.

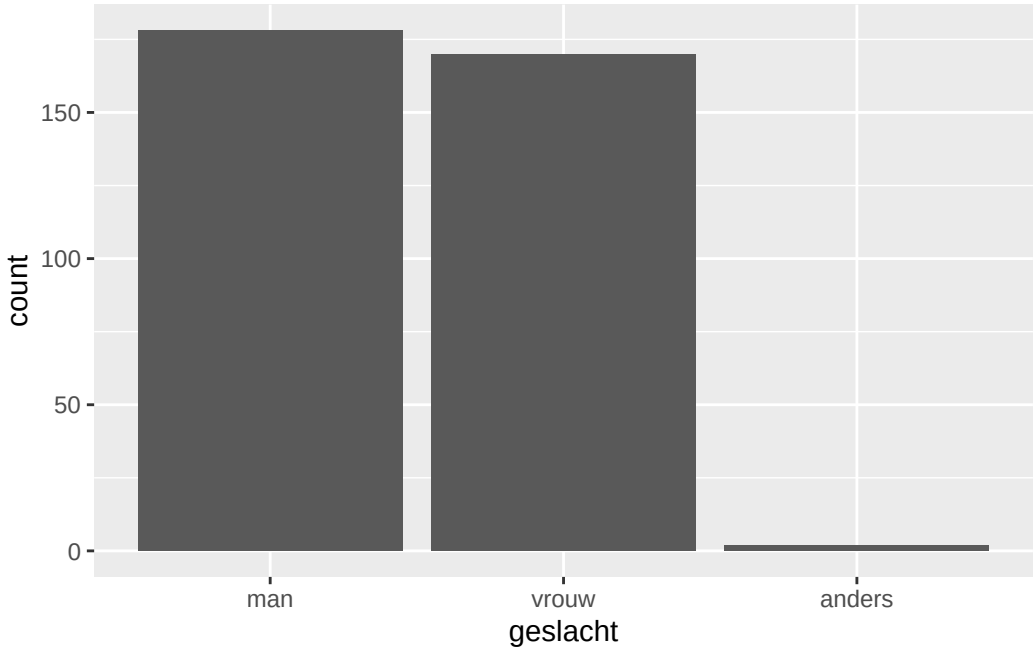
5.1 Kwalitatieve variabelen

Kwalitatieve variabelen bestaan uit categorieën die een kwalitatieve eigenschap van een observatie beschrijven. Deze eigenschappen zijn niet direct in cijfers uit te drukken, zoals bij kwantitatieve variabelen. Een belangrijk aspect is dat de categorieën *discreet* zijn: ze moeten elkaar uitsluiten.

5.1.1 Staafdiagram

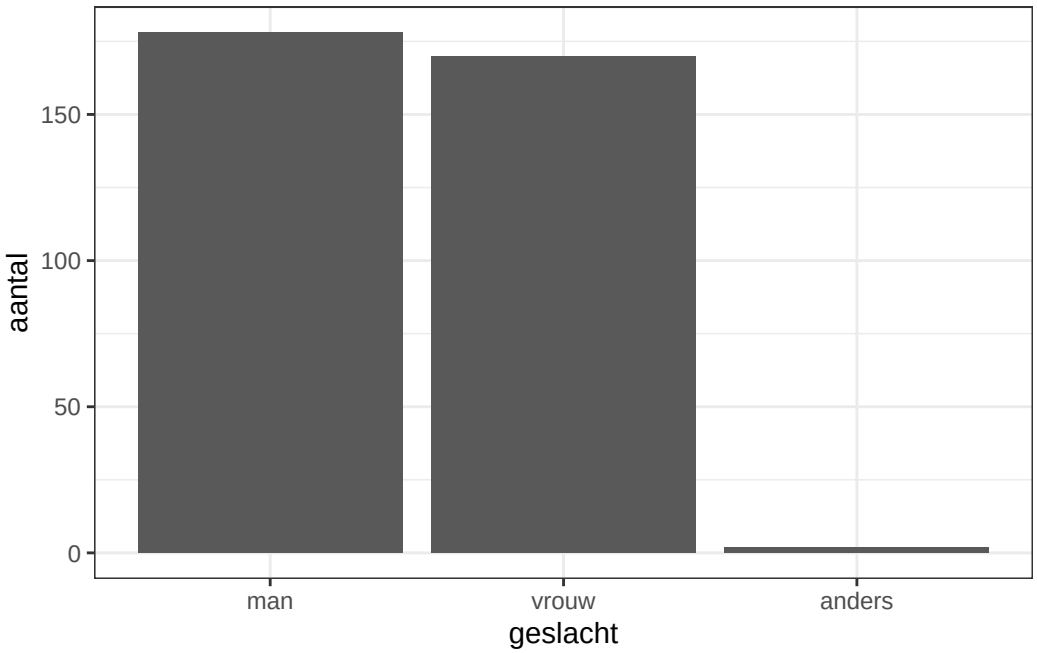
Laten we naar een voorbeeld kijken: geslacht. Stel dat we willen weten hoeveel mannen, vrouwen of anders-identificerenden er in de dataset zitten. Daarvoor kunnen we **staafdiagram** maken met `ggplot()`.

```
# staafdiagram maken
ggplot(data_uitgaan, aes(x = geslacht)) + # data en variabele selecteren
  geom_bar() # staafdiagram
```



De staafdiagram geeft een visuele presentatie van het aantal mannen, vrouwen en anders-identificerenden in de dataset. Het mooie aan R is dat we de figuur visueel nog wat aantrekkelijker kunnen maken. Hiermee ga je meer oefenen tijdens de practica.

```
# staafdiagram met betere visualisatie
ggplot(data_uitgaan, aes(x = geslacht)) +
  geom_bar() +
  theme_bw() + # witte achtergrond
  ylab("aantal")  # label voor y-as
```



De figuur heeft nu een witte achtergrond en de y-as heeft een Nederlandstalig label.

5.1.2 Simpele tabel

Als je wilt weten hoeveel respondenten er precies in elke categorie zitten, kun je ook een simpele tabel maken met de functie `table()`.

```
# tabel van geslacht
table(data_uitgaan$geslacht)
```

```
   man  vrouw anders
   178    170      2
```

De dataset bevat in totaal dus 178 mannen, 170 vrouwen en 2 personen in de categorie "anders".

5.1.3 Nominale variabele

Geslacht is een voorbeeld van een **nominale** variabele. Dit is een kwalitatieve variabele waarin geen rangorde bestaat tussen de categorieën. Mannen hebben niet intrinsiek meer waarde dan

vrouwen, of andersom. De variabele bestaat uit discrete categorieën die elkaar uitsluiten, maar je kunt niet zeggen dat de ene categorie 'hoger' of 'lager' is dan de ander.

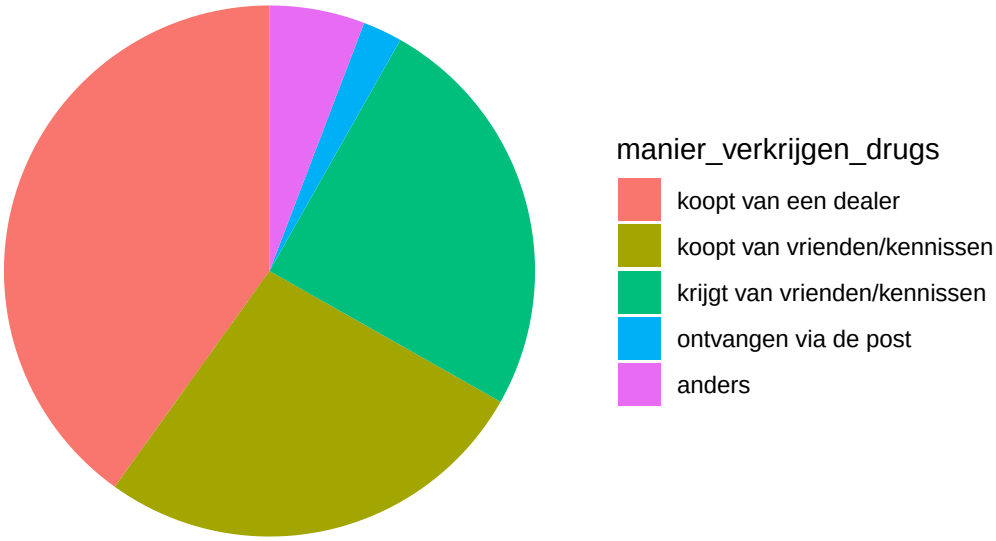
5.1.4 Taartdiagram

Een andere manier om een nominale variabele te presenteren, is via een **taartdiagram**. Een taartdiagram kan snel een overzicht geven van de verhouding tussen categorieën binnen een bepaalde variabele. Doorgaans werkt een taartdiagram het beste als er een beperkt aantal categorieën zijn.

Hieronder staat een voorbeeld van taartdiagram van de variabele `manier_verkrijgen_drugs`. Dit gaat over de wijze waarop uitgaande jongeren meestal aan hun drugs komen.

```
# samenvatten van de relevante data
drugs_verkrijgen <- data_uitgaan |>
  filter(!is.na(manier_verkrijgen_drugs)) |> # missende waarden verwijderen
  group_by(manier_verkrijgen_drugs) |> # groeperen op variabele
  summarise(n = n()) |> # aantal respondenten per categorie berekenen
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal

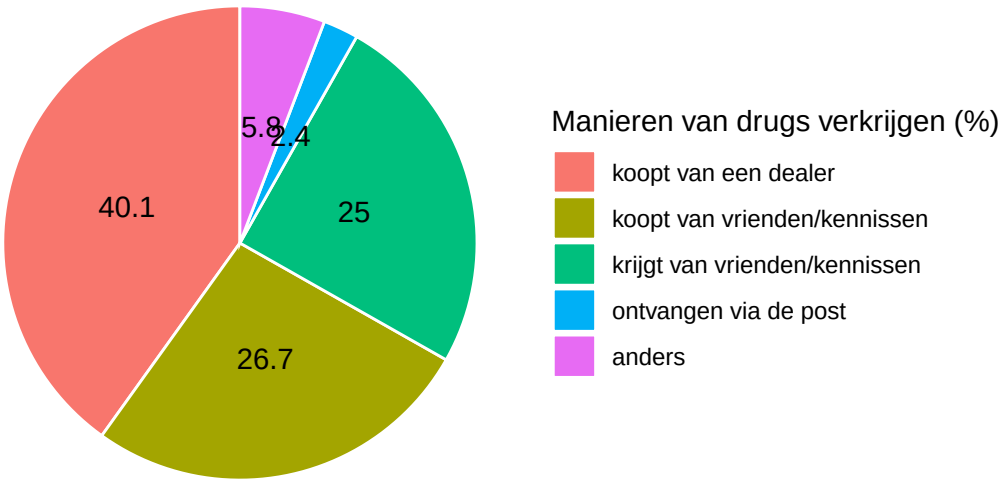
# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  # percentages (y) en categorieen (fill) selecteren
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y", start = 0) + # optie voor taartdiagram
  theme_void() # achtergrond weghalen
```



Je kan zien dat er best wat regels code nodig zijn om deze taartdiagram te maken. Hoe dat precies in zijn werk gaat, wat elke regel doet, gaan we tijdens de practica behandelen.

De taartdiagram weergeeft het aandeel per categorie van hoe jongeren doorgaans aan hun drugs komen. We kunnen de presentatie van de taartdiagram echter nog verbeteren.

```
# taartdiagram van hoe drugs worden verkregen
ggplot(drugs_verkrijgen, aes(x= "", y = perc, fill = manier_verkrijgen_drugs)) +
  geom_bar(stat = "identity", width = 1, colour = "white") + # witte randen toevoegen
  coord_polar("y", start = 0) +
  theme_void() +
  geom_text(aes(label = perc), position = position_stack(vjust = 0.5)) + # percentages als la
  labs(fill = "Manieren van drugs verkrijgen (%)") # titel voor legenda
```



We hebben nu een duidelijk inzicht in hoe jongeren die drugs gebruiken hier aan komen. Zo zien we bijvoorbeeld dat ongeveer 40 procent dit via een dealer koopt, en ongeveer een kwart het koopt via vrienden/kennissen en een kwart het van deze krijgt.

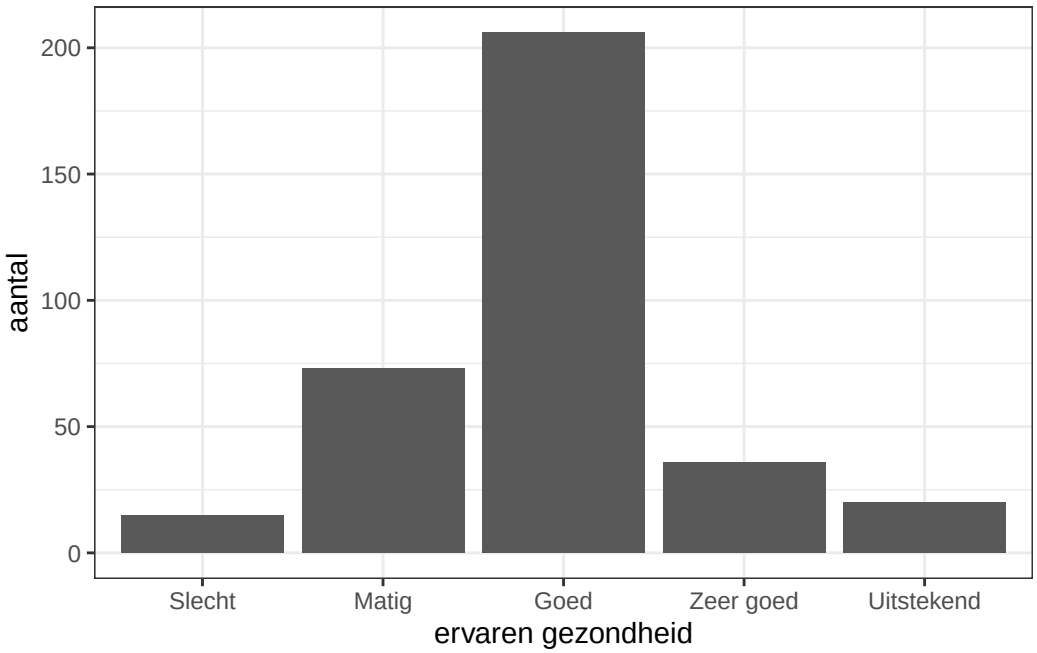
Dit toont meteen een relevante bevinding uit de literatuur over drugsgebruik onder jongeren, namelijk dat de helft van de jongeren hun drugs verkrijgen via "*sorting*" (zie Parker et al., 2002). Dat wil zeggen, dat een bekende uit een vrienden- of kennissenkring iemand van drugs voorziet eerder dan een dealer.

5.1.5 Ordinale variabele

Een kwalitatieve variabele waarbij er *wel* een bepaalde rangorde (hiërarchie) tussen de categorieën is, noemen we een **ordinale** variabele.

Laten we weer naar een voorbeeld kijken. In de enquête is gevraagd hoe jongeren hun eigen gezondheid over het algemeen beoordelen. Voor een ordinale variabele maken we in principe altijd een staafdiagram.

```
# staafdiagram van ervaren gezondheid
ggplot(data_uitgaan, aes(x = ervaren_gezondheid)) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab ("ervaren gezondheid")
```



De staafdiagram toont dat het grootste deel hun gezondheid als “goed” beoordeelt. Een relatief klein deel van de jongeren beoordeelt hun gezondheid als “matig” of zelfs “slecht”.

Dit voorbeeld illustreert een relevant kenmerk van ordinale variabelen: er is een bepaalde rangorde tussen de categorieën, maar de afstand ertussen is niet per se gelijk. Zo is de stap van “matig” naar “goed” bijvoorbeeld kwalitatief anders dan de stap van “zeer goed” naar “uitstekend”. Hierin verschilt een ordinale variabele doorgaans van een kwantitatieve variabele, bij de laatste is de afstand tussen waarden (1-2-3 etc.) in principe altijd gelijk.

Bij een ordinale variable kan het echter ook zijn dat de afstand tussen categorieën als gelijk wordt gezien. Als je bijvoorbeeld een antwoord op een stelling meet met de volgende antwoord-categorieën:

- helemaal mee oneens
- mee oneens
- niet mee oneens / niet mee eens
- mee eens
- helemaal mee eens

Dan wordt vaak aangenomen dat de afstand tussen de categorieën gelijk is. Zie verderop onder het kopje Section 5.3 meer uitleg hierover.

5.2 Kwantitatieve variabelen

Kwantitatieve variabelen zijn numeriek en bestaan dus uit cijfers. De afstand tussen waarden is altijd gelijk en er zit een rangorde in. Bijvoorbeeld bij een rapportcijfer van 1 t/m 10 is de afstand tussen 2 en 3 hetzelfde als de afstand tussen 7 en 8. Kwantitatieve variabelen worden soms ook wel lineaire of continue variabelen genoemd.

5.2.1 Interval en ratio variabelen

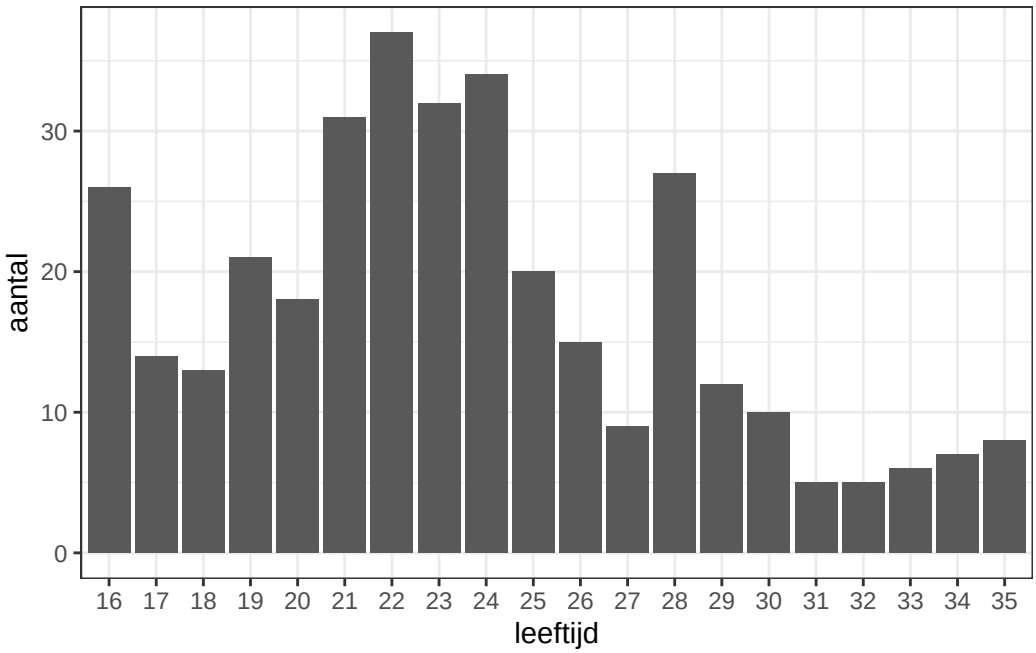
Er zijn twee types kwantitatieve variabelen: **interval** en **ratio**. Het verschil tussen deze twee types is dat een interval variabele geen *absoluut nulpunt* kent en een ratio variabele wel. Een absoluut nulpunt is wanneer de laagste waarde van een variabele nul is en het niet mogelijk is dat er een nog logische waarde daaronder bestaat.

Leeftijd is bijvoorbeeld een ratio variabele, je kunt namelijk niet jonger dan 0 jaar zijn. Geboortejaar, aan de andere kant, is weer een interval variabele. De christelijke jaartelling begint bij het jaar 0, maar dat is eigenlijk arbitrair omdat de jaren daarvoor ook geteld worden. Het specifieke karakter van de variabele bepaalt dus het meetniveau.

Om nog een ander voorbeeld te geven: inkomen is een ratio variabele. Inkomen wordt in euro's gemeten, maar kan niet negatief zijn. Aan de andere kant, als je banksaldo als variabele zou nemen, kan dit weer wel negatief zijn (als je in de min staat). Dat is dus een interval variabele.

Voor een lineaire variabele met relatief weinig unieke waarden gebruiken we meestal een staafdiagram. Zie hieronder een voorbeeld van de variabele leeftijd.

```
# staafdiagram van leeftijd
ggplot(data_uitgaan, aes(x = as.factor(leeftijd))) +
  geom_bar() +
  theme_bw() +
  ylab("aantal") +
  xlab ("leeftijd")
```

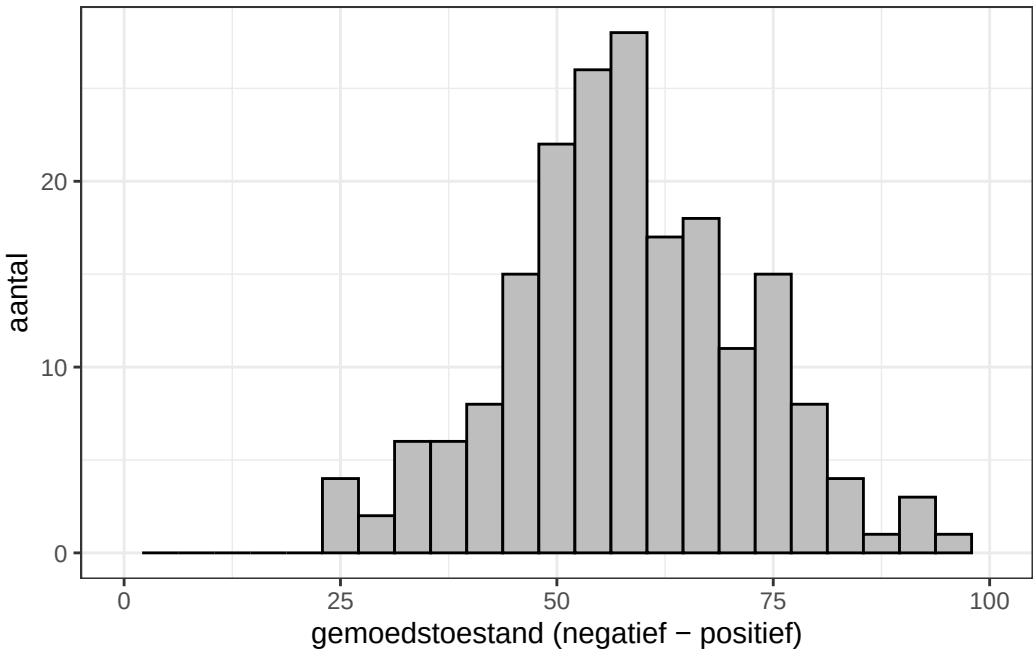


De staafdiagram toont dat relatief veel respondenten tussen 21 en 24 jaar zijn, een leeftijd waarop jongeren veel uitgaan.

5.2.2 Histogram

Voor een lineaire variabele met juist relatief veel unieke waarden gebruiken we meestal een histogram. Bij een een histogram worden bepaalde waardes gegroepeerd tot één staaf, waardoor de presentatie overzichtelijk blijft. Dit is hieronder weergeven voor de variabele `gemoed_dinsdag_na_xtc`. Dit is een score tussen de 0 en 100 die respondenten hebben gegeven over hoe ze zich voelen op de dinsdag na xtc-gebruik in het weekend, waarbij 0 voor negatief staat en 100 voor positief.

```
# histogram van gemoedstoestand op dinsdag na XTC gebruik
ggplot(data_uitgaan, aes(x = gemoed_dinsdag_na_xtc)) +
  geom_histogram(bins = 25, fill = "grey", colour = "black") +
  theme_bw() +
  ylab("aantal") +
  xlab ("gemoedstoestand (negatief - positief)") +
  xlim(0, 100)
```



5.3 Meetniveau bepalen

Het kan soms lastig zijn om het meetniveau te bepalen als je hier nog weinig ervaring mee hebt. Het belangrijkste is altijd om goed te blijven nadenken over de criteria die een meetniveau bepalen en hoe die van toepassing zijn op een variabele. Daarbij kun je jezelf steeds vragen stellen als:

- Bestaat deze variabele uit cijfers (numeriek/kwantitatief) of kwalitatieve categorieën?
- Is er een rangorde of hiërarchie tussen de categorieën? En in hoeverre is er een gelijke afstand tussen de waarden (1-2-3 … of, slecht - matig - goed)?
- Heeft de variabele een absoluut nulpunt?

Belangrijk om te onthouden is dat veel variabelen geen inherent meetniveau hebben. Het hangt af van de keuzes van de onderzoeker. Dat wil zeggen dat *hoe* ze worden gemeten leidend is voor welk meetniveau een variabele heeft.

Leeftijd kun je bijvoorbeeld meten door respondenten hun leeftijd als cijfer te laten invullen bij de vragenlijst (bijvoorbeeld 18, 24 of 33). Dan krijg je een ratio variabele. Je kunt als antwoordopties in een vragenlijst echter ook leeftijdscategorieën geven: 1) 16-20 jaar 2) 21-25 jaar 3) 26-30 jaar, etc. In dat geval meet je leeftijd als een ordinale variabele, omdat de deze nu uit categorieën bestaat met een rangorde waarvan de afstand tussen categorieën gelijk is.

Om het nog wat ingewikkelder te maken: je kunt variabelen ook aanpassen in R waardoor het meetniveau verandert. Dit kan middels hercoderen, iets waarmee je verder gaat oefenen in deze cursus.

Om dat met een kort voorbeeld te illustreren. Hieronder staan de eerste zes observaties op de variabele leeftijd.

```
# inspecteren eerste observaties leeftijd
head(data_uitgaan$leeftijd)
```

```
[1] 22 23 18 28 19 18
```

Je kunt zien dat de eerste respondent 22 jaar is, de tweede 23 jaar, de derde 18 jaar, etc. Leeftijd is hier gemeten als kwantitatieve variabele.

Nu hercoderen we deze leeftijden naar categorieën zoals hierboven aangegeven.

```
# hercoderen variabele leeftijd (van numeriek naar categorieën)
data_uitgaan$leeftijd_cat <- recode_values(data_uitgaan$leeftijd,
                                    16:20 ~ "16-20 jaar",
                                    21:25 ~ "21-25 jaar",
                                    26:30 ~ "26-30 jaar",
                                    31:35 ~ "31-35 jaar")

# nieuwe variabele leeftijd_cat inspecteren
head(data_uitgaan$leeftijd_cat)
```

```
[1] "21-25 jaar" "21-25 jaar" "16-20 jaar" "26-30 jaar" "16-20 jaar"
[6] "16-20 jaar"
```

Je ziet dat elke respondent nu in een categorie valt die hoort bij zijn of haar leeftijd. De eerste respondent valt bijvoorbeeld in de categorie '21-25 jaar' en de derde in categorie '16-20 jaar'. We hebben zojuist van een ratio variabele een ordinale variabele gemaakt!

Let op dat de transformatie andersom niet mogelijk is: je kunt niet zomaar van een ordinale variabele een kwantitatieve variabele maken. Van respondenten in de categorie '16-20 jaar' weet je bijvoorbeeld niet hun exacte leeftijd op basis van de informatie van deze variabele.

Ten slotte zul je onderzoek vaker **dichotome** (ook wel: binaire) **variabelen** tegenkomen. Dit is een variabele die uitsluitend uit twee antwoordmogelijkheden of waarden bestaat. Dit kunnen in principe zowel nominale als ordinale variabelen zijn. Bijvoorbeeld:

- Nominaal: alcohol gedronken laatste jaar (ja/nee)

- Ordinaal: leeftijd gemeten in twee categorieën (jonger dan 18 jaar/18 jaar of ouder)

In sommige gevallen worden de antwoordcategorieën van dichotome variabelen ook als 0/1 weergeven, waardoor het in principe numerieke waarden worden maar kwalitatieve variabelen blijven. Dit is handig om mee te rekenen, bijvoorbeeld als je het aandeel respondenten wil berekenen dat alcohol heeft gedronken het laatste jaar ('0' voor nee en '1' voor ja). Hier komen we in de practica op terug.

5.4 Samenvatting

Het meetniveau gaat over het type variabele en wat voor soort informatie deze bevat. Zoals we later zullen zien, is dit belangrijk om te weten wat voor soort statistische toets we kunnen uitvoeren. We onderscheiden de volgende meetniveaus (tussenhaakjes staat welke figuur we meestal gebruiken):

- nominaal (staaf- of taartdiagram)
- ordinaal (staafdiagram)
- interval (staafdiagram of histogram)
- ratio (staafdiagram of histogram)

6 Centrum- en spreiding

Inmiddels zijn we bekend met datasets, observaties, variabelen, meetniveaus en figuren. We hebben ook benoemd dat statistiek draait om het analyseren van *variatie* met behulp van de variabelen die in onze dataset zitten. Denk aan: variatie in drugsgebruik, uitgaansgedrag, leeftijden en opleidingsniveau. Om de variatie te analyseren maken we gebruik van diverse centrum- en spreidingsmaten. De meeste hiervan zul je herkennen van eerdere wiskundelessen die je hebt gehad.

6.1 Centrummaten

6.1.1 Gemiddelde

Het gemiddelde $\bar{x}$ berekenen we simpelweg door voor de variabele x alle observaties bij elkaar op te tellen $\sum_{i=1}^{n} x_i$ en dan te delen door het aantal observaties n. Dit gaat middels de volgende formule.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Formules berekenen en statistische toetsen uitvoeren kunnen we ook handmatig in R doen. Dit is leerzaam, omdat het intuïtie creëert voor hoe je statistisch onderzoek moet uitvoeren.

Stel we nemen vijf respondenten uit de dataset en bekijken hun leeftijd. We vinden de volgende observaties voor leeftijd: 16, 22, 22, 28 en 33.

Hieronder berekenen we in R de gemiddelde leeftijd van deze vijf respondenten.

```
# handmatig gemiddelde berekenen
(16 + 22 + 22 + 28 + 33) / 5
```

```
[1] 24.2
```

De gemiddelde leeftijd van deze vijf respondenten is is dus 24,2. In plaats een handmatige berekening kun je het ook berekenen middels de functie `mean()` in R:

```r
# vector aanmaken
x <- c(16, 22, 22, 28, 33)
print(x)
```

```
[1] 16 22 22 28 33
```

```r
# gemiddelde berekenen
mean(x)
```

```
[1] 24.2
```

Eerst hebben we een vector, of eigenlijk een variabele, aangemaakt met de vijf observaties. Via de functie `mean()` bereken je vervolgens het gemiddelde.

6.1.2 Mediaan

De mediaan is het getal waar het midden van het aantal observaties is bereikt (50%), oftewel de middelste observatie.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar.

Bij een even aantal cijfers zoals (16, 22, 22, 25, 28, 33) neem je het midden van de middelste twee getallen. In dit geval is dat 23,5 (tussen 22 en 25 jaar).

In R bereken je de mediaan via de functie *median().*

```r
# oneven aantal observaties
median(x)
```

```
[1] 22
```

```r
# even aantal observaties
y <- c(16, 22, 22, 25, 28, 33)
print(y)
```

```
[1] 16 22 22 25 28 33
```

```r
median(y)
```

```
[1] 23.5
```

6.1.3 Modus

De modus is de waarde die het vaakst voorkomt in een variabele.

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is dit 22 jaar omdat deze leeftijd tweemaal voorkomt en de rest slechts één keer.

In R bereken je de modus via de functie `mfv()`.

```
# modus berekenen
mfv(x)
```

```
[1] 22
```

6.2 Spreidingsmaten

Zoals eerder aangegeven, draait statistiek voor een belangrijk deel om de analyse van variatie. We hebben een groep respondenten die over allerlei kenmerken beschikken. We kunnen tellen welke kenmerken het meest voorkomen, of wat het gemiddelde op een bepaald kenmerk is. Maar vaak zijn we als sociale wetenschappers niet zozeer geinteresseerd in dingen die algemeen zijn, maar juist in zaken die variëren. Welke groepen gebruiken welke vormen van drugs? Welke groepen gebruiken juist geen drugs? Het idee is dat variatie, bijvoorbeeld door het maken van vergelijkingen, ons iets kan leren over hoe de sociale werkelijkheid in elkaar zit.[1] Dat geeft ons bijvoorbeeld inzicht in welke theorie bruikbaar is om een bepaald fenomeen beter te begrijpen c.q. verklaren of om beleid te ontwikkelen dat specifiek gericht is op een bepaalde doelgroep.

6.2.1 Bereik, minimum en maximum

Het bereik R van een variabele is de afstand tussen de laagste (minimum: x_{min}) en hoogste (maximum: x_{max}) waarde. Dit bereken je eenvoudig door de hoogste waarde minus de laagste waarde te nemen:

$$R = x_{max} - x_{min}$$

Bij de leeftijdsreeks (16, 22, 22, 28, 33) is het minimum 16 en het maximum 33. Het bereik is dus $R = x_{max} - x_{min} = 33 - 16 = 17$

[1] Sterker nog, onze methodes verklaren variat(n)ie met varia(n)tie. Als er geen variatie in een bepaald kenmerk is, kan het kenmerk ook niet als verklaring verschijnen. Of stel dat onze dataset alleen variatie meet op het niveau van individuen, dan gaan onze verklaringen ook te maken met individuele aspecten. Zie bijvoorbeeld het boek van John Levi Martin.

```
# handmatig bereik berekenen
33 - 16
```

```
[1] 17
```

Je kunt in R het minimum en maximum opvragen met de functies `min()` en `max()`. Ook kun je allebei tegelijk krijgen met de functie `range()`.

```
# minimum opvragen
min(x)
```

```
[1] 16
```

```
# maximum opvragen
max(x)
```

```
[1] 33
```

```
# minimum en maximum opvragen
range(x)
```

```
[1] 16 33
```

De functie `range()` geeft je alleen het minimum en maximum. Als je het bereik wilt weten, moet je zelf het minimum van het maximum aftrekken:

```
# bereik berekenen
max(x) - min(x)
```

```
[1] 17
```

6.2.2 Variantie

De variantie is een maat voor de spreiding van een variabele die aangeeft hoeveel de waardes onderling van elkaar verschillen. In de statistiek van de sociale wetenschappen zijn er twee soorten variantie: de populatievariantie en steekproefvariantie. Hier komen we later op terug, we rekenen nu voorlopig verder met de steekproefvariantie. De formule daarvoor is:

$$S^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}$$

De steekproefvariantie S^2 kun je bereken in een aantal stappen.

Dit doen we aan de hand van de leeftijdsreeks (16, 22, 22, 28, 33) en het gemiddelde hiervan $\bar{x}$ = 24,2

Eerst berekenen we voor elke observatie de afstand tot het gemiddelde (de deviatie):

x_i	$x_i - \bar{x}$
16	16 - 24,2 = -8,2
22	22 - 24,2 = -2,2
22	22 - 24,2 = -2,2
28	28 - 24,2 = 3,8
33	33 - 24,2 = 8,8

De optelsom van alle deviaties moet altijd nul zijn: -8,2 + -2,2 + -2,2 + 3,8 + 8,8 = 0

In de volgende stap kwadrateren we alle deviaties:

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
16	16 - 24,2 = -8,2	$(-8,2)^2 = 67,24$
22	22 - 24,2 = -2,2	$(-2,2)^2 = 4,84$
22	22 - 24,2 = -2,2	$(-2,2)^2 = 4,84$
28	28 - 24,2 = 3,8	$3,8^2 = 14,44$
33	33 - 24,2 = 8,8	$8,8^2 = 77,44$

Daarvan nemen we de som der kwadraten $\sum_{i=1}^{n} (x_i - \bar{x})^2$: 67,24 + 4,84 + 4,84 + 14,44 + 77,44 = 168,8

In de laatste stap delen we de som der kwadraten door het aantal observaties minus één $(n-1)$:

168,8 / (5-1) = 42,2

De steekproefvariantie van de leeftijd van vijf respondenten is dus 42,2.

Deze stappen kunnen we ook in R uitvoeren.

```
# deviatie voor elke leeftijd
x_deviatie <- x - mean(x) # voor elke waarde van x minus het gemiddelde
print(x_deviatie)
```

```
[1] -8.2 -2.2 -2.2  3.8  8.8
```

```
# kwadrateren van deviaties
x_deviatie_kwa <- x_deviatie^2 # voor elke deviatie het kwadraat nemen
print(x_deviatie_kwa)
```

```
[1] 67.24  4.84  4.84 14.44 77.44
```

```
# som der kwadraten
sum(x_deviatie_kwa) # sum() neemt de som van een vector
```

```
[1] 168.8
```

```
# steekproefvariantie berekenen
variantie_stkpr <- sum(x_deviatie_kwa) / (length(x) - 1) # length() berekent het aantal rije
print(variantie_stkpr)
```

```
[1] 42.2
```

In R kun je met de functie `var()` de steekproefvariantie ook direct berekenen

```
# steekproefvariantie
var(x)
```

```
[1] 42.2
```

6.2.3 Standaarddeviatie

De variantie is een handig getal om mee te rekenen, maar heeft meestal op zichzelf niet zoveel betekenis. Daarom wordt in onderzoek gebruik gemaakt van de standaarddeviatie (ook wel standaardafwijking genoemd). In combinatie met het gemiddelde en het bereik, geeft de standaarddeviatie meestal een redelijke indicatie van de spreiding van een lineaire variabele (hier komen we later weer op terug). Hoewel wiskundig niet helemaal correct, wordt de standaarddeviatie ook wel gezien als 'de gemiddelde afstand tot het gemiddelde'.

De standaarddeviatie is de wortel van de steekproefvariantie:

$$s = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}}$$

De standaarddeviatie van ons voorbeeld met de leeftijd van vijf respondenten is:

$s = \sqrt{42,2} = 6,50$

Je zou dus kunnen zeggen dat een willekeurige persoon van de vijf respondenten 'gemiddeld' 6,5 jaar afwijkt van de gemiddelde leeftijd van 24,2 jaar.

```
# standaarddeviatie berekenen
sqrt(variantie_stkpr) # sqrt() berekent de wortel over een getal/vector
```

```
[1] 6.496153
```

Je kunt de standaarddeviatie ook direct in R krijgen met `sd()`

```
# standaarddeviatie
sd(x)
```

```
[1] 6.496153
```

6.3 Toepassing op de dataset

We hebben hierboven middels een eenvoudig voorbeeld laten zien hoe de centrum- en spreidingsmaten berekend worden. In onderzoek willen we deze informatie voor variabelen in de hele dataset weten, zodat we snel kunnen zien hoe onze data in elkaar zit.

We vragen hier het gemiddelde, de mediaan en de modus op voor leeftijd in de complete dataset.

```r
# centrummaten opvragen
mean(data_uitgaan$leeftijd) # gemiddelde
```

```
[1] 23.52
```

```r
median(data_uitgaan$leeftijd) # mediaan
```

```
[1] 23
```

```r
mfv(data_uitgaan$leeftijd) # modus
```

```
[1] 22
```

De gemiddelde leeftijd is 23,5 jaar, de mediaan is 23 jaar en de modus is 22 jaar. Deze waarden liggen dus dicht bij elkaar.

We kunnen ook het minimum, maximum, bereik en de standaarddeviatie berekenen.

```r
# spreidingsmaten opvragen
range(data_uitgaan$leeftijd) # minimum en maximum
```

```
[1] 16 35
```

```r
max(data_uitgaan$leeftijd) - min(data_uitgaan$leeftijd) # bereik
```

```
[1] 19
```

```r
sd(data_uitgaan$leeftijd) #standaarddeviatie
```

```
[1] 4.782178
```

De minimumleeftijd is 16 jaar, de maximumleeftijd is 35 jaar en het leeftijdsbereik is 19 jaar. De standaarddeviatie is 4,8 jaar.

Veel van deze statistieken (min., max., mediaan, gemiddelde) kun je ook in één keer bekijken middels de functie `summary()`

```r
# meerdere statistieken tegelijkertijd opvragen
summary(data_uitgaan$leeftijd)
```

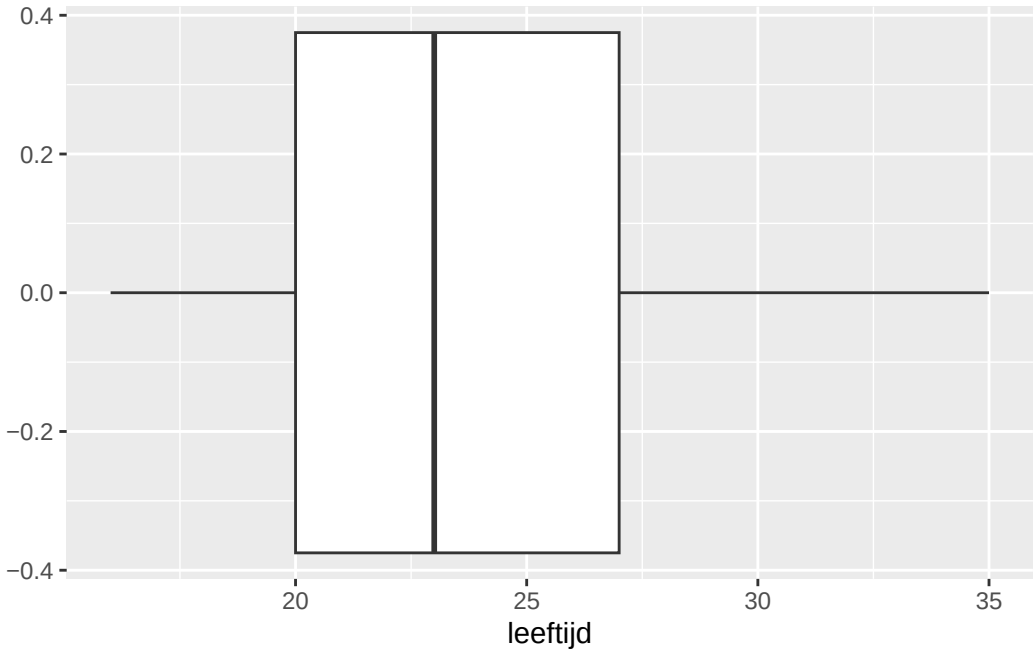
```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  16.00   20.00   23.00   23.52   27.00   35.00
```

Je ziet dat de `summary()` functie ook de waardes voor 1st Qu. en 3rd Qu. geeft. Dit zijn het eerste en derde kwartiel, de grenzen waarbij respectievelijk 25% (Q1) en 75% (Q3) van de data ligt. In dit geval dus 20,0 en 27,0 jaar. Het tweede kwartiel (Q2) is de mediaan, dit is op de grens van 50% van de data.

6.3.1 Doosdiagram

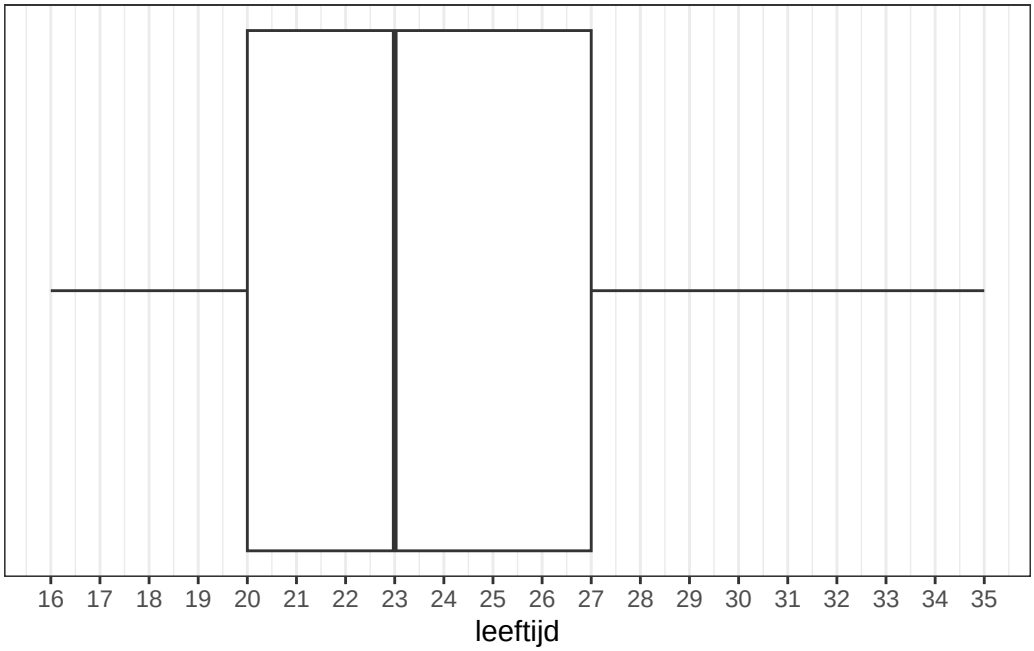
Er bestaat ook een manier om de spreiding van een lineaire variabele te visualiseren. Dit is via een **doosdiagram**.

```r
# doosdiagram maken
ggplot(data_uitgaan, aes(x = leeftijd)) +
  geom_boxplot() # doosdiagram
```



Zoals we inmiddels hebben gezien, kan de presentatie van de figuur kan nog verbeterd worden.

```r
# doosdiagram maken
ggplot(data_uitgaan, aes(x = leeftijd)) +
  geom_boxplot() + # doosdiagram
  theme_bw() +
  scale_x_continuous(breaks = seq(16, 35, by = 1)) + # aanpassen labels x-as, van 16 tot 35 r
  scale_y_continuous(breaks = NULL) # verwijderen labels y-as (hebben geen betekenis hier)
```



Een doosdiagram weergeeft de spreiding van een variabele en bevat het minimum en maximum, en de grenzen van het 1ste kwartiel (Q1), mediaan (Q2) en 3de kwartiel (Q3). De afstand tussen het 1ste en 3de kwartiel wordt ook wel de **interkwartielafstand** genoemd.

Je kunt aan bovenstaande figuur bijvoorbeeld zien dat alle waarden tussen het 1ste kwartiel en mediaan tussen de 20 en 23 jaar liggen. Het hoogste kwartiel (Q4) omvat relatief veel leeftijden, van 27 tot 35 jaar.

Vergelijk deze doosdiagram met de staafdiagram van leeftijd (Staafdiagram leeftijd). Je ziet dat er verschillende manieren zijn om data te visualiseren.

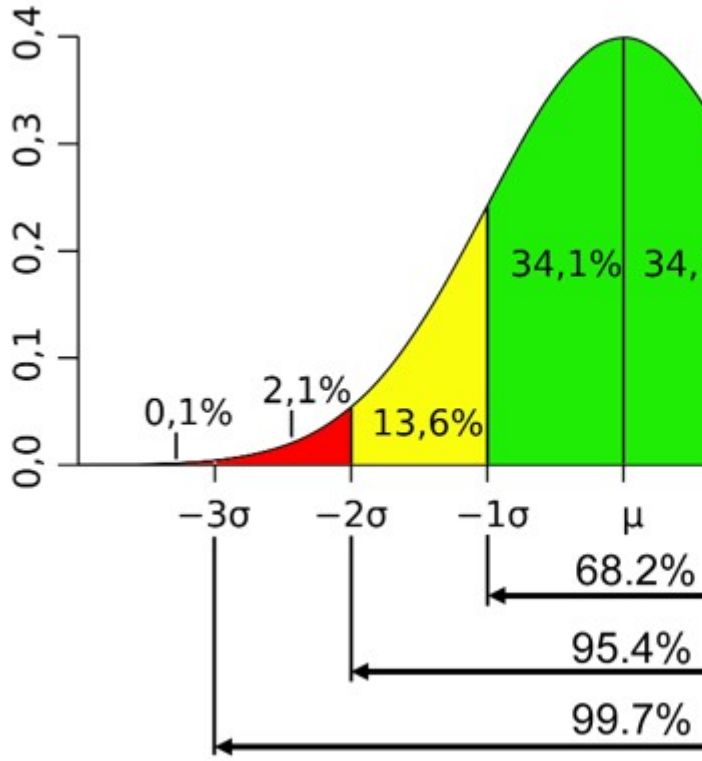
6.4 Normale verdeling

We hebben diverse centrum- en spreidingsmaten besproken. Deze kunnen we gebruiken om de verdeling van een variabele te visualiseren, afhankelijk van het meetniveau van de variabele

(zie ook Meetniveaus en visualisaties). Een van de meest bekende verdelingen in de statistiek is de **normale verdeling** (of normaalverdeling). Deze wordt gebruikt om verdeling van kwantitatieve variabelen te beschrijven, denk bijvoorbeeld aan lengte of IQ.

De normale verdeling heeft een aantal kenmerken:

- De verdeling bestaat uit een gemiddelde $\bar{x}$ en standaarddeviatie s
- Het gemiddelde en de mediaan zijn in principe gelijk aan elkaar. Dit betekent dat de verdeling symmetrisch is (50% van de observaties bevindt zich links van het gemiddelde, en 50% rechts)



Hieronder staat een afbeelding van de normale verdeling.

De notatie in deze afbeelding is iets anders dan je tot nu toe gewend bent. Het gemiddelde wordt aangegeven met μ (spreek je uit als: mu) en de standaardafwijking met σ (spreek je uit als: sigma). Deze symbolen zijn eigenlijk hetzelfde als $\bar{x}$ en s , alleen gebruiken we μ en σ om eigenschappen van de populatie te beschrijven terwijl $\bar{x}$ en s gelden voor de steekproef (zie ook Formuleblad). Dit verschil komt terug bij Inferentiële statistiek. Voor nu kun je er even van uitgaan dat ze hetzelfde betekenen.

De normaalverdeling noemen we ook wel een *kans*verdeling, omdat (onder bepaalde assumpties) een bepaald oppervlak onder de grafiek correspondeert met de kans op een waarde of uitkomst.

Zo kun in de afbeelding bijvoorbeeld zien dat tussen één standaarddeviatie onder het gemiddelde (-1σ) en één standaarddeviatie boven het gemiddelde (1σ) 68,2% van alle waarden liggen. Verder geldt:

- tussen -2σ en 2σ liggen 95,4% van alle observaties
- tussen -3σ en 3σ liggen 99,7% van alle observaties

Dat een bepaald bereik op basis van standaarddeviaties correspondeert met een zeker percentage van alle observaties, staat ook wel bekend als **de empirische regel.** Je zult later bij het berekenen van een betrouwbaarheidsinterval en hypothese toetsen gaan zien waarom dit relevant is.

Het is belangrijk om op te merken dat in de praktijk variabelen zelden exact normaal verdeeld zijn, ze volgen dus niet precies de verdeling zoals hierboven weergeven. Zo kunnen kwantitatieve variabelen ook linksscheef of rechtsscheef verdeeld zijn, die daarvoor deze link.

6.5 Z-score

Om inzicht te krijgen in de relatieve positie van een bepaalde observatie ten opzichte van het gemiddelde, kunnen we ten slotte een z-score berekenen. Een z-score is een gestandaardiseerde maat die aangeeft hoeveel standaarddeviaties een waarde van het gemiddelde ligt. Daarbij geldt dat, door het standaardiseren, het gemiddelde altijd 0 is en de standaardafwijking 1. De z-score heeft de volgende formule:

$$z = \frac{x - \bar{x}}{s}$$

De berekening is vrij eenvoudig: je trekt het gemiddelde $\bar{x}$ af van de specifieke waarde x en deelt dit door de standaardafwijking s van de originele variabele.

Laten we dit illustreren aan de hand van een voorbeeld. Bij Histogram zag je de variabele gemoed_dinsdag_na_xtc, die staat voor een score tussen de 0 en 100 over hoe positief respondenten zich voelen op de dinsdag na xtc-gebruik in het weekend. We vragen eerst het gemiddelde en de standaarddeviatie op.

```
# gemiddelde en standaarddeviatie (met verwijderen missende waarden via na.rm)
mean(data_uitgaan$gemoed_dinsdag_na_xtc, na.rm = TRUE)
```

```
[1] 58.27179
```

```r
sd(data_uitgaan$gemoed_dinsdag_na_xtc, na.rm = TRUE)
```

```
[1] 14.03798
```

We nemen als voorbeeld iemand die score 30 heeft ingevuld. Dan weten we in principe alle relevante informatie en kunnen we dit invullen in de formule:

$$z = \frac{x - \bar{x}}{s} = \frac{30 - 58,3}{14,0}$$

We kunnen R gebruiken om dit uit te rekenen:

```r
(30-58.3)/14.0
```

```
[1] -2.021429
```

De persoon met score 30 bevindt dus ongeveer 2 standaarddeviaties onder het gemiddelde. Zoals de normale verdeling laat zien, is dit een vrij extreme score (slechts 2,2% van de waardes ligt nog onder 2 standaarddeviaties).[2] Deze partyprins of -prinses voelt zich dus niet zo lekker vergeleken met de rest op de dinsdag na een wild weekend!

[2] Vergelijk dit ook visueel met de verdeling van gemoed_dinsdag_na_xtc bij Histogram. Waar ligt score 30 t.o.v. de rest van de verdeling?

7 Relaties tussen variabelen

We hebben tot nu toe gekeken naar wat voor verschillende variabelen er zijn (meetniveaus), hoe we de onderliggende data kunnen visualiseren, en met welke statistische maten we deze variabelen kunnen beschrijven. In onderzoek zijn we niet alleen geïnteresseerd in variabelen zelf, maar nog meer in de **relaties** daartussen. Voor onze dataset zouden we bijvoorbeeld de volgende vragen kunnen stellen:

- Wat is het verschil tussen mannen en vrouwen in drugsgebruik?
- In hoeverre denken gebruikers anders over de acceptatie van drugs dan niet-gebruikers?
- Wat is de relatie tussen verschillende soorten drugsgebruik?

Om dergelijke vragen te beantwoorden, moeten we data van verschillende variabelen met elkaar combineren. Daarbij moeten we ons steeds afvragen hoe we deze relaties inzichtelijk willen maken. Het is goed om te realiseren dat hier niet altijd één juist antwoord voor is. Er zijn meerdere manieren om data en relaties te presenteren, waarbij de creativiteit van de onderzoeker ertoe doet. Over het algemeen zijn er wel gebaande paden die we kunnen volgen.

We letten bij het onderzoeken van relaties tussen variabelen vooral op hun meetniveau. Hebben we bijvoorbeeld te maken met twee kwalitatieve variabelen, één kwalitatief en één kwantitatief, of twee kwantitatieve variabelen? Daaruit kunnen we vaak afleiden wat de handigste manier is om een relatie te presenteren. Denk dus altijd eerst goed na wat het meetniveau van een variabele is.

7.1 Kwalitatief vs. kwalitatief

7.1.1 Nominaal vs. nominaal

Als we de relatie tussen twee nominale variabelen willen presenteren, kunnen we een eenvoudige kruistabel maken in R. We kijken in dit voorbeeld naar de relatie tussen geslacht (man/vrouw/anders) en of men heeft gevapet in het afgelopen jaar (ja/nee). We gaan er hier vanuit dat er geen rangorde bestaat tussen wel of niet vapen en het dus een nominale variabele betreft.

Bij Meetniveaus en visualisaties hebben we al een tabel gemaakt voor `geslacht`. We kunnen aan het commando `table()` een variabele `vapen_laatste_jaar` toevoegen om een kruistabel te krijgen.

```r
# kruistabel tussen geslacht en vapen laatste jaar
table(data_uitgaan$vapen_laatste_jaar, data_uitgaan$geslacht) # vapen in de rijen, # geslacht
```

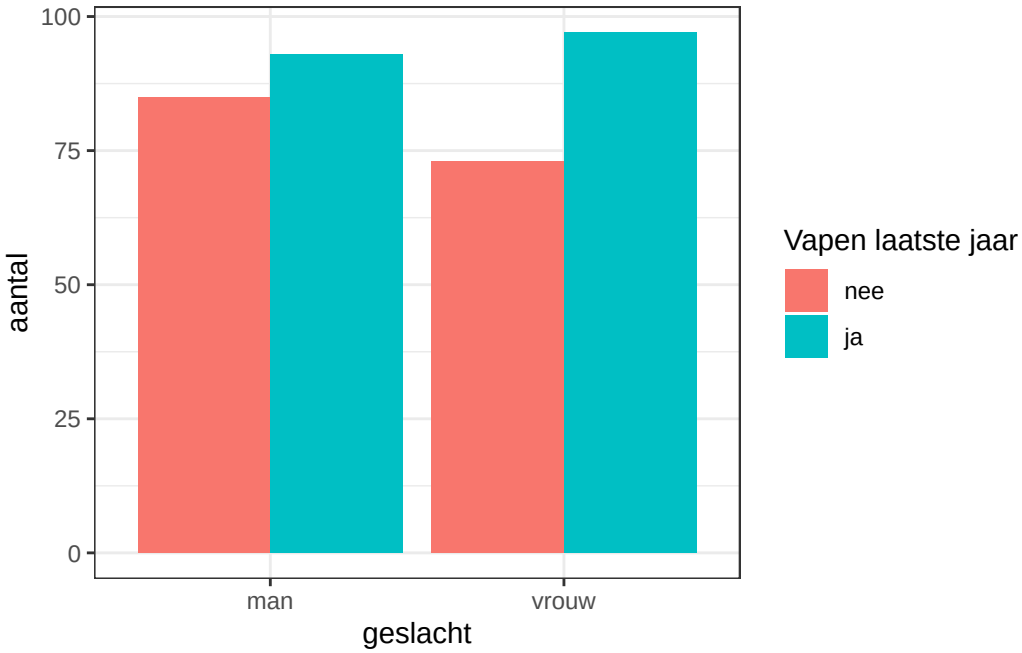
```
      man vrouw anders
  nee  85    73      0
  ja   93    97      2
```

We zien in bovenstaande tabel hoe vaak personen van een bepaald geslacht hebben gevapet het afgelopen jaar. Zo kun je zien dat 73 vrouwen niet hebben gevapet en 97 wel.

Visueel krijgen we vaak een beter inzicht in de verdeling van variabelen en de relaties daartussen. We kunnen de verdeling voor `vapen_laatste_jaar` uitgesplitst naar `geslacht` daarom apart weergeven in een figuur. De meest gangbare manier om de relatie tussen twee variabelen visueel te weergeven is een staafdiagram. We laten voor eenvoud de categorie 'anders' even buiten beschouwing hier.

```r
# samenvatten van de relevante data
geslacht_vapen <- data_uitgaan |>
  filter(geslacht != "anders") |> # categorie 'anders' eruit laten
  group_by(geslacht, vapen_laatste_jaar) |> # groeperen op variabelen
  summarise(n = n()) # aantal respondenten per categorie berekenen

# staafdiagram maken voor relatie geslacht en vapen
ggplot(geslacht_vapen, aes(x = geslacht, y = n, fill = vapen_laatste_jaar)) +
  geom_col(position = "dodge") +
  theme_bw() +
  ylab("aantal") +
  labs(fill = "Vapen laatste jaar")
```



We zien nu in een oogoopslag wat de verschillen zijn in aantallen tussen mannen en vrouwen die vapeten het laatste jaar.

De absolute aantallen geven slechts gedeeltelijk inzicht in wat verhoudingen zijn binnen de relatie tussen geslacht en vapen. Daarom is het handig ook de kolompercentages te bereken. Dit doen we door `prop.table()` toe te voegen aan de kruistabel.

```
# kolompercentages voor kruistabel
table(data_uitgaan$vapen_laatste_jaar, data_uitgaan$geslacht) |>
  prop.table(2) # 2 voor kolompercentages (1 voor rijpercentages)
```

```
           man     vrouw    anders
  nee 0.4775281 0.4294118 0.0000000
  ja  0.5224719 0.5705882 1.0000000
```

We zien nu dat 57,1% van de vrouwen heeft gevapet en 42,9% niet. Bij de mannen ligt dit percentage iets lager (52,2% vs. 47,8%). Je zou dus al (voorzichtig) kunnen concluderen dat vrouwen relatief meer vapen dan mannen.

7.1.2 Nominaal vs. ordinaal

De werkwijze bij het onderzoeken van een relatie tussen nominaal en ordinaal is in principe hetzelfde. We nemen hier de relatie tussen de volgende twee variabelen: `xtc_laatste_jaar` en `acceptatie_xtc_vrienden`. De eerste variabele meet of respondenten het laatste jaar xtc hebben gebruikt en de tweede variabele meet in hoeverre respondenten het eens zijn met de stelling dat het gebruik van xtc onder vrienden geaccepteerd is.

We bekijken eerst weer de aantallen in een kruistabel.

```
# kruistabel tussen xtc gebruik en acceptatie onder vrienden
table(data_uitgaan$acceptatie_xtc_vrienden, data_uitgaan$xtc_laatste_jaar)
```

```
                         nee  ja
  helemaal mee oneens     28   2
  mee oneens              19   4
  niet mee eens of oneens 20   4
  mee eens                65  32
  helemaal mee eens       23 153
  weet niet                0   0
```

Vervolgens kijken we naar de kolompercentages

```
# kolompercentages voor kruistabel
table(data_uitgaan$acceptatie_xtc_vrienden, data_uitgaan$xtc_laatste_jaar) |>
  prop.table(2)
```

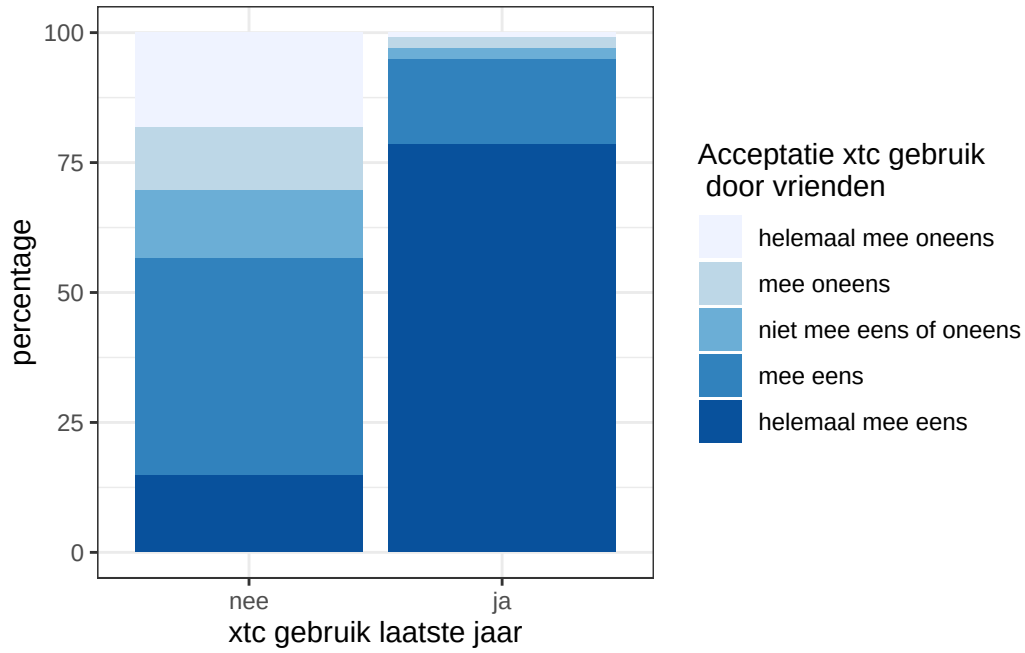
```
                                nee         ja
  helemaal mee oneens     0.18064516 0.01025641
  mee oneens              0.12258065 0.02051282
  niet mee eens of oneens 0.12903226 0.02051282
  mee eens                0.41935484 0.16410256
  helemaal mee eens       0.14838710 0.78461538
  weet niet               0.00000000 0.00000000
```

Hier tekent zich al een duidelijk patroon af: onder jongeren die xtc hebben gebruikt, is de acceptatie onder vrienden ook hoog. Bijna alle respondenten in de rechterkolom geven aan het eens (16,4%) of helemaal mee eens (78,5%) met de stelling te zijn. Bij jongeren die niet hebben gebruikt is de acceptatie wat meer verdeeld, al geeft een meerderheid aan dat het gebruik van xtc is geaccepteerd onder hun vrienden (eens: 41,9%, helemaal mee eens: 14,8%).

Als we deze relatie willen visualiseren, kunnen we het beste voor een zogenaamde gestapelde staafdiagram kiezen. Hierin worden de antwoordcategorieën op een variabele als het ware gestapeld binnen een staaf. We kunnen zo'n gestapelde staafdiagram maken voor de kolompercentages.

```
# samenvatten van de relevante data
xtc_gebruik_acceptatie <- data_uitgaan |>
  group_by(xtc_laatste_jaar, acceptatie_xtc_vrienden) |>
  summarise(n = n()) |>
  mutate(perc = round(n/sum(n) * 100, 1)) # percentages berekenen en afronden op 1 decimaal

# staafdiagram maken voor relatie geslacht en vapen
ggplot(xtc_gebruik_acceptatie,
       aes(x = xtc_laatste_jaar, y = perc,
           fill = acceptatie_xtc_vrienden)) +
  geom_col() + #
  theme_bw() +
  ylab("percentage") +
  xlab("xtc gebruik laatste jaar") +
  labs(fill = "Acceptatie xtc gebruik \n door vrienden ") +
  scale_fill_brewer(palette = 1)  # kleur bepalen van licht naar donkerblauw
```



Wederom krijgen we direct een indruk van de relatie tussen deze twee variabelen. Acceptie van

xtc gebruik is over het algemeen hoog onder vrienden, maar relatief veel meer bij vrienden van jongeren die zelf xtc gebruiken.

Kruistabellen en (gestapelde) staafdiagrammen zijn ook goed toepasbaar voor het onderzoeken van de relatie tussen twee ordinale variabelen (dit behandelen we niet verder hier). Alleen als je variabelen heel veel categorieën hebben, moet je wellicht nadenken over een alternatief.

7.2 Kwalitatief vs. kwantitatief

We beschikken over verschillende opties wanneer we de relatie tussen een kwalitatieve en kwantitatieve variabele willen onderzoeken. De meest eenvoudige optie is om naar het verschil in gemiddeldes te kijken. Als voorbeeld kijken we hier naar geslacht en het aantal sigaretten dat men rookt tijdens het uitgaan (`sigaretten_uitgaansdag`). Let op dat het hier alleen gaat over jongeren die minimaal één sigaret roken tijdens het uitgaan (rokers).

We berekenen het gemiddelde door de data eerst te groeperen en daarna het gemiddelde per groep te berekenen. Hoe je dat moet doen, leer je in het practicum.

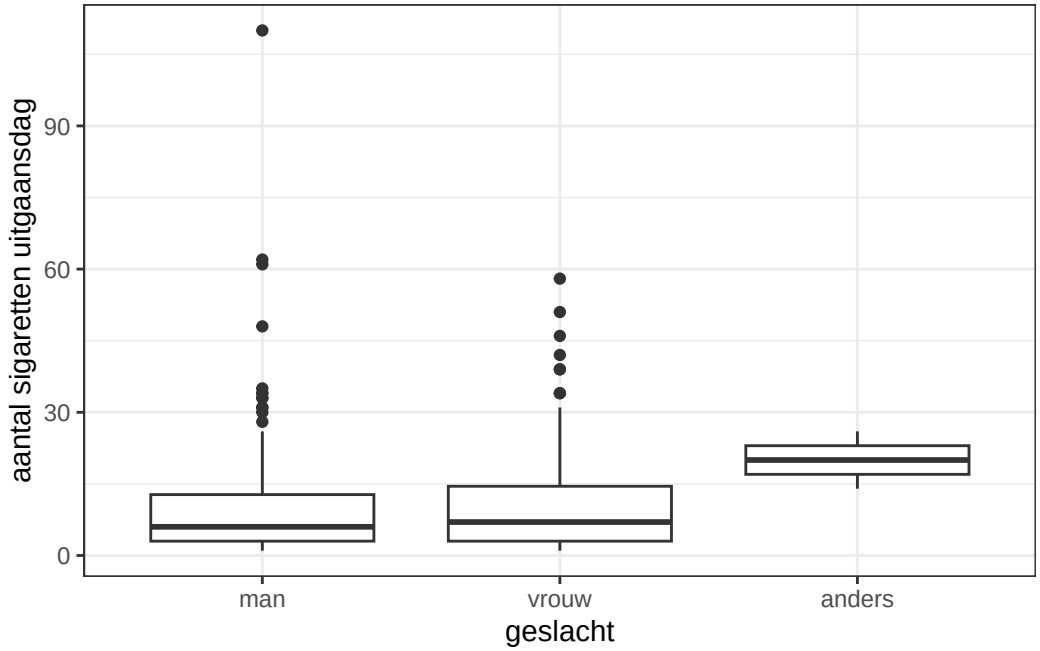
```
# gemiddelde berekenen van aantal sigaretten voor geslacht
data_uitgaan |> group_by(geslacht) |>
  filter(!is.na(sigaretten_uitgaansdag)) |> # respondenten die niet roken eruit laten
  summarise(gem_sigaretten = mean(sigaretten_uitgaansdag)) # summarise() en mean() voor gemi
```

```
# A tibble: 3 x 2
  geslacht gem_sigaretten
  <fct>             <dbl>
1 man                11.1
2 vrouw              11.2
3 anders             20
```

Je ziet dat zowel mannen als vrouwen gemiddeld zo'n 11 sigaretten per uitgaansdag roken. Er is dus niet echt een verschil tussen deze groepen. Bij de anders-identificerenden ligt dit aantal hoger (20), maar dit is een kleine groep wat betekent dat het meer afhankelijk is van wie er toevallig in de dataset zit.

Het verschil in gemiddeldes geeft nog niet zoveel inzicht in de distributie van verschillende groepen. Het kan zijn dat er onderling variatie is in het rookgedrag tussen mannen en vrouwen. Je kunt een doosdiagram voor beide groepen maken om hier meer inzicht in te krijgen.

```r
# doosdiagram met aantal sigaretten naar geslacht
ggplot(data_uitgaan, aes(x = geslacht, y = sigaretten_uitgaansdag)) +
  geom_boxplot() +
  theme_bw() +
  ylab("aantal sigaretten uitgaansdag")
```



Deze doosdiagrammen zien er wat anders uit dan in hoofdstuk xxx, omdat we hier met meer extreme waarden te maken hebben. Zo geeft de bovenste punt bij de mannen aan dat één respondent meer dan 100 sigaretten heeft gerookt. Gelet op de spreiding, is de afstand tussen Q1, Q2 en Q3 wat groter bij vrouwen dan mannen. Het lijkt er dus op dat bij de mannen meer extreme waarden voorkomen, terwijl bij de vrouwen er in het midden van de verdeling (interkwartielafstand) wat meer spreiding is.

Ook hier geldt weer: het onderzoeken van een beschrijvende relatie tussen ordinaal vs. kwantitatief kan doorgaans op dezelfde wijze als bij nominaal vs. kwantitatief.

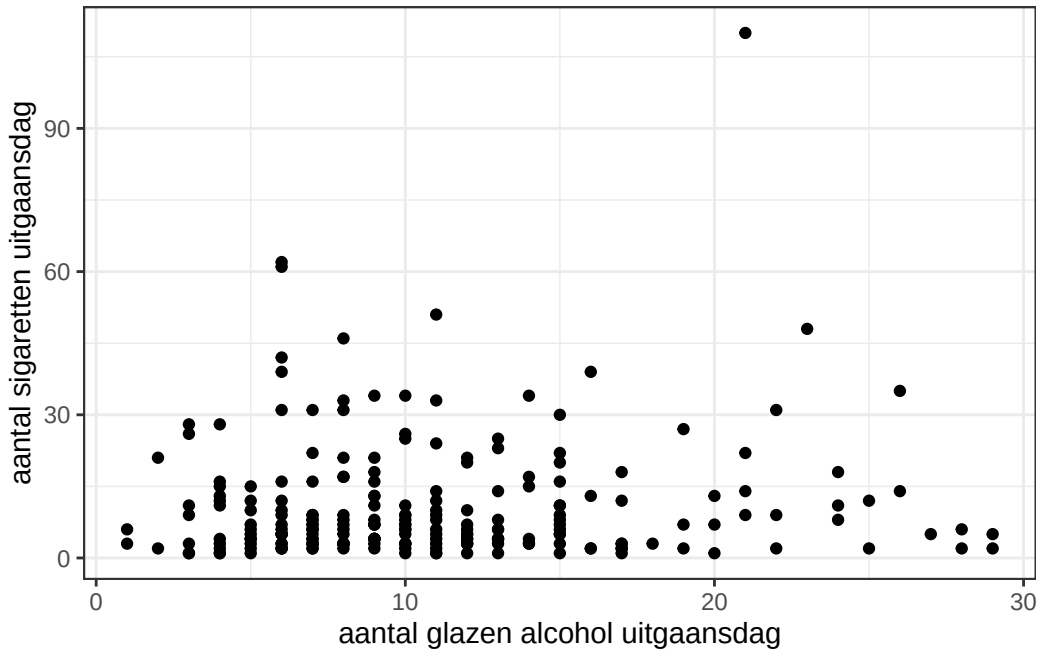
7.3 Kwantitatief vs. kwantitatief

Als laatste onderzoeken we de relatie tussen twee kwantitatieve variabelen. Het makkelijkst is om deze relatie direct te visualiseren (later in de cursus kijken we naar correlatie, een associatiemaat voor de sterkte van de relatie). We nemen de relatie tussen het aantal glazen alcohol op een uitgaansdag (`glazen_alcohol_uitgaansdag`) en het aantal gerookte sigaretten.

Het gaat hier om jongeren die dus zowel alcohol drinken als roken tijdens het uitgaan. Verder zijn dit twee ratio variabelen (bedenk waarom).

Om de relatie te visualiseren, maken we eerst gebruik van een spreidingsdiagram.

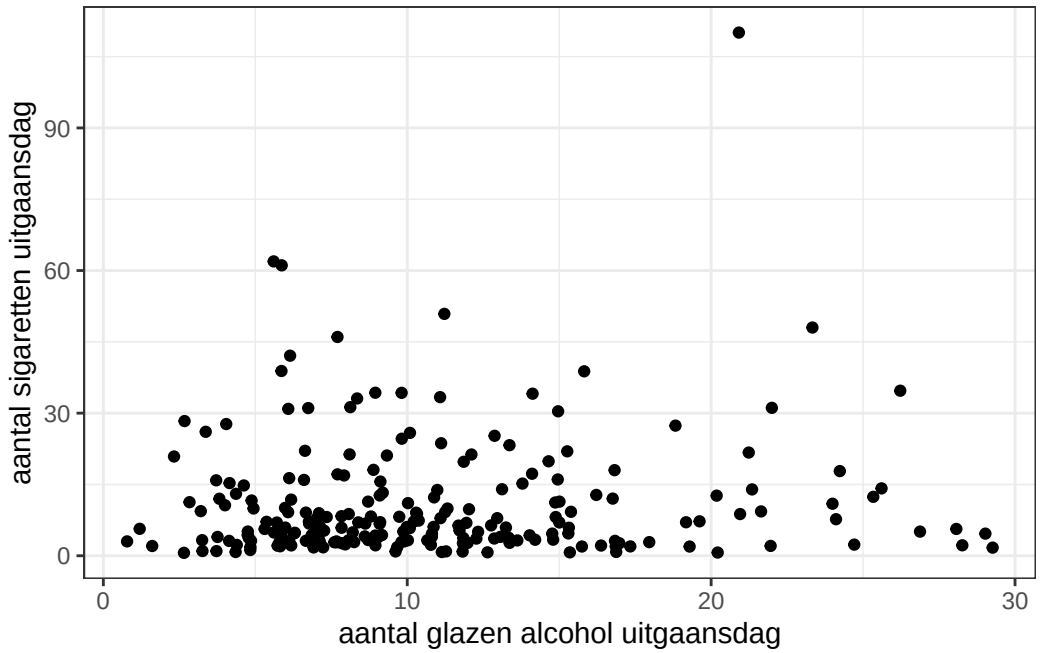
```
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point() +
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag")
```



Elke punt vertegenwoordigt een respondent in deze diagram, die laat zien hoe ze scoren op aantal glazen alcohol (x-as) en aantal sigaretten (y-as) tijdens het uitgaan. Er komt hier nog niet een heel duidelijk patroon uit naar voren. Zowel bij jongeren die relatief weinig drinken (10< glazen) zijn er wat uitschieters naar boven qua roken (>30 sigaretten), maar ook bij jongeren die relatief veel drinken. De dichste concentratie van punten zit linksonder, wat betekent dat de meeste respondenten rond de 5-15 glazen alcohol drinken en 1-15 sigaretten roken.

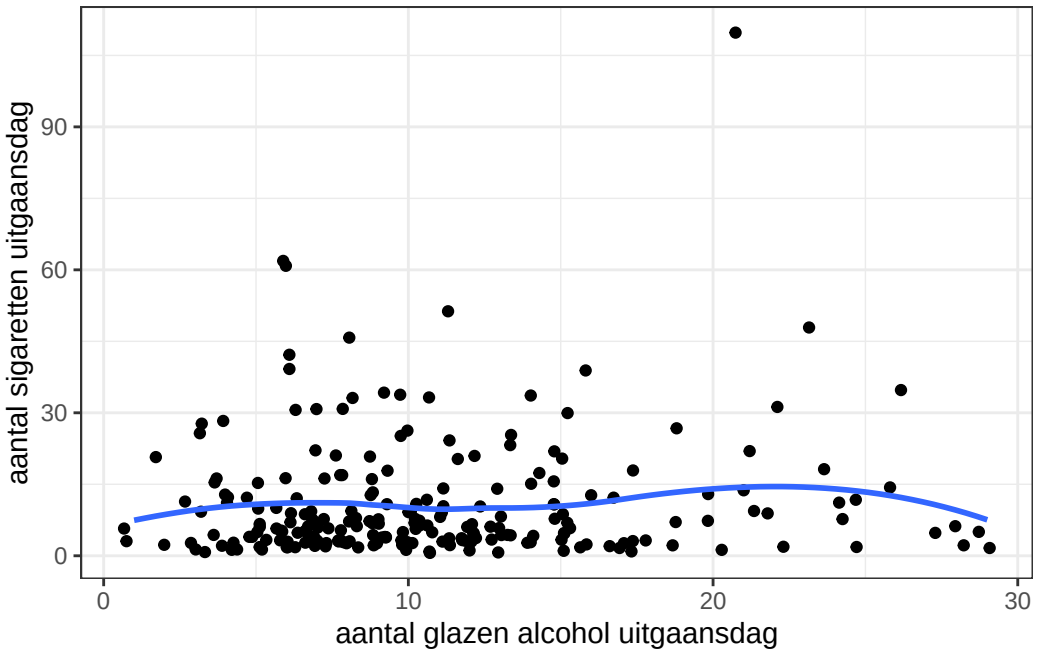
We kunnen de spreidingsdiagram nog wat aanpassen om beter inzicht te krijgen in de relatie. Sommige punten zijn nu niet goed te zien omdat ze dicht op elkaar zitten. Met de optie `"jitter"` wordt de puntenwolk wat meer uitgespreid.

```r
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point(position = "jitter") + # jitter toevoegen
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag")
```



Je ziet nu iets beter waar de concentratie van datapunten zit. Verder kun je kijken in hoeverre er een (lineair) verband is tussen aantal glazen alcohol en aantal sigaretten. Je kunt een zogenoemde regressielijn 'fitten' op de data met `stat_smooth()`.

```r
# spreidingsdiagram met aantal glazen alcohol en sigaretten
ggplot(data_uitgaan, aes(x = glazen_alcohol_uitgaansdag, y = sigaretten_uitgaansdag)) +
  geom_point(position = "jitter") +
  theme_bw() +
  xlab("aantal glazen alcohol uitgaansdag") +
  ylab("aantal sigaretten uitgaansdag") +
  stat_smooth(method = loess, se = FALSE)
```



De lijn toont dat er geen duidelijk verband is tussen aantal glazen alcohol en aantal sigaretten. Over het algemeen blijft deze vrij vlak en gaat niet duidelijk één richting op.

7.4 Tot slot

Dit hoofdstuk heeft geïllustreerd hoe je relaties tussen variabelen kan beschrijven, zowel door tabellen en visualisaties. Daarbij is het belangrijk om het meetniveau van beide variabelen te weten. Besteed ook aandacht aan de interpretatie: waaraan kun je aflezen hoe een bepaalde relatie in elkaar zit? Daarvan zijn enkele voorbeelden gegeven. Zo weet je na dit hoofdstuk bijvoorbeeld:

- Dat vrouwen iets vaker vapen dan mannen
- Acceptatie van xtc onder vrienden hoger is onder gebruikers dan niet-gebruikers
- Mannen en vrouwen gemiddeld evenveel roken, maar de variatie binnen deze groepen net wat anders is
- Er geen duidelijke relatie is tussen het aantal glazen alcohol dat men drinkt en aantal sigaretten dat men rookt op een uitgaansdag

Part III

Steekproeven en betrouwbaarheidsinterval

8 Inferentie en steekproeven

8.1 Populatie en steekproef

We zijn tot nu toe met beschrijvende statistiek bezig geweest. Je hebt nu een idee hoe we data kunnen samenvatten en visualiseren, en hoe we de relaties tussen variabelen kunnen analyseren. Dit zijn nuttige skills voor de rest van de cursus en (wellicht) ook voor later in je carrière als criminoloog.

We hebben ons in de vorige hoofdstukken gericht op de 350 respondenten die in de dataset zitten. Hoewel interessant, vertelt dit ons nog vrij weinig over de bredere populatie van uitgaande jongeren. Terwijl dit juist het centrale doel is van statistisch onderzoek: op basis van een steekproef willen we uitspraken doen die voor deze gehele populatie gelden! Dit noemen we ook wel **inferentie**, of **inferentiële statistiek**. Om dit te begrijpen, is het handig de begrippen populatie en steekproef kort uit te leggen.

> **i** Uitleg populatie vs. steekproef
>
> **Populatie**: De complete groep van analyse-eenheden waarin we geïnteresseerd zijn. In de criminologie gaat dit vaak om personen in een groep die we zo helder mogelijk proberen te identificeren en af te bakenen. Bijvoorbeeld alle leden van een criminele motorclub of smokkelnetwerk. In deze cursus richten we ons in principe op alle jongeren in Nederland die weleens op stap gaan.
> **Steekproef**: Een willekeurige selectie van eenheden uit de populatie. Willekeurige selectie betekent dat iedereen evenveel kans heeft om onderdeel te zijn van de steekproef (*random sample*). De steekproef is daarmee in principe een representatieve afspiegeling van de populatie. De steekproef bestaat uit onze observaties in de dataset, in dit geval alle jongeren die de vragenlijst hebben ingevuld.

Het idee achter inferentie is eigenlijk vrij simpel. In de praktijk is het vaak lastig om data over de hele populatie te verzamelen. We kunnen onmogelijk alle uitgaande jongeren in Nederland interviewen, dat gaat om miljoenen mensen! Toch willen we iets zinnigs kunnen zeggen over deze populatie. Bijvoorbeeld over het aandeel jongeren dat een bepaalde drugs gebruikt. Op basis van statistische kennis weten we dat we met slechts een klein deel van die jongeren (de steekproef) toch met bepaalde betrouwbaarheid (en onder bepaalde assumpties) iets kunnen zeggen over de populatie als geheel.

Dit brengt echter de nodige uitdagingen met zich mee. Hoe kun je de gegevens uit de steekproef gebruiken om iets te zeggen over de populatie, en hoe weet je zeker dat dit vervolgens klopt? En welke assumpties maken we daarbij? Dit omvat vele aspecten van meetmethode en statistiek. Daar gaan we in dit hoofdstuk verder op in. Ook zullen we tijdens de onderwijsgroepen en colleges hier meer bij stilstaan. Het is echter goed te realiseren dat we niet al deze complexiteit kunnen behandelen.

8.2 Steekproevenverdeling en centrale limietstelling

Stel, we willen weten welk aandeel uitgaande jongeren in Nederland weleens xtc heeft gebruikt. Daarvoor kunnen we een proportie berekenen: welk aandeel jongeren van het totaal aantal het betreft. Ons doel is hier om de proportie xtc-gebruikers in de Nederlandse populatie van uitgaande jongeren te *schatten* (bij benadering), we zullen immers nooit zeker weten wat deze precieze proportie is. Daar zouden we alle uitgaande jongeren in de populatie voor moeten bevragen.

Een proportie is een voorbeeld van een **parameter**: een kwantiteit die we schatten die ons informatie geeft over de populatie. Dit kan een proportie zijn, maar bijvoorbeeld ook een gemiddelde of een correlatie.

We geven eerst kort wat notatie. We zijn geïnteresseerd in wat de proportie xtc-gebruikers is in de populatie uitgaande jongeren, deze populatieparameter noteren we als P . Omdat we deze parameter niet direct weten, nemen we een steekproef van jongeren uit deze populatie. De proportie xtc-gebruikers in deze steekproef wordt genoteerd als $\hat{p}$.[1]

Om het proces van het schatten van de populatieparameter P (proportie xtc-gebruikers) uit te leggen, doen we geheel volgens wetenschappelijke traditie een klein gedachte-experiment, maar deze keer ook met praktische toepassing. Voor dit experiment doen we alsof we wel data voor de gehele populatie hebben. In dit geval is deze populatie alle jongeren die onze dataset zitten (wat origineel de steekproef was). We berekenen eerst de proportie P voor deze populatie.

```
# proportie xtc-gebruikers berekenen
table(data_uitgaan$xtc_ooit) |> prop.table()
```

```
      nee        ja
0.3150289 0.6849711
```

[1] Hetzelfde principe geldt voor andere parameters waarin we mogelijk geinteresseerd zijn. Als je het gemiddelde van een populatie (μ) wil schatten, trek je daarvoor een steekproef die uiteraard ook zijn eigen gemiddelde heeft ($\bar{x}$)

We zien dat deze proportie 0,685 bedraagt, oftewel 68,5% van de uitgaande jongeren heeft ooit xtc geprobeerd.

Voor het gedachte-experiment gaan we er even vanuit dat we de proportie van de populatie niet kennen, maar juist willen schatten. Daarom trekken we uit de populatie een steekproef van 30 personen. Vervolgens berekenen we daarvoor de proportie xtc-gebruikers $\hat{p}$.

```
# set.seed() om voorbeeld te reproduceren
set.seed(010)

# steekproef trekken van 30 personen uit populatie
sample_30 <- slice_sample(data_uitgaan, n = 30)

# proportie xtc-gebruikers berekenen
table(sample_30$xtc_ooit) |> prop.table()
```

```
      nee        ja
0.3448276 0.6551724
```

We zien dat voor deze steekproef van 30 personen de proportie 0,655 is (65,5%). Dit lijkt dus op de populatie proportie P van 0,685, maar er zit wel een klein verschil tussen (0,685 - 0,655 = 0,030; 3,0% om precies te zijn).

Dit verschil tussen P en $\hat{p}$ treedt in principe altijd op bij een willekeurige steekproef en de grootte ervan varieert per genomen steekproef. Laten we dit nader te bekijken. We trekken nu tien willekeurige steekproeven van 30 personen en berekenen alle steekproefproporties van xtc gebruikers.

```
set.seed(010)

# 10 keer een steekproef van 30 trekken en de proportie xtc-gebruikers berekenen
proporties_xtc <- replicate(10, {
  sample_30 <- slice_sample(data_uitgaan, n = 30)
  mean(sample_30$xtc_ooit == "ja", na.rm = TRUE) # na.rm om eventuele missenden waarden te ve
})

# proporties bekijken
print(proporties_xtc)
```

```
 [1] 0.6551724 0.6666667 0.7586207 0.7333333 0.5333333 0.8000000 0.6666667
 [8] 0.6896552 0.7586207 0.5862069
```

Je ziet dat sommige proporties $\hat{p}$ vrij dicht bij P liggen (bijvoorbeeld 0,690) terwijl anderen er ver weg van liggen (0,533). We zien dus dat er variatie is tussen steekproeven in de proporties.

Een uitgangspunt van inferentiële statistiek is dat een steekproef één mogelijke uitkomst is van een denkbeeldig universum met een oneindig aantal uitkomsten. Deze uitkomsten zijn willekeurige variaties op een onderliggende 'ware' populatieparameter (in dit geval P). Als we steekproeven oneindig zouden blijven herhalen, dan zal uiteindelijk het gemiddelde van alle mogelijke uitkomsten deze ware populatieparameter weergeven. Dit omdat eventuele afwijkingen het gevolg zijn van willekeurige variatie.

Als je hoofd inmiddels begint te duizelen, geen paniek. We komen hier later meer op terug. Ook zullen we vooral kijken naar wat dit in de praktijk betekent.

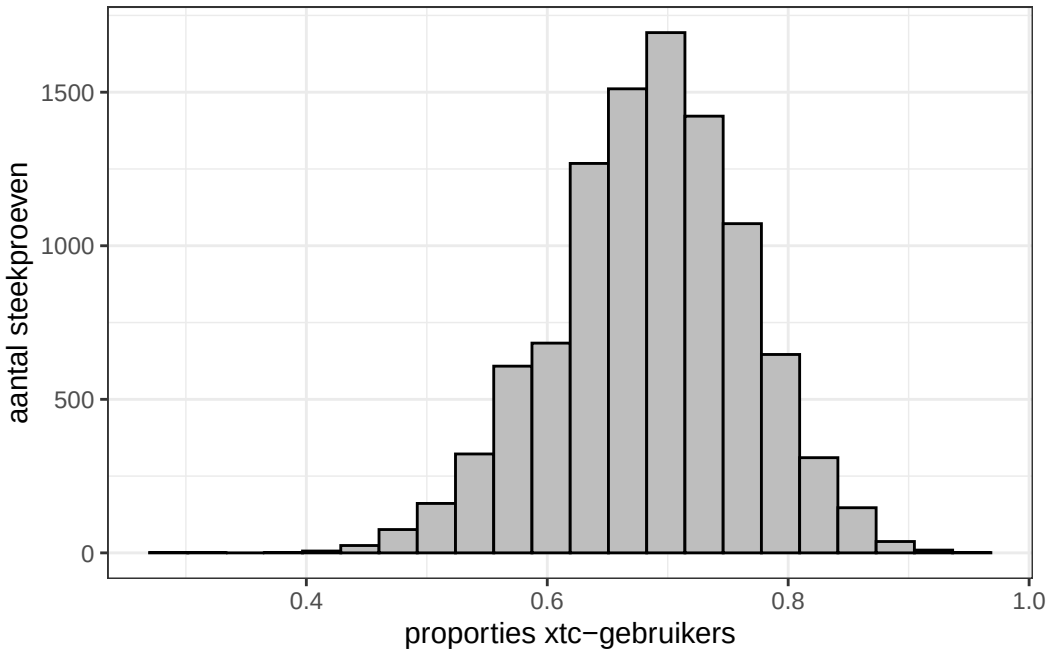
Zoals je wellicht kunt voorstellen, is het logisch niet mogelijk om oneindig steekproeven te blijven trekken. Daarom doen we dat hier bij benadering door 'slechts' 10.000 steekproeven te trekken van 30 personen.

```
set.seed(010)

# 10.000 keer een steekproef van 30 personen trekken en de proportie xtc-gebruikers berekener
proporties_xtc_10k <- replicate(10000, {
  sample_30 <- slice_sample(data_uitgaan, n = 30)
  mean(sample_30$xtc_ooit == "ja", na.rm = TRUE) # na.rm om eventuele missenden waarden te ve
})
```

Vervolgens visualiseren we de proporties xtc-gebruikers van al deze steekproeven in een histogram, en berekenen we enkele centrum- en spreidingsmaten.

```
# histogram maken
ggplot(as.data.frame(proporties_xtc_10k),
       aes(x = proporties_xtc_10k)) +
  geom_histogram(bins = 22, fill = "grey", colour = "black") +
  theme_bw() +
  ylab("aantal steekproeven") +
  xlab ("proporties xtc-gebruikers")
```




```
# berekenen centrum- en spreidingsmaten
summary(proporties_xtc_10k)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.3000  0.6333  0.6897  0.6849  0.7333  0.9667
```

```
sd(proporties_xtc_10k)
```

```
[1] 0.08147867
```

Wat je hierboven ziet, staat ook wel bekend als de **steekproevenverdeling**. Dat wil zeggen, de verdeling van de mogelijke uitkomsten (hier: proporties) van herhaalde steekproeven (in dit geval: 10.000 steekproeven van 30 personen betreffende de proportie xtc-gebruikers).

Er vallen een paar dingen op als we bovenstaande gegevens kijken. Ten eerste lijkt de verdeling van steekproefproporties nagenoeg op een normale verdeling, zoals we eerder hebben gezien (Normale verdeling). Dit betekent dat de steekproevenverdeling dezelfde eigenschappen heeft als een normale verdeling, zoals dat het een kansverdeling is (we kunnen de kans op een bepaalde uitkomst berekenen) en dat het een gemiddelde en een standaarddeviatie heeft. Je kunt verder zien dat het gemiddelde van 0,685 nagenoeg gelijk is aan de mediaan van 0,690, wat verder indiceert dat we hier met een normale verdeling te maken hebben (symmetrie). Het minimum (0,300) en maximum (0,967) tonen verder dat bij enkele steekproeven de proportie juist ver

af zit van het populatiegemiddelde, maar de verdeling toont tevens dat dit uitzonderlijke uitkomsten zijn.

Het meest interessant is echter dat de steekproevenverdeling van proporties allesbehalve willekeurig is. Het resulteert immers in een normale verdeling! En dat niet alleen: de gemiddelde proportie van de steekproevenverdeling ($\bar{x}_{\hat{p}} = 0,685$) is afgerond gelijk aan het populatiegemiddelde ($P = 0,685$). In het algemeen geldt dan ook dat het gemiddelde van de steekproevenverdeling gelijk is aan het populatiegemiddelde.

Hoe komt dat? Stel dat je een steekproef trekt met een selectie personen die op alle denkbare kenmerken gelijk zijn aan alle personen in de populatie. Het is met andere woorden een perfecte afspiegeling van de populatie. In dit geval vind je dat $P = \hat{p}$. Dit is echter bijna nooit het geval. Omdat een steekproef willekeurig wordt getrokken, zul je bijna altijd toevallige afwijkingen hebben. Dat je bijvoorbeeld net iets meer xtc-gebruikers selecteert dan niet-gebruikers ten opzichte van de verhouding in de populatie, wat weer invloed heeft op de hoogte van de proportie xtc-gebruikers. Maar, ervan uitgaande dat elke afwijking willekeurig is, zal bij oneindige herhaling van steekproeven het gemiddelde van alle afwijkingen 0 zijn (het is immers willekeurig of je een hogere of lagere proportie krijgt in een steekproef).

Een ander interessant gegeven is dat de steekproevenverdeling naast een gemiddelde zijn eigen standaarddeviatie heeft. Dit is een speciale variant van de standaarddeviatie, en wordt de **standaardfout** genoemd. Deze noteren we als $\sigma_{\hat{p}}$. [2] De 'fout' geeft dus eigenlijk aan in hoeverre een steekproefuitkomst (proportie v/d steekproef) afwijkt van de populatieparameter (proportie van de populatie). De standaardfout is belangrijk omdat we deze, zoals we later zullen zien, kunnen gebruiken om te berekenen wat de foutmarge van onze steekproef is met betrekking tot het schatten van de populatieparameter.

Knoop het dus goed in je oren: *de standaardfout is de standaarddeviatie van de steekproevenverdeling.* Deze noteren we bijvoorbeeld als $\sigma_{\hat{p}}$ voor proporties en $\sigma_{\bar{x}}$ voor gemiddeldes.

Dit is wat anders dan de gebruikelijke standaarddeviatie, die gaat om originele variabelen in de dataset die iets proberen te meten (bijvoorbeeld leeftijd of gemoedstoestand op dinsdag)

Wat we zojuist hebben geïntroduceerd, is de **centrale limietstelling**. Deze houdt in dat:

- Als een oneindig aantal willekeurige steekproeven bestaat uit ongeveer 30 observaties of meer, dan…
- Is het gemiddelde van de steekproevenverdeling gelijk aan het populatiegemiddelde
- Is de steekproevenverdeling normaal verdeeld, met eigen standaardfout
- Zelfs als de oorspronkelijke variabele niet normaal verdeeld is! (zoals bijvoorbeeld xtc_gebruik_ooit; dit is een dichotome variabele)

[2] goed om te weten: het aantal observaties (respondenten) in de steekproef noteren we met n; het aantal eenheden (personen) in de populatie noteren we met N

De regels rondom de centrale limietstelling zijn net wat anders bij minder dan 30 observaties, zie daarvoor bijvoorbeeld Statistiek als hulpmiddel of het internet.

Doordat we de standaardfout kennen, kunnen we in combinatie met de empirische regel bepalen hoe waarschijnlijk een bepaalde (willekeurige) steekproefuitkomst voorkomt. Daar gaan we zo mee verder. Eerst laten we de magie van de steekproevenverdeling en centrale limietstelling even op ons inwerken.

8.3 Één steekproef en de standaardfout

Degenen die een beetje bij zijn gekomen van het conceptueel geweld hierboven (en wellicht ook degenen voor wie de verwarring compleet is), zullen wellicht inmiddels aan het denken zijn: ja dat is allemaal leuk en aardig die 10.000 steekproeven, maar in de praktijk helemaal niet werkbaar. We kunnen immers niet voor elk onderzoek 10.000 steekproeven uitvoeren, dat kost tijd en geld en na de eerste steekproef is de lol er eigenlijk ook wel een beetje vanaf.

Gelukkig is hier een eenvoudige oplossing voor. Het blijkt namelijk statistisch zo te zijn dat we de standaardfout kunnen berekenen op basis van één steekproef. We hoeven dus helemaal geen 10.000 steekproeven te trekken om de standaardfout te berekenen!

Voor een het berekenen van de standaardfout van proporties $\sigma_{\hat{p}}$ geldt[3]:

$$\sigma_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

In deze formule zie je dat de proportie van de steekproef $\hat{p}$ wordt vermenigvuldigd met $(1-\hat{p})$, vervolgens gedeeld door het aantal observaties in de steekproef n en daar de wortel van wordt genomen.[4]

Dat de n in deze formule in de noemer staat (onder de streep) heeft een belangrijke implicatie. Dit betekent namelijk dat hoe meer data we verzamelen voor een steekproef (het aantal observaties), hoe kleiner de standaardfout wordt. En met een kleinere standaardfout kunnen we weer meer exact de populatieparameter schatten! (komen we later nog op terug)

Laten we dit even illustreren aan de hand van een voorbeeld. We selecteren willekeurig 10, 30, en 100 mensen uit de dataset, wat neerkomt op steekproeven met een verschillend aantal observaties. Ook berekenen we de standaardfout voor de gehele dataset (350 respondenten).

[3]Voor het berekenen van de standaardfout van steekproefgemiddeldes $\sigma_{\bar{x}}$ geldt een andere formule (zie Formuleblad)

[4]Goed om te weten: het aantal observaties (respondenten) in de steekproef noteren we met n; het aantal eenheden (personen) in de populatie noteren we met N

```r
set.seed(010)

# Functie om de standaardfout van een proportie te berekenen
se_proportie <- function(x) {
  x <- na.omit(x)
  p <- mean(x == "ja")
  sqrt(p * (1 - p) / length(x))
}

# Steekproeven trekken van 10, 30 en 100 respondenten
steekproef_10  <- slice_sample(data_uitgaan, n = 10)
steekproef_30  <- slice_sample(data_uitgaan, n = 30)
steekproef_100 <- slice_sample(data_uitgaan, n = 100)

# Standaardfouten berekenen
se_proportie(steekproef_10$xtc_ooit) # 10 respondenten
```

```
[1] 0.1656347
```

```r
se_proportie(steekproef_30$xtc_ooit) # 30 respondenten
```

```
[1] 0.083666
```

```r
se_proportie(steekproef_100$xtc_ooit) # 100 respondenten
```

```
[1] 0.04661037
```

```r
se_proportie(data_uitgaan$xtc_ooit) # 350 respondenten (complete dataset)
```

```
[1] 0.02497315
```

Je ziet dus dat de standaardfout steeds kleiner wordt naarmate we een grotere steekproef hebben. Bij 10 respondenten is de standaardfout nog 0,16; bij xxx respondenten is deze 0,02. Dit toont dat, als de assumpties kloppen, meer data meer beter is.

8.4 Assumpties (the mother of all...)

Je hebt het al een paar keer voorbij horen komen: onder bepaalde assumpties kunnen we ervan uitgaan dat een schatting van de populatieparameter klopt.[5] Maar wat zijn die assumpties? In de statistiek gaan we hier vaak makkelijk aan voorbij of kijken we er liever van weg, waarschijnlijk omdat de waarheid wat ongemakkelijk is en ook ingewikkeld. We hechten er echter veel waarde aan dat je toch op de hoogte bent van enkele assumpties. Omdat je daardoor beter begrijpt wat je wel en niet kan met statistiek. En dat je uiteindelijk hopelijk kritischer zal kijken naar veel statistieken die je in het dagelijks leven voorbij ziet komen.

8.4.1 Willekeurige en systematische fouten

Een eerste belangrijke assumptie is dat eventuele afwijkingen/fouten in de steekproef willekeurig zijn (**willekeurige fout**; *random error* in het Engels). Dit hebben we al deels besproken in dit hoofdstuk. Er zal altijd een zekere mate van toeval zijn die maakt dat het steekproefresultaat niet gelijk is aan de populatieparameter. Zolang het een willekeurige afwijking betreft, is er niet zoveel aan de hand. We weten immers, gegeven alleen toeval aan het werk is wat de kans op alle steeproefresultaten (hoe ver deze van P of μ liggen) en kunnen daarmee rekening houden bij het schatten van de populatieparameter.

Helaas komt het in steekproefonderzoek vaak voor dat fouten niet willekeurig zijn, maar eerder systematisch van aard. Dit kan op diverse wijzen gebeuren en zullen we daarom niet uitputtend behandelen hier. We geven een aantal voorbeelden om dit te verhelderen.

Een type **systematische fout** (*systematic error*) is dat je selectie van respondenten niet willekeurig is omdat er een structurele afwijking in zit. Dit kan zijn omdat een bepaalde groep binnen de populatie waar je in geïnteresseerd bent om een specifieke reden niet deelneemt aan onderzoek. Jongeren die een problematische hoeveelheid xtc gebruiken, zullen vaker vermoeid zijn en wellicht mentale problemen hebben. Daardoor zullen ze minder snel meedoen aan surveyonderzoek vanwege een gebrek aan focus of andere prioriteiten. Wanneer deze groep systematisch ondervertegenwoordigd is in je steekproef, zul je de proportie xtc-gebruikers (en ook de frequentie van gebruik) steeds te laag in schatten. Hoe vaak je ook een steekproef afneemt! Het voorkomen van dit soort systematische fouten is erg lastig en vergt goede kennis van de doelpopulatie en goed zicht op het proces van dataverzameling.

Een ander type systematisch fout kan in de vragenlijst zelf zitten. Stel dat die groep problematische en hoog-frequente gebruikers wel meedoet aan je onderzoek, maar in de vragenlijst hun gebruik stelselmatig onderrapporteert. Dat ze in hun antwoorden aangeven minder te gebruiken dan ze daadwerkelijk doen, vanwege sociale wenselijkheid of schaamte. Dan schat je het gebruik nog steeds te laag in.

[5] Kleine waarschuwing: wat nu volgt kan de eerste keer een beetje pijn doen aan je brein.

8.4.2 Willekeurige selectie

Bij het verzamelen van steekproefdata zijn er verder diverse praktische uitdagingen. Het idee van een willekeurig getrokken steekproef (*random sample*) veronderstelt dat je een overzicht heb van je populatie (alle uitgaande jongeren in Nederland tussen de 16 en 35 jaar) en vervolgens potentiële respondenten op willekeurige wijze selecteert. Maar hoe krijg je dat overzicht, het gaat immers om honderdduizenden zo niet miljoenen personen? Je zou bijvoorbeeld kunnen beginnen bij het willekeurig selecteren van plekken in Nederland (steden en dorpen), vervolgens een aantal uitgaansgelegenheden willekeurig selecteren (cafés, kroegen, discotheken, festivals, etc.) en dan op die plekken willekeurig jongeren benaderen om mee te doen aan het onderzoek. Je kunt je voorstellen dat dit laatste al lastig genoeg is: hoe ga je in drukke discotheek willekeurig mensen benaderen? Nog los van het gegeven dat sommige mensen te veel onder invloed zijn om een vragenlijst serieus in te vullen.

In het oorspronkelijke onderzoek (Het Grote Uitgaansonderzoek), waar onze dataset op is gebaseerd, is de werving van respondenten via social media gegaan. Het Trimbos instituut heeft via advertenties en een wervingscampagne respondenten geworven via Instagram, Snapchat en Facebook. Hoewel dit geschikte platformen zijn om uitgaande jongeren te bereiken, is de selectie van respondenten allesbehalve willekeurig. In plaats van willekeurig te selecteren uit de populatie is het proces hier eerder andersom: je stuurt een bericht de wereld in om te kijken wie uit de populatie er mee wil doen aan het onderzoek. Ook zal niet iedereen uit de doelpopulatie op deze platformen zitten (mensen zonder social media).

Dit wil niet zeggen dat het onderzoek geen zin heeft of meteen niet valide is. Het gaat er eerder om dat we ons bewust zijn van de beperkingen en mogelijke fouten, zodat we geen onjuiste uitspraken doen op basis van de data en onze methoden. In theorie stellen we dat als de selectie van respondenten totaal willekeurig plaatsvindt, dat er geen systematische fouten zijn op basis van zowel geobserveerde (variabelen die we meten) en niet-geobserveerde kenmerken (wat we niet meten in de vragenlijst). In de praktijk is het vaak wat rommeliger.

De hier genoemde fouten hebben te maken met de **validiteit** en **betrouwbaarheid** van kwantitatief onderzoek. Dit zijn belangrijke aspecten waar we in de colleges en onderwijsgroepen ook meer aandacht aan zullen besteden.

8.4.3 De constante populatieparameter

Naast mogelijke systematische fouten zijn de filosofische aannames achter statistiekonderzoek niet altijd even goed toepasbaar. Zoals eerder gesteld is het idee achter de dominante manier van statistiek bedrijven dat er zoiets bestaat als een ware populatieparameter P die we in theorie kunnen achterhalen door een oneindig aantal onderzoeken (bijvoorbeeld experimenten of steekproeven) uit te voeren. Er wordt aangenomen dat de populatieparameter een constante, vaste waarde heeft. Als we onderzoek blijven herhalen, krijgen we steeds net wat andere data door willekeurige fouten. De data varieert dus, de populatieparameter niet. Op de lange termijn

zal het gemiddelde van al deze onderzoeken echter leiden tot de ware P (zie Section 8.2). Dit denken gaat dus uit van een soort denkbeeldig universum waarin we deze onderzoeken oneindig kunnen herhalen. In de praktijk voeren we het onderzoek vaak eenmaal uit.

In sommige situaties is deze manier van denken geschikt. Als we geïnteresseerd zijn in xtc-gebruik onder uitgaande jongeren in Nederland, kunnen we ervan uitgaan dat in er in deze populatie een zekere constante proportie van gebruik bestaat. Bij herhaalde onderzoeken zullen we dan los van toevallige fouten naar verwachting min of meer steeds op dezelfde proportie uitkomen (zie het voorbeeld onder Section 8.2), althans op de korte tot middellange termijn. Over de tijd zal het gebruik als het gevolg van maatschappelijke en culturele veranderingen variëren.

Voor meer specifieke vragen geeft de aanname van een universum met een ware populatieparameter die we ontdekken door oneindig herhaalde onderzoeken wel problemen (lees deze zin gerust nog een keer). Neem als voorbeeld dat we geïnteresseerd zijn in de proportie xtc-gebruikers op het festival Lowlands in 2026. Dit is een eenmalig evenement. We kunnen er wellicht van uitgaan dat er zoiets is als een constante populatieparameter 'proportie xtc-gebruik' voor dit festival, maar we kunnen in de praktijk geen herhaalde onderzoeken blijven doen om dit te meten. Deze editie van 2026, waar we specifiek in zijn geïnteresseerd, vindt immers maar één keer plaats en we kunnen dus ook maar één keer onderzoek doen. De statistiekfilosofie laat ons hier in de steek.

Dat de filosofie niet helemaal kloppend is voor de onderzoekspraktijk is niet per se een probleem, onderzoek vergt wel vaker wat conceptueel rekwerk. Desalniettemin moeten we ons goed rekenschap geven van deze assumpties.

8.5 Samenvatting

Je hersenen zullen vast een beetje kraken na dit hoofdstuk. In essentie komt het erop neer dat:

- In inferentie proberen we een populatieparameter (proportie xtc-gebruik onder uitgaande jongeren) te schatten middels een willekeurig getrokken steekproef.
- Middels de steekproevenverdeling kunnen we berekenen hoe groot de kans is op een afwijkende steekproefproportie ten opzichte van de proportie in de populatie, met behulp van de standaardfout
- Aan de hand van één steekproef kunnen we de standaardfout verkrijgen, waarbij geldt dat deze kleiner wordt bij een grotere steekproef
- Er zijn diverse fouten mogelijk bij een steekproef waar we ons bewust van moeten zijn

9 Betrouwbaarheidsinterval

We zijn in het vorige hoofdstuk ingegaan op de principes van inferentiële statistiek, de steekproevenverdeling, de standaardfout, assumpties en mogelijke fouten die kunnen plaatsvinden.

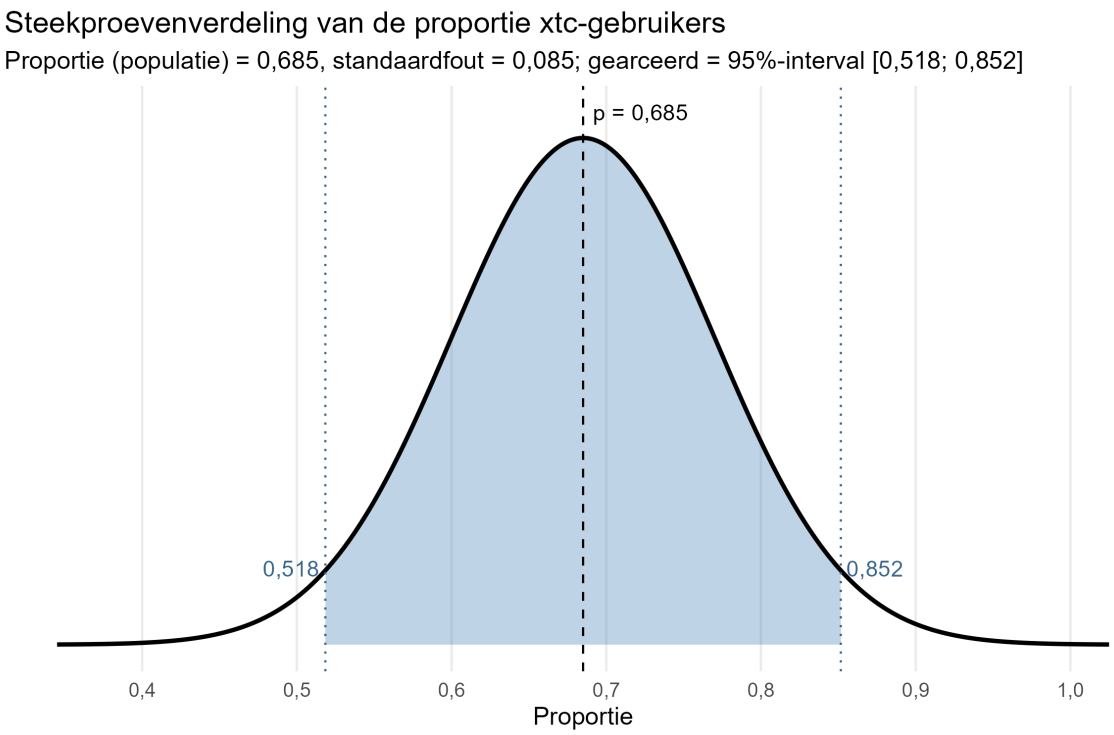
We moeten nu een volgende stap maken, namelijk die van het trekken van één steekproef naar het schatten van de populatieparameter. Omdat we nooit helemaal zeker weten wat de populatieparameter is, schatten we met behulp van de standaardfout hoe dicht we in de buurt zitten (de foutmarge). Dit doen we aan de hand van een **betrouwbaarheidsinterval** (afkorting: bhi). We zullen in dit hoofdstuk in een aantal concrete stappen laten we zien we hoe dit doen.

9.1 Betrouwbaarheidsinterval voor proporties

9.1.1 Denkbeeldig voorbeeld

We beginnen met een denkbeeldig voorbeeld. We gaan er net als bij het vorige hoofdstuk vanuit dat we de populatieproportie en de standaardfout al kennen van xtc-gebruik onder uitgaande jongeren, waarbij we de dataset als populatie beschouwen. Dit is uiteraard zelden het geval (daarom doen we onderzoek!), maar voor de uitleg die volgt is dit wel handig.

Als we volgens de centrale limietstelling oneindig steekproeven trekken van 30 personen, willen we weten wat het bereik is van 95% van de steekproefuitkomsten (proporties in dit geval) rondom het populatiegemiddelde. Met 95% hebben we een aardig beeld van wat voor proporties de meeste steekproeven zouden opleveren. Dat is hieronder gevisualiseerd.



De afbeelding hierboven is afgeleid van het voorbeeld uit het vorige hoofdstuk. Het toont dat als we herhaalde steekproeven zouden doen waarbij de proportie in de populatie van xtc-gebruik 0,685 is, dat 95% van de steekproeven een proportie tussen de 0,518 en 0,852 zou opleveren.

Waarom kiezen we hier voor 95%? Dat is afgeleid uit de empirische regel die we bij de Normale verdeling hebben besproken. Daar zag je bijvoorbeeld dat 95,4% van alle observaties tussen 2 standaarddeviaties boven en onder het midden van de verdeling liggen. 95% wordt vaak als conventioneel interval gebruikt, omdat het een breed interval betreft dat veel mogelijke uitkomsten bevat zonder dat het betekenisloos wordt.[1] Het 95%-betrouwbaarheidsinterval correspondeert met 1,96 standaarddeviaties boven en onder het midden van de verdeling.

Aan de hand van de formule van betrouwbaarheidsinterval kunnen we zien hoe we dit berekenen:

$$bhi = P \pm z \times \sigma_{\hat{p}}$$

of:

$$bhi \;\; ondergrens = P - z \times \sigma_{\hat{p}}$$

[1] Andere veelgebruikte betrouwbaarheidsintervallen zijn 90% en 99%. De bijbehorende standaarddeviaties zijn hierbij respectievelijk 1,65 en 2,58 (op basis van z-scores).

$$bhi\ \ bovengrens = P + z \times \sigma_{\hat{p}}$$

Je neemt dus:

- de (schatting van de) populatieparameter P
- telt daarbij op en trekt af de standaarddeviatie z die je hebt gekozen voor de grens van het bhi. De z komt van de (gestandaardiseerde standaarddeviaties) die je eerder hebt gezien.
- De z moet je wel eerst vermenigvuldigen met de standaardfout $\sigma_{\hat{p}}$

We weten voor dit voorbeeld dat:

- $P = 0,685$
- $z = 1,96$ (we hebben gekozen voor een 95%-bhi)

Je hebt eerder gezien hoe je de standaardfout berekent voor proporties. Je hoeft alleen de proportie en aantal respondenten in te vullen:

$$\sigma_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0,685(1-0,685)}{30}}$$

```
# berekenen standaardfout voor voorbeeld
sqrt(0.685*(1-0.685)/30)
```

```
[1] 0.08480861
```

De standaardfout is in dit geval dus 0,085.

Dan hoeven we in principe alleen nog de formule van het bhi in te vullen:

$$bhi = P \pm z \times \sigma_{\hat{p}} = 0,685 \pm 1,96 \times 0,085$$

We berekenen eerst het deel achter de $\pm$ ($z \times \sigma_{\hat{p}}$):

```
# gedeelte achter +-
1.96*0.085
```

```
[1] 0.1666
```

Dit is dus 0,167. Het bereik van het 95%-bhi ligt 0,167 boven en onder de populatieproportie van 0,685. Dit tellen we op/trekken we af van 0,685.

```
# berekenen bhi
0.685-0.167 # ondergrens
```

```
[1] 0.518
```

```
0.685+0.167 # bovengrens
```

```
[1] 0.852
```

Voilà! We weten nu dus dat als we oneindig willekeurige steekproeven zouden trekken van 30 personen uit een populatie uitgaande jongeren, dat de proporties xtc-gebruik in 95% van de steekproeven tussen de 0,518 en 0,852 zouden liggen (als overige assumpties kloppen).

9.1.2 Reëel voorbeeld

Het denkbeeldige voorbeeld is instructief, maar eigenlijk overbodig. We gingen er al vanuit dat de proportie in de populatie 0,685 was. Dan is het in principe niet meer nodig een betrouwbaarheidsinterval te berekenen.

We weten nu echter ook het volgende: omdat 95% van de verdeling van mogelijke steekproefproporties tussen 0,518 en 0,852 ligt (0,167 boven of onder 0,685), is de kans 95% dat een proportie van een willekeurige steekproef binnen dit bereik valt. Dit betekent dat als we herhaaldelijk een proportie $\hat{p}$ berekenen op basis van een willekeurige steekproef (van 30 personen in dit geval), en vervolgens een interval berekenen tussen $\hat{p} - 0,167$ en $\hat{p} + 0,167$, dat dit interval de populatieproportie zal bevatten in 95% van de steekproeven.

Simpel gezegd, kunnen we in de formule $bhi = P \pm z \times \sigma_{\hat{p}}$ de P vervangen door $\hat{p}$, en dan voor elke steekproef berekenen in welk interval de populatieparameter mogelijk ligt. We zullen daarbij ook de standaardfout $\sigma_{\hat{p}}$ opnieuw moeten berekenen, omdat we die berekend hebben aan de hand van $P = 0,685$ maar die kennen we in de werkelijkheid niet. De nieuwe formule voor het schatten van een betrouwbaarheidsinterval is:

$$bhi = \hat{p} \pm z \times \sigma_{\hat{p}}$$

of:

$$bhi \;\; ondergrens = \hat{p} - z \times \sigma_{\hat{p}}$$

$$bhi \;\; bovengrens = \hat{p} + z \times \sigma_{\hat{p}}$$

We kunnen nu zien hoe dit werkt aan de hand van een voorbeeld. We trekken een steekproef van 30 personen en berekenen de proportie xtc-gebruikers in deze steekproef.

```
set.seed(42)

# steekproef trekken van 30 personen uit populatie
sample_30 <- slice_sample(data_uitgaan, n = 30)

# proportie xtc-gebruikers berekenen
table(sample_30$xtc_ooit) |> prop.table()
```

```
      nee        ja
0.3666667 0.6333333
```

De proportie xtc-gebruikers in deze steekproef is dus 0,633. Eerst berekenen we de nieuwe standaardfout:

$$\sigma_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0,633(1-0,633)}{30}}$$

```
# berekenen standaardfout voor willekeurige steekproef met 30 respondenten
sqrt(0.633*(1-0.633)/30)
```

```
[1] 0.0879983
```

De standaardfout is 0,088. Dan hebben we alle relevante gegevens om het 95%-betrouwbaarheidsinterval te berekenen:

$$bhi = \hat{p} \pm z \times \sigma_{\hat{p}} = 0,633 \pm 1,96 \times 0,088$$

```
# gedeelte achter +-
1.96*0.088
```

```
[1] 0.17248
```

```
# berekenen bhi
0.633-0.172 # ondergrens
```

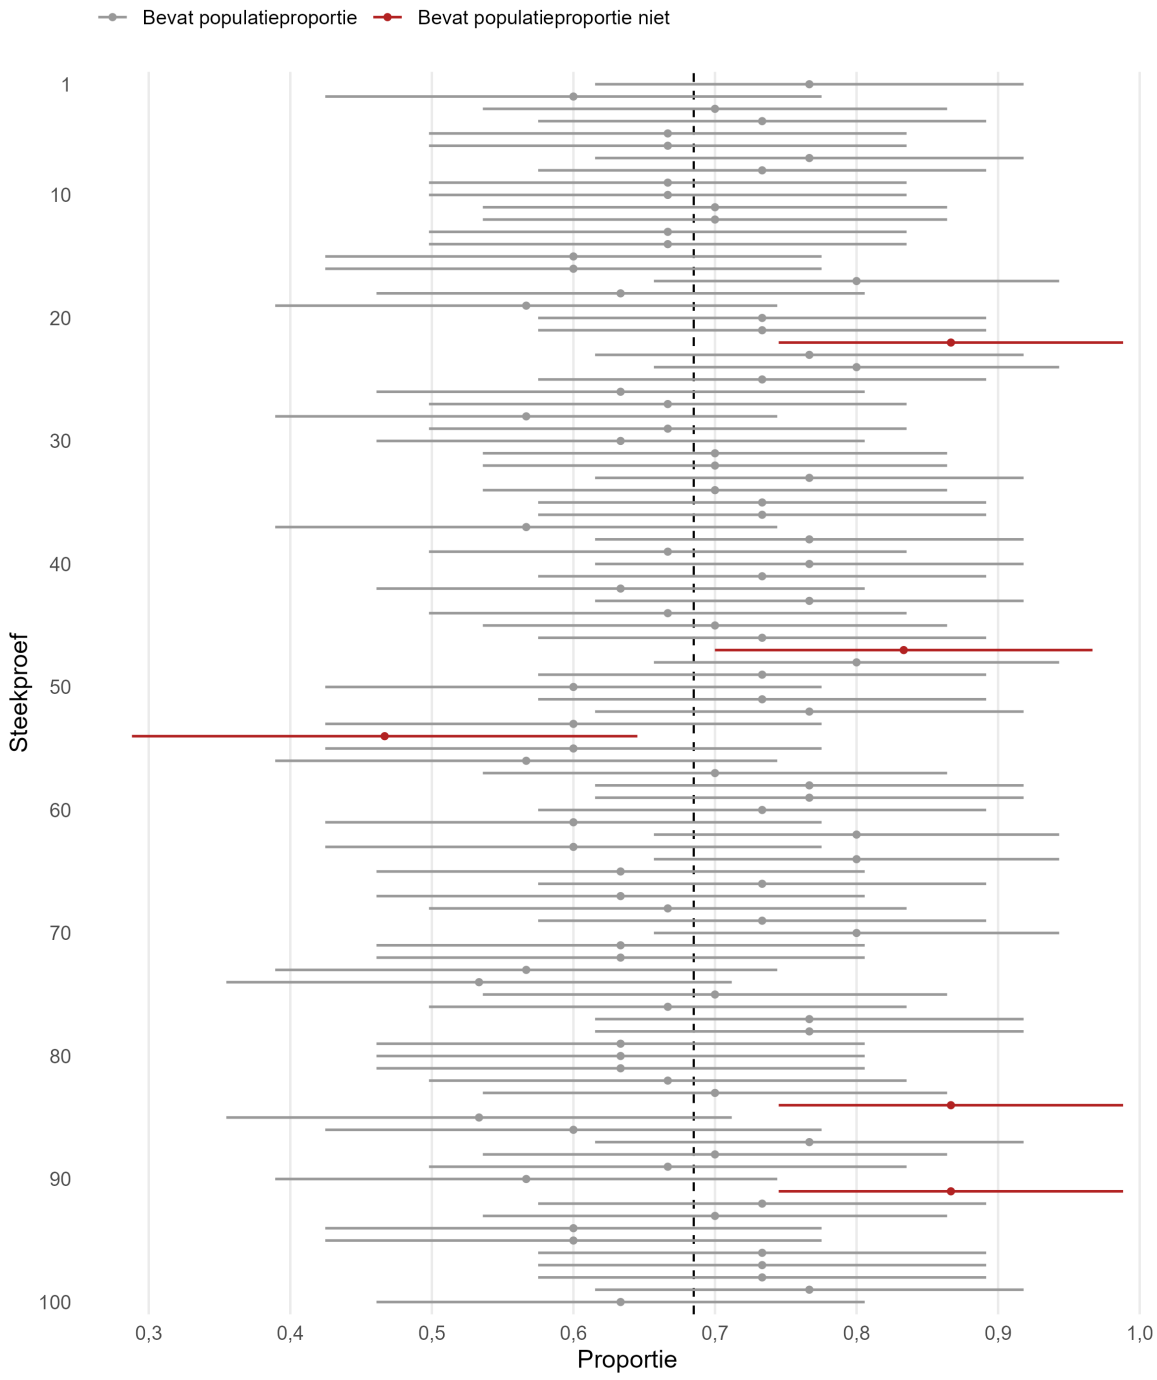
```
[1] 0.461
```

```
0.633+0.172 # bovengrens
```

```
[1] 0.805
```

De ondergrens van het 95%-bhi is in dit geval 0,461 en de bovengrens is 0,805. Dit noteren we ook wel als $[0,461; 0,805]$. Op basis hiervan concluderen we (voorlopig) dat in 95% van de herhaalde steekproeven de populatieproportie tussen deze twee waarden zou moeten liggen. In dit geval is dat correct: 0,685 ligt tussen 0,461 en 0,805.

Het principe van een 95%-bhi is hieronder uitgebeeld. Deze grafiek toont een simulatie waarin we 100 keer een steekproef hebben getrokken van 30 personen en voor elke steekproef het 95%-bhi hebben berekend. Wanneer een interval de populatieproportie bevat, dan overlapt het interval (horizontale grijze streep) met de verticale gestippelde lijn die de populatieproportie presenteert. In 5% van de steekproeven zie je dat het interval en de populatieproportie niet overlappen. Dit zijn steekproeven die toevallig een hele hoge of lage proportie van xtc-gebruikers hebben (rode kleur). Uitgaande van een 95%-bhi, valt de populatiewaarde dan buiten het interval bij deze steekproeven. We zitten er dus ook weleens naast met een steekproef, ook al is aan alle assumpties voldaan. Het voordeel is wel dat we weten hoe vaak we er naast zaten, namelijk in 5% procent van de steekproeven.


100 betrouwbaarheidsintervallen van 95% (n = 30 per steekproef)
Stippellijn = populatieproportie (0,685); 5 van de 100 intervallen bevatten deze niet
Bevat populatieproportie
Bevat populatieproportie niet
Steekproef
1
10
20
30
40
50
60
70
80
90
100
0,3
0,4
0,5
0,6
0,7
0,8
0,9
1,0
Proportie

9.1.3 Reëel voorbeeld #2

Hopelijk heb je inmiddels een beetje feeling gekregen voor betrouwbaarheidsintervallen. Het vorige voorbeeld was leerzaam, maar de uitkomst was een beetje teleurstellend. Dat we op basis van een steekproef van 30 personen weten dat in 95% van de steekproeven de populatieproportie xtc-gebruikers ergens tussen de 0,461 en 0,805 ligt is nog niet zo informatief. Het kan namelijk 0,461 zijn, of 0,805, of alles daar tussen in. Het maakt nogal uit of het 46,1% gebruikers gaat of om 80,5%! Stel je voor dat de media een bericht schrijft over jouw onderzoek, dan wil je toch wat nauwkeuriger kunnen zeggen hoeveel uitgaande jongeren ooit xtc hebben gebruikt.

We gaan nu kijken hoe de grootte van de steekproef hier van invloed is (zie ook het deel over de standaardfout). We trekken nu geen steekproef van 30 personen, maar één van 10 en één van 100 personen. Eerst schrijven we even een functie om het 95%-bhi automatisch te berekenen, zodat we niet alles weer stap voor stap hoeven te berekenen.

```
# functie schrijven voor 95%-bhi
bhi_95 <- function(p, n) {
  p + c(-1, 1) * 1.96 * sqrt(p * (1 - p) / n)
}
```

We trekken twee steekproeven van respectievelijk 10 en 100 personen, en berekenen de proporties.

```
set.seed(42)

# steekproeven trekken van 10 en 100 personen
sample_10 <- slice_sample(data_uitgaan, n = 10)
sample_100 <- slice_sample(data_uitgaan, n = 100)

# proportie xtc-gebruikers berekenen
table(sample_10$xtc_ooit) |> prop.table() # 10 personen
```

```
nee  ja
0.3 0.7
```

```
table(sample_100$xtc_ooit) |> prop.table() # 100 personen
```

```
      nee       ja
0.4183673 0.5816327
```

De proportie voor de steekproef met 10 personen bedraagt 0,700 en die voor 100 personen is 0,582. Nu berekenen we het 95%-bhi voor beide steekproeven.

```
# 95%-bhi berekenen voor beide steekproeven
bhi_95(0.7, 10) # 10 personen
```

```
[1] 0.415969 0.984031
```

```
bhi_95(0.582, 100) # 100 personen
```

```
[1] 0.4853269 0.6786731
```

Je ziet grote verschillen tussen deze betrouwbaarheidsintervallen. De steekproef van 10 personen heeft een 95%-bhi tussen $[0,416; 0,984]$. Dit is een heel breed interval. De populatieproportie van 0,685 valt er wel binnen, maar dit zal sowieso in 95% van de steekproeven het geval zijn. Op basis van het interval zelf kunnen we niet veel zeggen over de mogelijke populatieproportie xtc-gebruikers. Dit zou alles tussen de 41,6% en 98,4% kunnen zijn.

Het 95%-bhi van de steekproef met 100 personen is daarentegen veel smaller: $[0,485; 0,679]$. Afgaande op dit interval, zou je stellen dat in 95% van de herhaalde steekproeven de proportie xtc-gebruikers in de populatie tussen de 48,5% en 67,9% ligt. Dit is nog steeds een redelijk breed interval, maar wel al nauwkeuriger dan wat we eerder hebben gezien. Toevallig valt de populatieproportie (0,685) buiten dit interval, we hebben dus een 5% misser hier!

We kunnen het voorbeeld van proportie xtc-gebruikers nu full circle afsluiten. We hebben de hele tijd voor didactische redenen aangenomen dat $P = 0,685$, de proportie uit de dataset. We laten nu het idee los dat we de populatieparameter zouden kennen, en schatten wat deze mogelijk zou kunnen zijn op basis van de hele dataset. Nu is $\hat{p} = 0,685$. Herinner dat we xxx respondenten hebben in de dataset.

```
# berekenen 95%-bhi voor de complete steekproef
bhi_95(0.685, 350)
```

```
[1] 0.6363343 0.7336657
```

Onze schatting is dat we met 95% van de gevallen kunnen zeggen dat de proportie xtc-gebruikers in de populatie uitgaande jongeren tussen 0,636 en 0,737 ligt, bij herhaalde steekproeven van xxx personen. Dus ergens tussen de 63,3% en 73,7%. Dat komt al aardig in de buurt van een vrij precies resultaat!

9.2 Betrouwbaarheidsinterval voor gemiddeldes

Het is voor het oudere publiek wel even slikken, dat waarschijnlijk tussen 63,3% en 73,7% van de uitgaande jongeren weleens xtc heeft gebruikt. Je zal inmiddels wel redelijk klaar zijn met het schatten van de proportie xtc-gebruikers. Daarom gaan we nu naar een ander voorbeeld kijken.

We hebben ons tot nu toe vooral met proporties schatten bezig gehouden. Een proportie is een aandeel van iets dat in een score tussen de 0 en 1 wordt uitgedrukt, en is toepasbaar op veel variabelen. Naast xtc-gebruik zou je bijvoorbeeld ook naar het ooit-gebruik van sigaretten (ja/nee) of cocaine (ja/nee) kunnen kijken. Andere variabelen vragen echter om een andere statistiek, zoals leeftijd, aantal sigaretten of aantal glazen alcohol op een uitgaansdag. Daarvoor schatten we een gemiddelde, wat we nu zullen doen voor aantal glazen alcohol.

De formule voor een bhi van een populatiegemiddelde is net wat anders:

$$bhi = \bar{x} \pm z \times \sigma_{\bar{x}}$$

We nemen nu dus het gemiddelde van de steekproef $\bar{x}$ en de standaardfout van gemiddeldes $\sigma_{\bar{x}}$. Deze laatste berekenen we volgens de formule:

$$\sigma_{\bar{x}} = \frac{s}{\sqrt{n}}$$

We kunnen nu vrij eenvoudig schatten wat het gemiddeld aantal glazen alcohol is dat uitgaande jongeren drinken op een uitgaansdag. Let op dat deze statistiek alleen van toepassing is op mensen die minimaal één glas hebben gedronken. Eerst berekenen we het gemiddelde en de standaarddeviatie in de dataset.

```
# gemiddelde aantal glazen alcohohol
mean(data_uitgaan$glazen_alcohol_uitgaansdag, na.rm = TRUE)
```

```
[1] 10.66471
```

```
# gemiddelde aantal glazen alcohohol
sd(data_uitgaan$glazen_alcohol_uitgaansdag, na.rm = TRUE)
```

```
[1] 5.823302
```

Het gemiddelde is $10,7$ en de standaarddeviatie $5,8$. We weten al dat het aantal respondenten xxx is. Dan hebben we alle gegevens om een 95%-bhi te berekenen. Dit doen we als volgt:

$$bhi = \bar{x} \pm z \times (\frac{s}{\sqrt{n}}) = 10,7 \pm 1,96 \times (\frac{5,8}{\sqrt{350}})$$

We berekenen weer eerst het gedeelte achter $\pm$ $(1,96 \times (\frac{5,8}{\sqrt{350}}))$

```
# gedeelte achter +-
1.96*(5.8/sqrt(350))
```

```
[1] 0.6076452
```

En dit tellen we op/trekken we af van het gemiddelde:

```
# 95%-bhi berekenen
10.7-0.61
```

```
[1] 10.09
```

```
10.7+0.61
```

```
[1] 11.31
```

Op basis van steekproef, kunnen we zeggen dat in 95% van herhaalde steekproeven (van 350 personen) het populatiegemiddelde van aantal glazen alcohol ergens tussen de $10,1$ en $11,3$ zal liggen. We kunnen dus wel redelijk zeker stellen dat het gemiddeld aantal glazen alcohol dat men drinkt zo 10 à 11 per uitgaansdag is. Je ziet dat het schatten van een populatiegemiddelde niet veel anders is dan het schatten van een proportie in de populatie.

9.3 Interpretatie betrouwbaarheidsinterval

We hebben hierboven al een aantal keer een interpretatie van een betrouwbaarheidsinterval gegeven. Daarbij hebben we het er een beetje makkelijk vanaf gebracht, want een bhi heeft een meer uitgebreide interpretatie nodig dan we tot nu toe hebben gedaan. Een technische correcte interpretatie van een 95%-bhi is:

> Als we steekproeven oneindig herhalen en we berekenen een 95%-bhi voor alle steekproeven, dan zullen 95% van deze bhi's de ware populatieparameter bevatten (terwijl 5% van de bhi's deze niet bevatten).

Deze wat langdradige formulering weerspiegelt de achterliggende aannames van een bhi. Namelijk dat deze

1) één schatting is van een serie van mogelijke steekproeven die we kunnen we trekken uit de populatie en …

2) dat er zoiets bestaat als een constante, vaste populatieparameter die het bhi wel of niet bevat.

Omdat we vaak maar één steekproef hebben in onderzoek, formuleren we de interpretatie van een bhi als volgt:

> We kunnen met 95% betrouwbaarheid stellen dat de ware populatieparameter ergens tussen [ondergrens] en [bovengrens] ligt, gebaseerd op (hypothetische) herhaalde steekproeven.

Vertalen we dit door naar ons voorbeeld over de proportie xtc-gebruikers, dan zou je de volgende interpretatie kunnen geven: *we kunnen met 95% betrouwbaarheid stellen dat de proportie uitgaande jongeren die ooit xtc hebben gebruikt ergens tussen de 0,636 en 0,737 ligt, gebaseerd op (hypothetische) herhaalde steekproeven.*

Een veelgemaakte fout bij het interpreteren van een bhi is dat men stelt dat er een 95% *kans* bestaat dat de populatieparameter in het interval ligt. Dit is niet juist, omdat de populatieparameter een vaste waarde is die *wel* of *niet* binnen het interval ligt. De kans dat een betrouwbaarheidsinterval de ware populatieparameter bevat, is daarmee 100% (wel) of 0% (niet). Om deze reden zeggen we juist dat 95% van alle mogelijke bhi's de populatieparameter zal bevatten.

We maken het ten slotte wederom nog een stukje ingewikkelder (sorry!). De uitspraak "met 95% betrouwbaarheid stellen we dat de proportie uitgaande jongeren die ooit xtc hebben gebruikt ergens tussen de 0,636 en 0,737 ligt, gebaseerd op (hypothetische) herhaalde steekproeven" is statistisch correct, maar niet per se neutraal of altijd overeenkomstig met de werkelijkheid. De uitspraak is puur gebaseerd op het onderzoek, maar neemt geen eerdere kennis in overweging.

Stel dat eerdere onderzoeken hebben aangetoond dat de proportie xtc-gebruik onder uitgaande jongeren lager ligt, rond de 30-40%. Is het dan echt nog zo aannemelijk dat we in 95% van de herhaalde steekproeven een populatiewaarde zo hoog als het onze zullen vinden in het interval? De eerdere kennis van het onderwerp heeft dus invloed op hoe we het bhi interpreteren en de geloofwaardigheid daarvan. We kunnen deze kennis niet zomaar aan de kant schuiven.

De gedachtegang hier geeft aan dat de interpretatie van een bhi subjectiever kan zijn dan we vaak denken. Er even hypothetisch van uitgaand dat de daadwerkelijke populatieproportie van xtc-gebruik veel lager ligt dan ons interval lijkt aan geven, zou een persoon met kennis hiervan die 95% betrouwbaarheid in twijfel trekken. Iemand zonder kennis zal het daarentegen wellicht een plausibel resultaat vinden. Een meer accurate interpretatie van een bhi is daarom:

> We kunnen met 95% betrouwbaarheid stellen dat de ware populatieparameter ergens tussen [ondergrens] en [bovengrens] ligt, gebaseerd op (hypothetische) herhaalde steekproeven *en geen additionele relevante kennis*.

Je zult inmiddels wel denken: wat moet ik hier allemaal mee (voor het tentamen)? We zullen wat duidelijkheid verschaffen op dit punt. We verwachten in ieder geval:

- Dat je de laatst gegeven interpretatie van een betrouwbaarheidsinterval consistent toepast op de variabelen die je onderzoekt tijdens de practica
- Dat je op basis van logisch redeneren en ervaring die je opdoet tijdens de cursus kan uitleggen hoe precies of nauwkeurig je de populatiemeter weet te schatten op basis van het bereik van het interval. In hoeverre is bijvoorbeeld een interval van proporties tussen 0,461 en 0,805 informatief (Section 9.1.3)?
- Dat je begrijpt wat we bedoelen met "95% betrouwbaarheid … gebaseerd op (hypothethische) herhaalde steekproeven" en hoe dit voorkomt uit de steekproevenverdeling
- Dat je begrijpt waar de toevoeging "en geen additionele relevante kennis" vandaan komt en ook in hoeverre dit van toepassing kan zijn op zaken die je zelf onderzoekt.

9.4 Samenvatting

- Op basis van de steekproevenverdeling en empirische regel kunnen we voor elke steekproef berekenen, met een bepaalde mate van betrouwbaarheid, in welk interval de populatieparameter zal liggen. Hiervoor kiezen we doorgaans het 95%-betrouwbaarheidsinterval.
- Over het algemeen geldt dat het betrouwbaarheidsinterval smaller wordt (en daarmee nauwkeuriger) wanneer we meer data verzamelen.
- Bij het interpreteren van het bhi moeten we met verschillende assumpties en aspecten rekening houden. Dit is belangrijk omdat we daardoor meer bewust zijn van wat we eigenlijk aan het doen zijn.

Part IV

Hypotheses toetsen

10 Hypothesetoetsing

In het vorige deel hebben we kennis gemaakt met inferentiële statistiek. We bespraken hoe je op basis van een steekproef iets zinnigs kan zeggen over een bepaalde populatie en welke aspecten daarbij komen kijken. We keken vooral naar het schatten van een populatieparameter, bijvoorbeeld wat de proportie xtc-gebruik onder uitgaande jongeren is.

In statistisch onderzoek zijn we vaak geïnteresseerd in relaties tussen bepaalde dingen (zie ook de vragen bij Data), waarbij we verwachtingen hebben over hoe die relatie werkt of in elkaar zit. Zoals bij Relaties tussen variabelen, kunnen we data verzamelen over bepaalde kenmerken van personen en dan de relaties hiertussen onderzoeken. Dit zegt alleen iets over de personen in de dataset, maar nog niet de bredere populatie.

Om onze verwachtingen over relaties in de populatie te onderzoeken, maken we daarom gebruik van **hypothesetoetsing**. "Hypotheses toetsen" betekent dat we een verwachting formuleren over hoe iets werkt in de populatie, dit vervolgens analyseren en dan uitspraken doen in hoeverre deze verwachting klopt. Daarbij houden we, net als bij de eerder behandelde betrouwbaarheidsintervallen, rekening met hoe zeker we kunnen zijn over de juistheid van onze uitspraak.

In dit hoofdstuk gaan we hypothesetoetsing uitleggen aan de hand van een concreet voorbeeld. Er zijn grofweg twee manieren om een hypothese te toetsen. De klassieke methode is volgens het criterium van **statistische significantie**. Hierbij bepaal je voor een bepaalde grenswaarde (significantieniveau) of een hypothese kan worden verworpen. Hoewel deze methode (nog steeds) de standaard is in sociaalwetenschappelijk onderzoek, is er ook veel kritiek op. Hier komen we straks op terug. De andere methode is (surprise, surprise) het uitrekenen van een betrouwbaarheidsinterval. We zullen uitleggen waarom deze laatste methode onze voorkeur geniet.

Er komen bij het toetsen van hypotheses meerdere zaken kijken. De basics daarvan zullen we in deze cursus behandelen. Het is echter goed te realiseren dat de onderzoekspraktijk vaak nog wat complexer is en je na deze cursus dus nog niet uitgeleerd bent. Op een aantal van die zaken gaan we de komende hoofdstukken dieper in. Het is dus niet erg als je nog niet alles meteen begrijpt.

Ten slotte werken we het voorbeeld eerst uit middels de overschrijdingskans, wat je de 'computerbenadering' zou kunnen noemen. In latere hoofdstukken werken we ook nog handmatige voorbeelden uit om meer inzicht te geven in het proces. Voor nu is het relevant dat je het principe van hypothesetoetsing snapt.

10.1 Wie drinkt er meer?

Als voorbeeld kijken we naar het verschil tussen mannen en vrouwen in hoeveel glazen alcohol ze drinken tijdens een uitgaansdag. Er bevinden zich onder zowel mannen als vrouwen matige en stevige drinkers. Hoewel het algemene beeld wellicht is dat vooral mannen tijdens het stappen de sluizen flink open kunnen zetten, onderzoeken we voor dit voorbeeld of er überhaupt een verschil in alcoholconsumptie is. Je zult later zien waarom dergelijke formuleringen relevant zijn.

Merk meteen op dat we hier twee verschillende meetniveaus met elkaar in verband brengen. We willen voor een nominale variabele (geslacht) weten wat het verschil is in gemiddeldes op een ratio variabele (aantal glazen alcohol). Dit type toets noemen we een **t-toets voor onafhankelijke groepen**. Er zijn diverse varianten van de t-toets, waarvan we er twee in deze cursus zullen behandelen.

Het onderzoeken van verschillen in drankconsumptie tussen mannen en vrouwen geeft een uitdaging. Stel dat we data verzamelen onder een groep van 40 uitgaanders bestaande uit 20 mannen en 20 vrouwen, en vinden dat mannen gemiddeld 11,4 glazen per uitgaansdag drinken en vrouwen 8,7. Op basis van de steekproef weten we dan dat mannen gemiddeld $11,4 - 8,7 = 2,7$ meer glazen alcohol drinken dan vrouwen. We zouden op basis hiervan kunnen stellen dat er een verschil bestaat tussen mannen en vrouwen in drankconsumptie.

Je weet echter uit de vorige hoofdstukken dat deze steekproef slechts één resultaat is van een (hypothetisch) oneindig aantal mogelijke steekproeven. In een andere steekproef kan het zijn dat we vinden dat vrouwen evenveel drinken als mannen. Hoe kunnen we nu vaststellen dat, met een bepaalde mate van zekerheid, er over het algemeen een verschil bestaat in drankconsumptie tussen mannen en vrouwen?

Voor dit dilemma is de methode van hypothesetoetsing ontwikkeld. Het idee achter deze methode is in feite niet anders dan dat we gezien hebben bij het betrouwbaarheidsinterval. In plaats van de proportie xtc-gebruikers, nemen we nu het verschil tussen mannen en vrouwen in aantal glazen als onze te schatten populatieparameter en gaan we berekenen wat de verdeling is van steekproefuitkomsten als we deze oneindig zouden herhalen. Hier komt de steekproevenverdeling dus weer van pas!

Het aantal stappen bij hypothesetoetsing is uitgebreider dan bij het berekenen van een betrouwbaarheidsinterval. Die lopen we nu stap voor stap door.

10.2 Statistische significantie

10.2.1 1) Hypothese opstellen

De eerste stap is dat je jouw verwachting van de uitkomst zo expliciet mogelijk formuleert, dit wordt een **hypothese** genoemd. Hier volgt meteen een hersenkronkel. In statistisch onderzoek toetsen we namelijk niet wat we verwachten, maar juist het tegenovergestelde daarvan! Deze tegenovergestelde verwachting wordt de **nulhypothese** genoemd. Het werken met de nulhypothese vindt zijn oorsprong in het wetenschapsfilosofisch idee dat we aannemen iets nooit helemaal zeker te weten. Het is daarom makkelijker om het onwaarschijnlijke van wat we verwachten (de nulhypothese) te verwerpen, en er dan vanuit gaan dat het waarschijnlijke (onze originele verwachting) 'voorlopig' waar is. Dit staat bekend als het falsificatieprincipe van Karl Popper. *De nulhypothese wordt wel of niet verworpen, dit is in feite het centrale doel van statistisch wetenschappelijk onderzoek.* Bij hypotheses formuleren bespreken we ook uitgebreider waar je op moet letten bij het formuleren van een nulhypothese.

Onze verwachting bij dit voorbeeld is dat er een verschil bestaat tussen mannen en vrouwen in hoeveel glazen alcohol ze drinken op een uitgaansdag. We gebruiken vaak statistische notatie om dit expliciet te maken:

$$\mu_1 \neq \mu_2$$

Dit betekent dat het gemiddelde in de populatie van de eerste groep (μ_1) *niet gelijk is aan* het gemiddelde van de populatie van de tweede groep (μ_2). Oftewel, het gemiddelde aantal glazen alcohol onder mannen is niet gelijk aan het gemiddelde aantal glazen alcohol onder vrouwen.

Draaien we dit om voor het formuleren van de nulhypothese, dan krijgen we:

$$\mu_1 = \mu_2$$

Dit lezen we als: het populatiegemiddelde aantal glazen alcohol onder mannen (μ_1) is *gelijk aan* het populatiegemiddelde aantal glazen alcohol onder vrouwen (μ_2).

We zouden dit ook als volgt kunnen noteren:

$$\mu_1 - \mu_2 \ = 0$$

Oftewel, voor de nulhypothese verwachten we dat het verschil tussen μ_1 en μ_2 gelijk is aan nul. Bij de nulhypothese verwacht je vaak geen verschil of in een andere richting dan je zou denken. Daarom wordt het de nulhypothese genoemd (nul verschil, nul samenhang, nul effect, etc.) .

10.2.2 2) Bepalen significantieniveau

Het **significantieniveau** α is de grenswaarde waarbij we een nulhypothese verwerpen. Als de overschrijdingskans (p-waarde) kleiner is dan deze grenswaarde, verwerpen we de nulhypothese. Hier komen we bij de volgende stappen op terug. Gebruikelijke significantieniveaus in de statistiek zijn 0,01 (1%), 0,05 (5%) en 0,1 (10%). Net als bij dit voorbeeld gaan we meestal uit van een significantieniveau α van 0,05.

10.2.3 3) Overschrijdingskans

De **overschrijdingskans**, ook wel p-waarde genoemd of simpelweg p, speelt een centrale rol in het toetsen van hypotheses.[1] Het geeft aan hoe waarschijnlijk het resultaat verkregen uit onze steekproef is (of extremer), aangenomen dat de nulhypothese waar is.[2]

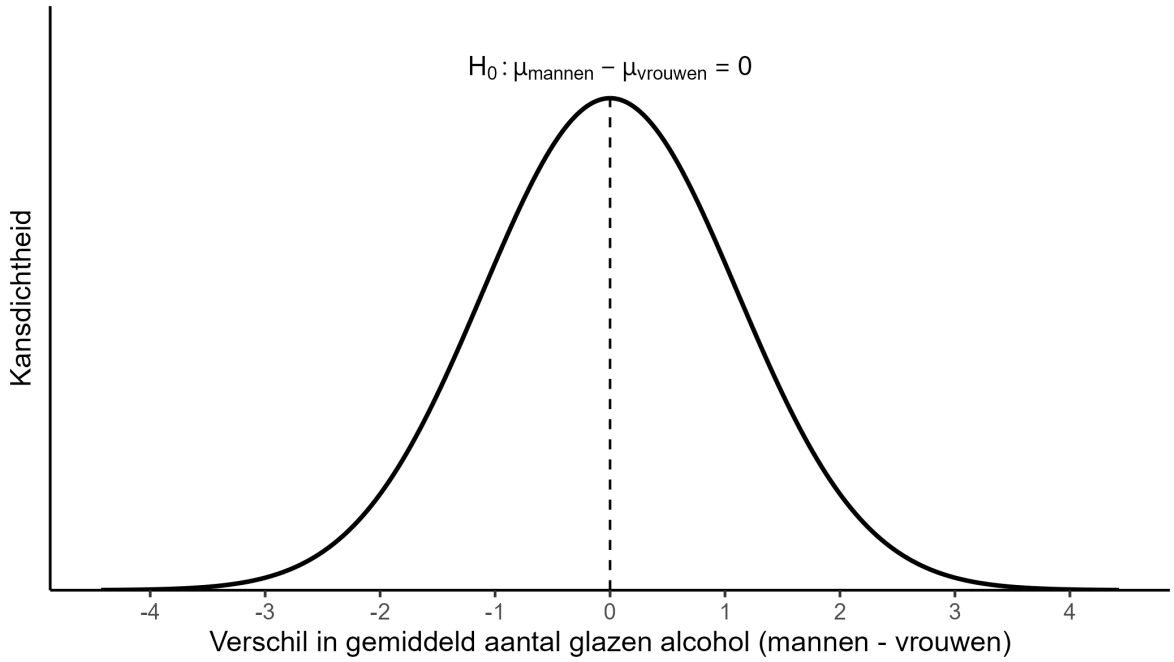
Je zult inmiddels wel denken: "waar zijn we nu weer aanbeland"?

Laten we het laag voor laag afpellen.

In de praktijk vormt de nulhypothese ons vertrekpunt. Vanuit de nulhypothese is de verwachting doorgaans dat er geen verschil is tussen groepen. Onze 'ware' populatiewaarde, gegeven de nulhypothese, is daarom nul. We maken een denkbeeldige steekproevenverdeling van mogelijke steekproefuitkomsten die hierbij past (zie ook Steekproevenverdeling en Betrouwbaarheidsinterval). Dit noemen we ook wel de H_0-verdeling of de verdeling onder de nulhypothese (zie hieronder).

[1] Let op dat p hier naar iets heel anders verwijst dan P en $\hat{p}$ uit de vorige hooddstukken. p gaat over de overschrijdingskans terwijl P en $\hat{p}$ gaan over proporties.

[2] 'Steekproefresultaat' verwijst hier naar de populatieparameter waarin we geïnteresseerd zijn: het gemiddelde verschil tussen mannen en vrouwen in drankconsumptie.



De verdeling geeft een indicatie van hoe waarschijnlijk een bepaalde steekproefuitkomst is onder H_0. Je kunt bijvoorbeeld zien dat een gemiddeld verschil van drie glazen zeer onwaarschijnlijk is: het ligt ver van het midden van de verdeling. Hoe groter de afstand tot H_0, hoe eerder we de nulhypothese zullen verwerpen.

We kunnen nu de kans berekenen dat een bepaalde steekproefuitkomst voorkomt binnen deze H_0-verdeling: de overschrijdingskans! We werken immers met een normaalverdeling en kunnen via de empirische regel nagaan wat de kans op een bepaalde uitkomst is (zie Normale verdeling).

We generen eerst de data die hoort bij ons voorbeeld. We hebben ons onderzoek verricht onder 20 mannen en 20 vrouwen, met respectievelijke gemiddeldes van 11,4 en 8,7 glazen alcohol. Voor het gemak gaan we er even vanuit dat de standaarddeviatie s binnen beide groepen 3,5 is.

```
set.seed(010)

# Trekt n respondenten en schaalt ze zodat gemiddelde en sd exact kloppen
genereer_groep <- function(n, gemiddelde, s) {
  rnorm(n) |> scale() |> as.vector() * s + gemiddelde
}

voorbeeld_alcohol <- data.frame(
  geslacht                    =  factor(rep(c("man", "vrouw"), each = 20)), # variabele mann
```

```
  glazen_alcohol_uitgaansdag   =
    c(genereer_groep(20, 11.4, 3.5), genereer_groep(20, 8.7, 3.5)) # 20 respondenten per gesl
)
```

Vervolgens berekenen we de overschrijdingskans die bij deze steekproef hoort.

```
# t-toets uitvoeren om overschrijdingskans te berekenen
t.test(glazen_alcohol_uitgaansdag ~ geslacht, # variabelen bepalen
       data = voorbeeld_alcohol) # dataset
```

```
    Welch Two Sample t-test

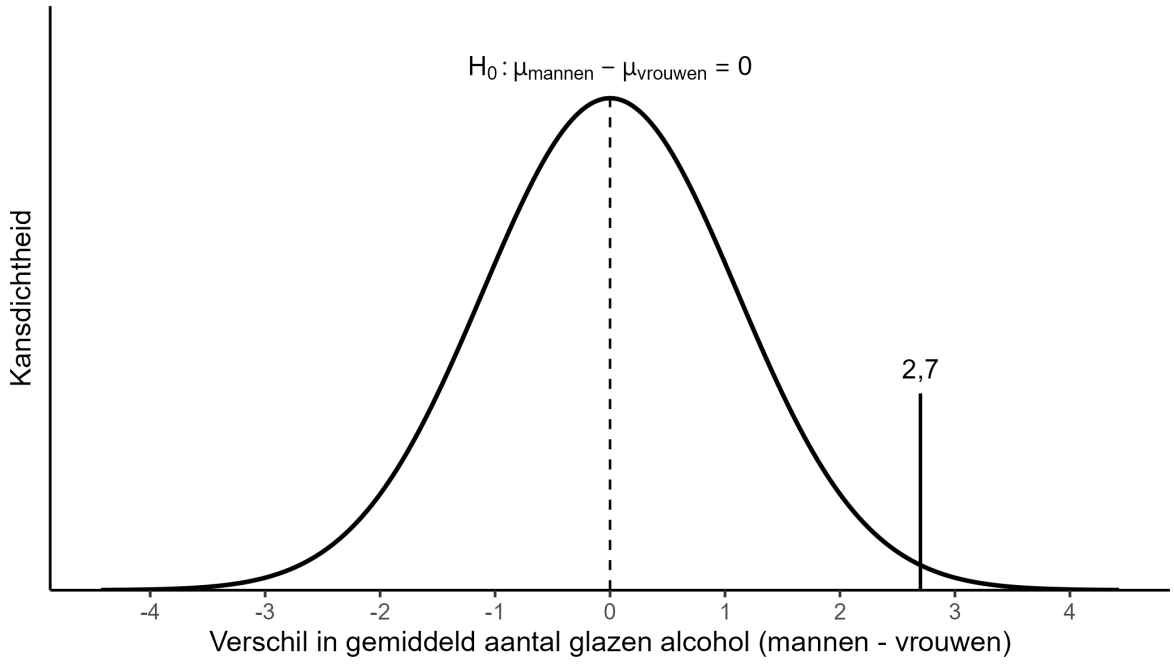
data:  glazen_alcohol_uitgaansdag by geslacht
t = 2.4395, df = 38, p-value = 0.01949
alternative hypothesis: true difference in means between group man and group vrouw is not equ
95 percent confidence interval:
 0.4594062 4.9405938
sample estimates:
  mean in group man mean in group vrouw
               11.4                 8.7
```

De output van deze toets geeft aardig wat informatie. Voorlopig kijken we alleen naar de p-waarde (p-value), dit is onze overschrijdingskans. Deze bedraagt afgerond dus 0,019. Formeel interpreteren we de p-waarde als volgt:

> de kans op het verkrijgen van een steekproefresultaat minstens zo extreem als het huidige, aangenomen dat de nulhypothese waar is (en alle andere model assumpties).

Je kunt zien dat die kans in dit voorbeeld klein is (ongeveer 2%).

Het gemiddelde verschil tussen mannen en vrouwen dat we hebben gevonden in de steekproef bedraagt 2,7 glazen. Deze uitkomst ligt ver van het midden van de verdeling en is daarmee onwaarschijnlijk onder de H_0-verdeling (zie figuur hieronder). Het corresponderende gebied onder de grafiek (de kans) is daarmee klein.



10.2.4 4) Vergelijken significantieniveau en overschrijdingskans

Nu resteert een laatste stap in het hypothese toetsen. We hebben gevonden dat de kans op een gemiddeld verschil van 2,7 glazen alcohol zeer onwaarschijnlijk is onder de nulhypothese ($p = 0,019$). Dit is een sterke indicatie dat de nulhypothese kan worden verworpen. Er bestaat echter de mogelijkheid dat we (toevallig) een steekproef hebben getrokken die ver afligt van de H_0-verwachting (herinner wederom de Steekproevenverdeling). Volgens de methode van statistische significantie willen we met bepaalde zekerheid stellen of een nulhypothese moet worden verworpen of niet. Daarom kiest men voor een significantieniveau: een grens waarbij we de nulhypothese verwerpen met een bepaalde zekerheid.

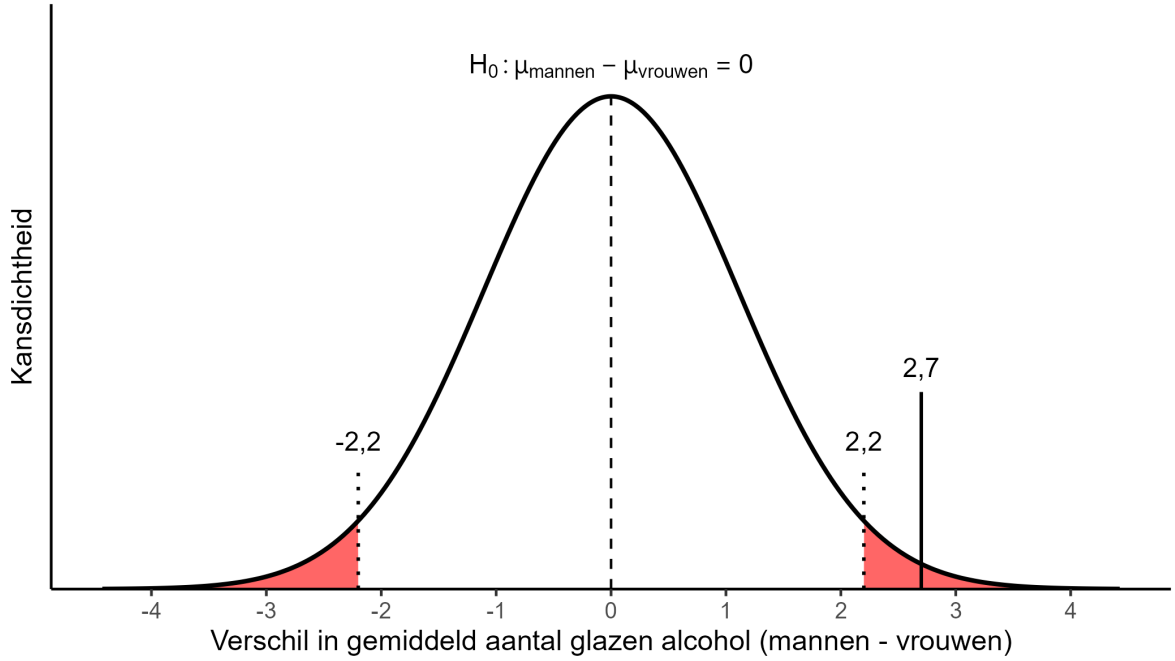
In dit geval hebben we een significantieniveau van 0,05 gekozen. We kunnen in dit voorbeeld simpelweg de overschrijdingskans vergelijken met het significantieniveau. Als de eerste kleiner is dan de laatste ($p < \alpha$), dan verwerpen we de nulhypothese. Andersom ($p > \alpha$) doen we dit juist niet, dan verwerpen we de nulhypothese *niet*. Omdat hier $p = 0,019$ kleiner is dan het significantieniveau van 0,05, verwerpen we de nulhypothese.

De technische interpretatie luidt als volgt:

> Als mannen en vrouwen in de populatie van uitgaanders gemiddeld evenveel zouden drinken, dan is een verschil van 2,7 glazen of meer (in een van beide richtingen) zo zeldzaam dat het in minder dan 5% van de herhaalde steekproeven voorkomt.

Daarom verwerpen we de nulhypothese en gaan er voorlopig vanuit dat er een statistisch significant verschil bestaat tussen mannen en vrouwen in hoeveel ze gemiddeld drinken.

Om dit verder te verduidelijken, tonen we de grenzen van aantal glazen alcohol waarbij je de nulhypothese moet verwerpen (zie onderstaande figuur). De rode zones aan het uiteinde van de verdeling noemen we het H_0-verwerpingsgebied. Als we terugrekenen dan correspondeert een significantieniveau van 5% met 2,2 glazen alcohol bij dit voorbeeld. Als we een steekproefuitkomst vinden die voorbij deze grens ligt, dus lager dan -2,7 of hoger dan 2,7, dan verwerpen we de nulhypothese in principe bij een significantieniveau van 5%.



Let op dat we onder de nulhypothese zowel een positief (mannen drinken meer dan vrouwen) als negatief (vrouwen drinken meer dan mannen) verschil verwachtten, daarom ligt de grens van significantie in dit geval aan beide kanten van de H_0-verdeling (zie LATER HOOFDSTUK).

10.3 Wat nog meer...

Hierboven hebben we in een notendop laten zien welke stappen je moet nemen bij het toetsen van een (nul)hypothese. Voor de eenvoud hebben we wel een aantal relevante aspecten achterwege gelaten. Dit betreffen de volgende zaken:

- Bij het berekenen van de overschrijdingskans moeten we rekening houden met de grootte van de steekproef. Dit doen we middels de t-verdeling, die wat anders in elkaar zit dan de normale verdeling waar we tot nu toe mee gewerkt hebben.

- Hypotheses kunnen eenzijdig of tweezijdig worden geformuleerd. Bij eenzijdig hebben we een specifiek idee over de richting van een verband (bijv. mannen drinken meer dan vrouwen), terwijl we bij tweezijdig er alleen vanuit gaan dat er een verschil. Dit bepaalt mede hoe we de toets uitvoeren en interpreteren.
- Bij een t-toets voor onafhankelijke groepen onderzoeken we hoe twee verschillende groepen (mannen en vrouwen) gemiddeld verschillen op één variabele (aantal glazen alcohol). Daarbij kun je ervan uitgaan dat de varianties gelijk of ongelijk zijn. Bij gelijke varianties is er binnen de groep mannen evenveel variantie (onderlinge verschillen) in drinkgedrag als binnen de groep vrouwen. Stel dat binnen de groep mannen veel meer diversiteit bestaat in lichte en zware drinkers dan bij de vrouwen, dan spreken we van ongelijke varianties. Voor het gemak gaan we in deze cursus steeds uit van ongelijke varianties, maar dit hoeft lang niet altijd zo te zijn.
- ASSUMPTIE VAN NORMALE VERDELING VOOR BEIDE GROEPEN.

De eerste twee punten komen uitgebreider aan bod in LATER HOOFDSTUK.

10.4 Beperkingen statistische significantie

De methode van statistische significantie voor hypothesetoetsing, zoals hierboven beschreven, wordt veel toegepast in wetenschappelijk onderzoek. Je zult in veel wetenschappelijke studies lezen dat onderzoekers hebben gevonden dat een bepaald verschil tussen groepen of een effect 'significant' is. Ondanks de wijdverbreide toepassing is er echter ook veel kritiek op de methode van statistische significantie. Het is belangrijk om hier bewust van te zijn, zodat we niet dezelfde fouten reproduceren. Ook leert het ons beter begrijpen wat we wel en niet kunnen met statistisch onderzoek.

Een veelgemaakte fout is dat de uitkomst van een hypothesetoets verkeerd geïnterpreteerd wordt. Zo wordt de p-waarde vaak geïnterpreteerd als "de kans dat de nulhypothese waar is". Dit is echter geen juiste interpretatie. De p-waarde geeft ons slechts de kans op het verkrijgen van bepaalde data (een steekproefresultaat), aangenomen dat de nulhypothese waar is (onder de H_0-verdeling dus). Op eenzelfde manier wordt vaak gezegd dat een statistisch significant resultaat bij een significantieniveau van 5% betekent dat "er een 95% kans is dat er verschil tussen groepen bestaat in de populatie", wat ook niet juist is.

Zulke verkeerde interpretaties hebben dezelfde oorsprong, namelijk dat men veronderstelt dat de uitkomst direct iets zegt over de kans dat de nulhypothese waar is of niet. Echter, strikt gezien kunnen we alleen iets zeggen over de kans op *het vinden een bepaalde gegevens of data* (het steekproefresultaat) *onder de aanname dat de nulhypothese waar is*. We gaan er dus vanuit dat de nulhypothese in principe waar is of niet, en niet voor 95% bijvoorbeeld (zie ook discussie van de interpretatie van het betrouwbaarheidsinterval).

Een andere veelgemaakte fout is het verwarren van 'statistisch significant' met **praktisch significant**. Praktisch significant betekent dat je een substantieel verschil of verband vindt

met inhoudelijke relevantie. Stel dat uit jouw onderzoek blijkt dat mannen twee keer zoveel drinken als vrouwen, bijvoorbeeld gemiddeld 10 vs. 5 glazen alcohol op een uitgaansdag. Dat is een behoorlijk verschil, wat ook gevolgen zal hebben voor wie als probleemdrinker wordt gezien en hoe beleid rondom alcoholpreventie moet worden vormgegeven. Dit is dus een bevinding waarbij de grootte van het verschil er toe doet.

Het kan aan de andere kant ook voorkomen dat je vindt dat er slechts een klein verschil bestaat tussen mannen en vrouwen in drankconsumptie, bijvoorbeeld 10 vs. 9 glazen respectievelijk. Het kan zijn dat je dan alsnog een statistisch significant verschil vaststelt, afhankelijk van de groepsvarianties en het aantal personen in de steekproef.[3] Het verschil tussen 10 en 9 glazen is echter klein, waardoor het praktisch gezien bijna verwaarloosbaar is.

In de onderzoekspraktijk zul je vaker vinden dat er wel een bepaald verschil is, maar dat de substantiële betekenis hiervan niet meteen duidelijk is. In het voorbeeld op deze pagina is het gevonden gemiddelde verschil 2,7 glazen. Is dit veel of weinig? Dat is gedeeltelijk een subjectieve opvatting. In de sociale wetenschappen zijn er geen vastomlijnde regels van wanneer iets praktisch significant is, dat hangt af van de context. Meestal bepaal je de praktische relevantie aan de hand van logisch redeneren en afvragen waarom deze bevinding relevant is. Als je bijvoorbeeld gaat autorijden, kunnen 2-3 glazen een groot verschil maken. Voor een avond stappen waarin sowieso heel veel gedronken wordt, heeft een verschil van 2-3 glazen wellicht minder effect op de totale mate van intoxicatie. Context doet er dus toe.

10.5 Betrouwbaarheidsinterval voor hypothesetoetsing

Bovenstaande duidt er op dat hypothesetoetsen via statistische significantie zijn beperkingen heeft. Deze komen er grotendeels op neer dat:

- de interpretatie van een significant resultaat regelmatig verkeerd gaat
- een focus op statistische significante afleidt van praktische significantie
- er weinig aandacht is voor hoe precies de populatieparameter wordt geschat

Deze beperkingen kunnen we grotendeels ondervangen door een alternatieve methode te gebruiken waar we al bekend mee zijn: het betrouwbaarheidsinterval! Een bhi kan ons informatie verschaffen over hoe groot een verschil is in populatiegemiddeldes, en met welke mate van zekerheid we dat kunnen vaststellen. Het werkt hier niet veel anders dan bij het schatten van een gemiddelde of proportie in de populatie, alleen nemen we deze keer een andere type populatieparameter: *het verschil tussen twee gemiddeldes* (voor onafhankelijke groepen). Volgens dezelfde principes die eerder hebben geleerd berekenen we voor deze populatieparameter een bhi.

Wellicht was het je opgevallen dat we dit al hebben gedaan. De output bij het berekenen van de Section 10.2.3 geeft tevens een bhi. Die bedraagt voor het voorbeeld op deze pagina $[0,46; 4,94]$.

[3] Dit komt verder aan bod bij Aspecten van hypothesetoetsing.

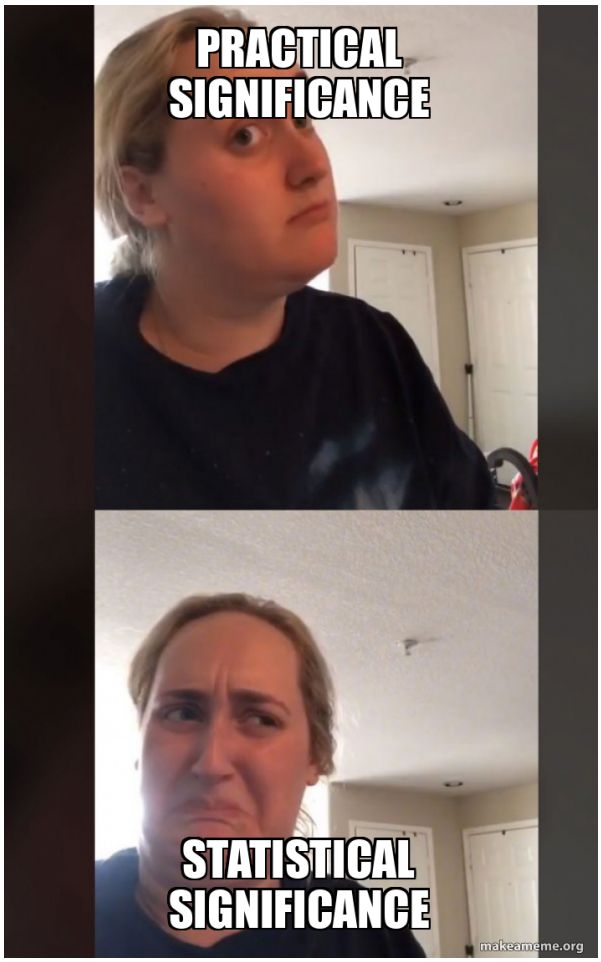
Op basis van wat we eerder hebben gezien bij de interpretatie van een betrouwbaarheidsinterval, kunnen we dit interval hier interpreteren als:

> We kunnen met 95% betrouwbaarheid stellen dat het gemiddelde verschil tussen mannen en vrouwen in glazen alcoholconsumptie op een een uitgangsdag ergens tussen de 0,46 en 4,94 ligt, gebaseerd op (hypothetische) herhaalde steekproeven engeen additionele relevante kennis.

We kunnen een dergelijk bhi op vrij simpele wijze gebruiken om tevens de nulhypothese te toetsen. Omdat we bij de t-toets gekozen hebben voor het standaard 5% significantieniveau, correspondeert dit met een (tweezijdig) 95%-bhi. Omdat onze verwachting onder de nulhypothese is dat het gemiddelde verschil 0 is, hoeven we alleen te kijken of die waarde in het geschatte bhi ligt. Dat is hier niet het geval: 0 valt niet binnen het bereik van $[0,46; 4,94]$. Wat we al wisten, hebben we nu op alternatieve wijze aangetoond: de nulhypothese kan worden verworpen. We gaan er voorlopig vanuit dat er een statistisch significant verschil bestaat tussen mannen en vrouwen in hoeveel ze gemiddeld drinken.

Deze laatste observatie is op zich niet zo interessant. We zijn meestal geïnteresseerd in hoe groot dat verschil is (met andere woorden: praktische significantie). Het bhi vertelt ons iets over welke populatieparameter we zullen vinden in 95% van de herhaalde steekproeven. Dat blijkt hier nog behoorlijk uiteen te liggen. Het kan zowel 0,46 zijn (een half glas) of 4,94 (5 glazen), en alles daartussen in. Deze waardes hebben potentieel hele andere praktische implicaties, omdat een half glas in de meeste situaties verwaarloosbaar is terwijl vijf glazen dat niet zijn. Dit resultaat geeft dus nog niet een heel nauwkeurig beeld.

Je merkt hopelijk dat het hanteren en interpreteren van een bhi (in plaats van statistische significantie alleen) leidt tot een andere focus. We kijken meer naar de inhoudelijke en praktische betekenis, en niet alleen of iets statistisch significant is.



10.6 Samenvatting

Je hebt in vogelvlucht kennis gemaakt met hypothesetoetsen en enkele relevante aspecten. We hebben hierboven gekeken naar een t-toets voor onafhankelijke groepen (met ongelijke varianties). Dit soort toets voeren we uit wanneer we de gemiddelde score op een kwantitatieve variabele willen vergelijken tussen twee groepen (nominale variabele). De belangrijkste punten van dit hoofdstuk zijn als volgt:

- In wetenschappelijk onderzoek hebben we verwachtingen over hoe iets werkt (relaties) in de populatie. Om die te toetsen formuleren we de nulhypothese: het tegenovergestelde van wat we verwachten.
- Via de methode van statistische significantie stellen we vast hoe (on)waarschijnlijk een bepaald steekproefresultaat is, gegeven de nulhypothese. Dit gebruiken om vast te stellen met welke mate van zekerheid een populatieparameter niet nul zal zijn.

- Een enge focus op statistische significantie heeft echter zijn beperkingen. In plaats daarvan gebruiken we bij voorkeur betrouwbaarheidsintervallen om zowel de nulhypothese te toetsen als praktische relevantie te bepalen.

11 Aspecten van hypothesetoetsing

In het vorige hoofdstuk heb je geleerd wat hypothese toetsen inhoudt en welke stappen je daarbij moet nemen. Als je dit voor deze eerste keer leert, kan het behoorlijk uitdagend zijn om het allemaal te verwerken. Je zult echter zien dat naarmate je het vaker oefent en verschillende bhi's hebt berekend, je het principe ervan beter zult gaan begrijpen. Oefening baart kunst (OBK)!

We hebben tot nu een paar bochten afgesneden. Zoals gesignaleerd in het vorige hoofdstuk, zijn er bij hypothese toetsen meerdere aspecten waar je rekening mee moet houden. Een aantal van die aspecten behandelen we hier. Daarna heb je, als het goed is, een aardig overzicht van wat er allemaal bij hypothese toetsen komt kijken. We gaan in op de volgende vier zaken: 1) de t-verdeling 2) het formuleren van hypotheses 3) eenzijdig en tweezijdig toetsen en 4) type-I en type-II fouten.

11.1 T-verdeling

Zoals je inmiddels weet, gebeurt het berekenen van dingen zoals de overschrijdingskans en een bhi op basis van de normale verdeling. Tot nu toe hebben we aangenomen dat de normale verdeling altijd hetzelfde is, waarbij de distributie van waarden de empirische regel volgt. Dit houdt in dat binnen een xx aantal standaarddeviaties van het gemiddelde xx% van alle waarden ligt, afhankelijk van hoeveel standaarddeviaties je neemt. Deze vaste vorm staat ook wel bekend als de *standaard*normale verdeling of z-verdeling en geldt over het algemeen voor populatiedata.

Het blijkt echter dat de standaardnormale verdeling niet altijd even goed van toepassing is. Met name voor kleinere steekproeven vinden we dat de normale verdeling een andere vorm heeft dan standaardnormale verdeling. In deze video wordt uitgelegd hoe dat werkt:

https://youtu.be/32CuxWdOlow?si=75mpR9UutZl4BBm3

We moeten dus rekening houden met de t-verdeling in ons onderzoek, omdat deze afhankelijk van de steekproefgrootte een iets andere vorm heeft dan de z-verdeling. Dit is vooral bij kleinere steekproeven relevant (onder de 30 respondenten).

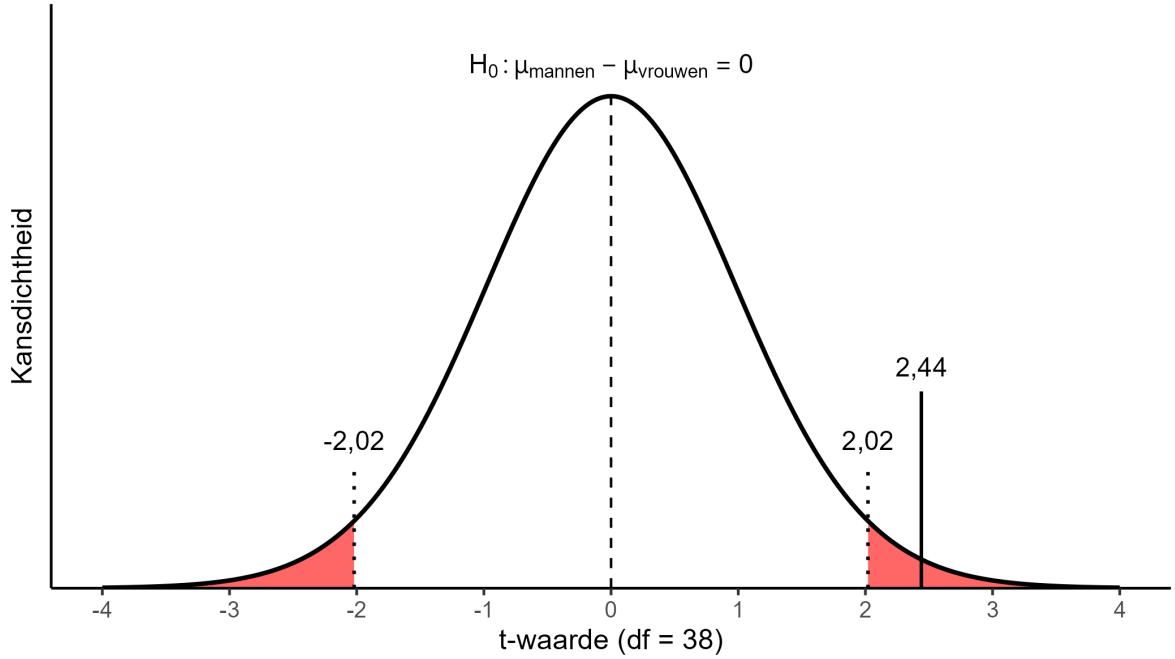
Bij het hypothese toetsen via statistische significantie zijn er in essentie twee relevante t-waardes: de kritieke grenswaarde (t_k) en toetsingsgrootheid (t_g). De eerstgenoemde is de grenswaarde waarbij we de nulhypothese verwerpen. De t_k is afhankelijk van het gekozen significantieniveau

(bijv. 0,01; 0,05 of 0,1) en het aantal respondenten in de steekproef minus het aantal geschatte populatieparameters bij een t-toets (oftewel: het aantal vrijheidsgraden).

Bij het voorbeeld uit het vorige hoofdstuk zagen we dat de nulhypothese werd verworpen wanneer het gemiddelde verschil in aantal glazen alcohol groter was dan 2,2 of kleiner dan -2,2. Deze waarden hebben we kunnen herleiden uit de t_k . Als je voor dit voorbeeld de t_k zou opzoeken in de t-tabel, dan zou je uitkomen op $t_k = 2,024$.[1] [2]

De toetsingsgrootheid t_g is de t-waarde die correspondeert met het steekproefresultaat en waar deze zich bevindt onder de H_0-verdeling. Elke toets kent zijn eigen formule om dit te berekenen. Bij de R-output uit het voorbeeld kun je zien dat (afgerond) $t_g = 2,440$. Deze waarde komt dus overeen met gevonden verschil in gemiddeldes van 2,7 glazen.

In de figuur hieronder wordt bovenstaande gevisualiseerd. Je ziet dus dat dit in feite niet anders is dan wat we in het vorige hoofdstuk hebben gezien. De t-waardes worden gebruikt om de bijbehorende grens van het significantieniveau en de overschrijdingskans te bepalen.



[1] Op basis van de volgende gegevens:

- aantal vrijheidsgraden: $n - 2$ in dit geval, dus $40 - 2 = 38$.
- gekozen significantieniveau: 5%
- tweezijdig toetsen (zie verderop dit hoofdstuk)

[2] Het aantal vrijheidsgraden bij een t-toets voor onafhankelijke groepen en ongelijke varianties wordt normaliter via een ingewikkelde formule berekend. Omdat bij dit voorbeeld de varianties gelijk zijn alsmede het aantal respondenten, hoeven we alleen $n - 2$ te doen om het aantal vrijheidsgraden te verkrijgen.

11.1.1 Bhi op basis van t-verdeling

We maken het ons iets makkelijker in deze cursus door voornamelijk te kijken naar bhi's. Daarvoor hebben we alleen de kritieke grenswaarde t_k nodig en niet de toetsingsgrootheid t_g. De laatste is alleen van toepassing bij de methode van statistische significantie.

We doorlopen nu nogmaals het voorbeeld uit het vorige hoofdstuk, maar nu met 15 mannen en 15 vrouwen. We berekenen handmatig het bhi volgens de t-verdeling. Dan krijg je een idee hoe een bhi voor een t-toets voor onafhankelijke groepen tot stand komt. De formule is als volgt:

$$bhi = (\bar{x}_1 - \bar{x}_2) \pm t_k \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Deze formule is niet veel anders dan bij het Betrouwbaarheidsinterval. Hier neem je het gemiddelde van mannen $\bar{x}_1$ minus het gemiddelde van vrouwen $\bar{x}_2$. Het gedeelte achter de $\pm$ bereken je wederom apart. Daarvoor zoek je de bijbehorende t_k. Daarvoor kunnen we weer kijken in de t-tabel: $t_k = 2,048$.[3] Het laatste deel $\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$ is de berekening van de standaardfout $s.e.$ voor deze toets.[4] Net zoals bij Betrouwbaarheidsinterval kunnen we dit weer in R berekenen.

```
# verschil in gemiddeldes
11.4-8.7
```

```
[1] 2.7
```

```
# gedeelte achter +-
2.048*sqrt(3.5^2/15+3.5^2/15)
```

```
[1] 2.617384
```

```
# 95%-bhi berekenen
2.7-2.617
```

```
[1] 0.083
```

[3] Op basis van de volgende gegevens:

- aantal vrijheidsgraden: $n - 2$, dus $30 - 2 = 28$.
- gekozen significantieniveau: 5%
- Tweezijdig toetsen

[4] $s.e.$ is een meer algemene notatie voor de standaardfout (*standard error*).

```
2.7+2.617
```

```
[1] 5.317
```

Je ziet dus dat het bhi in dit geval $[0,08; 5,32]$ bedraagt. Dit is een breder bhi dan in het vorige hoofdstuk ($[0,46; 4,94]$). Als je naar de formule kijkt, kun je zien dat een kleinere n leidt tot een grotere standaardfout *s.e.* *Daar komt nu nog bovenop dat we middels de t-verdeling (de kritieke grenswaarde t_k) corrigeren voor kleinere steekproeven.* Bij grotere steekproeven is de t-verdeling nagenoeg gelijk aan de z-verdeling (zie het youtube filmpje hierboven).

Interessant is overigens dat de ondergrens van het huidige bhi $[0,08; 5,32]$ net boven de nul ligt. Op basis hiervan zouden we de nulhypothese van geen verschil tussen mannen en vrouwen verwerpen. In het geval dat de ondergrens net onder 0 zou liggen, zouden we dat niet doen. Het zou echter aan de interpretatie van de mogelijke populatieparameter niet zoveel veranderen: het gemiddelde verschil in glazen alcohol ligt ongeveer ergens tussen de 0 en 5. Je ziet hier dus al hoe je tot andere conclusies komt wanneer je de bhi-methode vergelijkt met de methode van alleen statistische significantie.

R houdt verder automatisch rekening met de t-verdeling bij het uitvoeren van toets. We kunnen bovenstaande berekening ook 'computermatig' met R doen.

```
set.seed(010)

# nieuwe dataset met totaal 30 respondenten
voorbeeld_alcohol_2 <- data.frame(
  geslacht                    =  factor(rep(c("man", "vrouw"), each = 15)), # variabele mann
  glazen_alcohol_uitgaansdag   =
    c(genereer_groep(15, 11.4, 3.5), genereer_groep(15, 8.7, 3.5)) # 15 respondenten per gesl
)
```

```
# t-toets uitvoeren voor bhi
t.test(glazen_alcohol_uitgaansdag ~ geslacht,
       data = voorbeeld_alcohol_2)
```

```
    Welch Two Sample t-test

data:  glazen_alcohol_uitgaansdag by geslacht
t = 2.1126, df = 28, p-value = 0.04368
alternative hypothesis: true difference in means between group man and group vrouw is not equ
95 percent confidence interval:
 0.08209614 5.31790386
```

```
sample estimates:
  mean in group man mean in group vrouw
               11.4                 8.7
```

Het bhi is hier, op wat miniscule afrondingsverschillen na, hetzelfde als bij de handmatige berekening. Dit is dus een stukje sneller dan altijd alles met de hand moeten doen.

Merk tenslotte op dat de formules van bhi's voor proporties en gemiddeldes bij Betrouwbaarheidsinterval niet helemaal correct waren voor steekproeven. Daar gingen we nog van z-waardes uit i.p.v. t-waardes. De 'juiste' formules kun je vinden in het Formuleblad. Daarmee zullen we ook werken in de practica.

11.2 Hypotheses formuleren

In het vorige hoofdstuk bij Hypothese opstellen werd genoemd dat het relevant is om een hypothese zo exact mogelijk te formuleren. Dit omdat een hypothese invulling geeft aan *wat* we willen onderzoeken en *hoe* wat dat willen meten (lees: operationaliseren). Daarom hanteren we de volgende regels bij het opstellen van een hypothese:

1. De richting van het verband moet duidelijk zijn

Hypotheses kunnen in principe tweezijdig of eenzijdig zijn (zie ook Section 11.4). Tweezijdig betekent dat we geen specifieke verwachting hebben over de richting van het verband. Bijvoorbeeld dat er geen verschil is tussen mannen en vrouwen in hoeveel glazen alcohol ze gemiddeld drinken (de nulhypothese). De originele verwachting is dan dat mannen mogelijk meer drinken dan vrouwen, maar ook dat vrouwen meer kunnen drinken dan mannen. Je verwacht alleen een bepaald verschil te vinden.

Bij een eenzijdige hypothese maak je de richting expliciet. Dan zeg je bijvoorbeeld dat je verwacht dat mannen meer drinken vrouwen (en niet andersom). De nulhypothese is dan dat het gemiddelde aantal glazen dat mannen drinken *kleiner of gelijk is* aan het gemiddelde aantal glazen dat vrouwen drinken op een uitgaansdag.

2. De nulhypothese moet het tegenovergestelde zijn van de originele verwachting (en elkaar uitsluiten)

Als je de nulhypothese verwerpt, ga je er 'voorlopig' vanuit dat je originele verwachting waar is. Daarvoor is het wel belangrijk dat die nulhypothese een spiegel is van de originele verwachting, dat ze tegenovergesteldes van elkaar zijn. Anders sluiten ze elkaar niet uit.

Het voorbeeld hierboven van de eenzijdige hypothese bevestigt toont waarom. Als je verwacht dat mannen meer drinken dan vrouwen, dan verwacht je dat het verschil groter is dan nul met een hoger gemiddelde bij de mannen. Het tegenovergestelde (de nulhypothese) is dan dat het

verschil tussen mannen en vrouwen nul is of lager bij de mannen, vandaar 'kleiner of gelijk aan'.

3. Gebruik de juiste statistische notatie

Zoals je al eerder zag, gebruiken we statistische notatie om onze verwachtingen formeel uit te drukken. Zo verwachten we bij een tweezijdige hypothese dat $\mu_1 \neq \mu_2$, wat betekent dat het gemiddelde in de populatie van de eerste groep (μ_1) niet gelijk is aan het gemiddelde van de populatie van de tweede groep (μ_2). De nulhypothese is dan $\mu_1 = \mu_2$, oftewel dat de populatiegemiddeldes wel gelijk zijn aan elkaar.

Bij een eenzijdige hypothese verwachten we bijvoorbeeld dat het gemiddelde van mannen μ_1 groter is dan dat van vrouwen μ_2. Dit noteren we als $\mu_1 > \mu_2$. De nulhypothese is hier dan $\mu_1 \leq \mu_2$: het het gemiddelde van mannen μ_1 is kleiner of gelijk aan dat van vrouwen μ_2.

4. Begrippen moet helder zijn en geformuleerd op operationaliseerbaar niveau

De hypothese moet duidelijk maken wat je precies onderzoekt en hoe dat is gemeten. Neem als voorbeeld: "de ene groep drinkt meer dan de andere groep". Deze hypothese is te vaag. Het zegt niks over welke groepen het gaat, wat voor drank en in welke eenheden wordt gemeten. Ook de formulering "mannen drinken meer dan vrouwen" is niet voldoende. Dit zegt nog weinig over welke drankconsumptie we precies onderzoeken. Bovendien zijn we bij een t-toets expliciet gemiddeldes aan het vergelijken. Een juiste formulering van de nulhypothese zou zijn (bij een tweezijdige hypothese):

> het gemiddelde aantal glazen alcohol gedronken door mannen is gelijk aan het gemiddelde aantal glazen alcohol gedronken door vrouwen op een uitgaansdag (onder de populatie alcoholgebruikers)

Dit is een wat langdradige formulering, maar beschrijft wel zo exact mogelijk wat je probeert te onderzoeken. Het geeft ook meer informatie over de context (op een uitgaansdag, alleen voor mensen die überhaupt drinken).[5]

5. Het moet duidelijk zijn om welke toets het gaat.

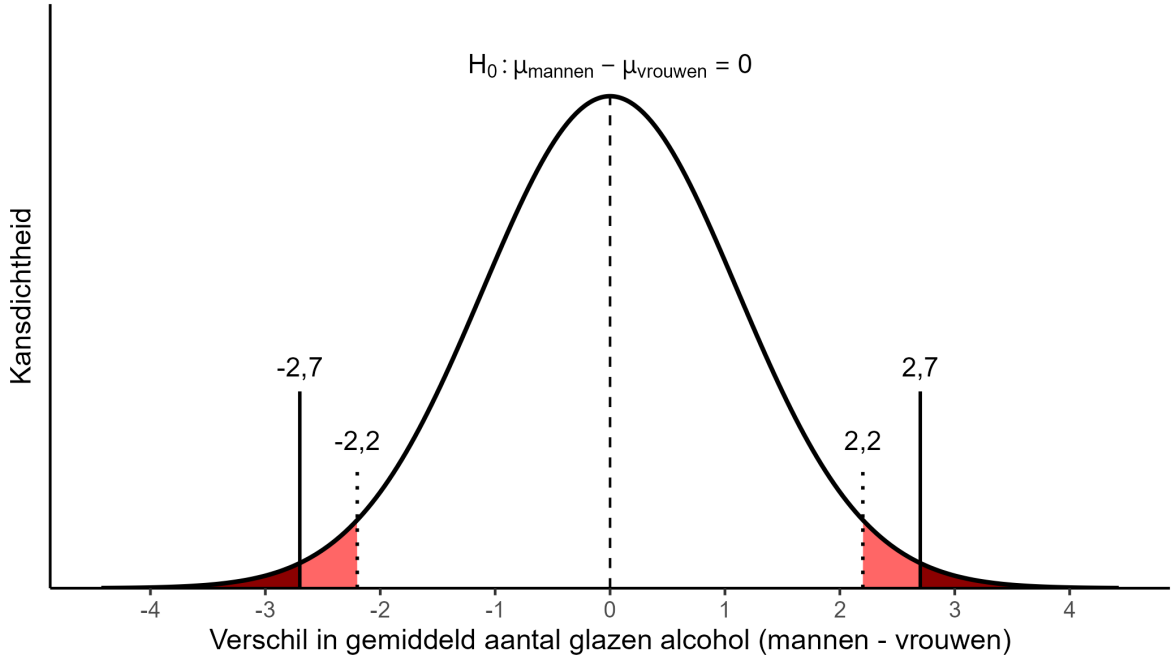
Tot nu toe hebben we alleen een t-toets voor onafhankelijke groepen behandeld. Daarin vergelijken we de gemiddeldes van twee groepen (nominale variabele) op één kwantitatieve variabele met elkaar: $\mu_1 = \mu_2$. In de komende hoofdstukken gaan we nog meer toetsen behandelen: t-toets voor afhankelijke groepen, chi-kwadraat, en correlatie. Uit de formulering van de hypotheses en statistische notatie moet volgen om wat voor soort toets het steeds gaat. Hoe je dat per toets doet, wordt bij de voorbeelden uitgelegd.

[5] In de lopende tekst van dit boek omschrijven we de verbanden/hypotheses niet altijd even precies. Dit doen we om de tekst leesbaar te houden. Aan het begin van een onderzoek is het belangrijk dat je de hypotheses altijd zo precies mogelijk formuleert.

11.3 Tweezijdig/eenzijdig toetsen

Hierboven is al genoemd dat er twee soorten hypotheses zijn: hypotheses zonder een specifieke richting (**tweezijdig**) en hypotheses waarin het verband een specifieke richting heeft (**eenzijdig**). Het verschil tussen tweezijdig en eenzijdig is niet alleen relevant voor hoe we de hypothese formuleren, maar ook voor hoe we deze toetsen uitvoeren. Het heeft namelijk invloed op hoe de overschrijdingskans wordt berekend.

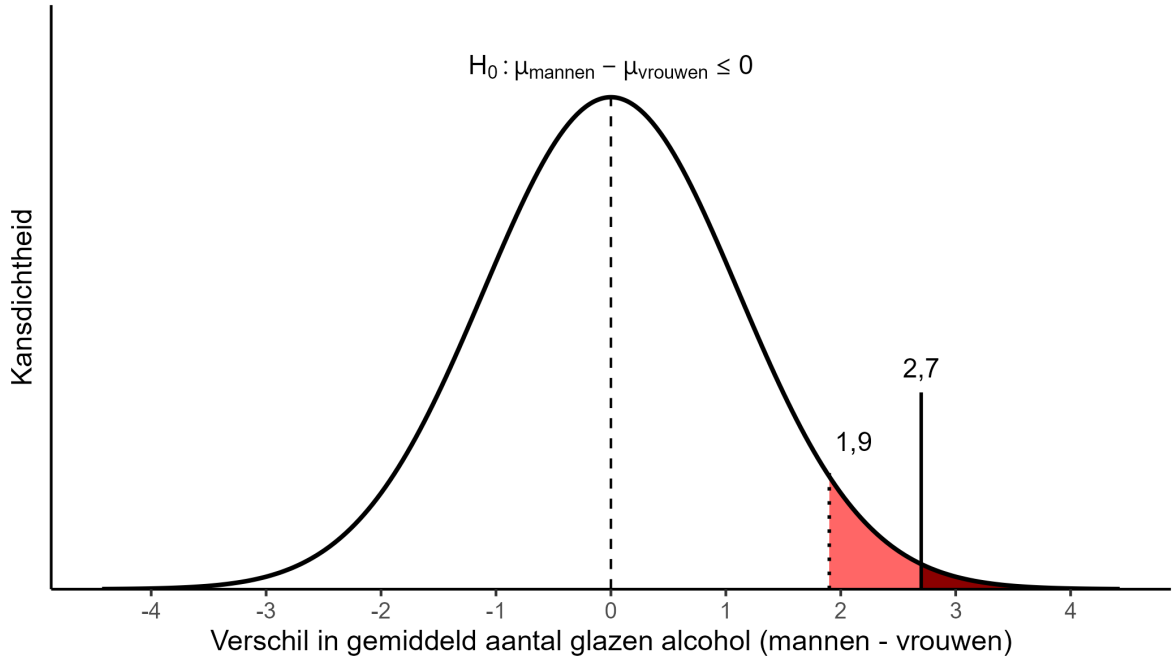
Wanneer we een tweezijdige hypothese hebben, berekenen we de kans op het verkrijgen van een steekproefresultaat minstens zo extreem *in beide richtingen* van de verdeling (onder de H_0 uiteraard). Teruggaand naar het voorbeeld uit het vorige hoofdstuk, betekent dit dat we de kans berekenen op het verkrijgen van een verschil in gemiddeldes van 2,7 of hoger of -2,7 of lager. Dat is hieronder verbeeld.



Het donkere gedeelte onder de normale verdeling vertegenwoordigt de overschrijdingskans $p = 0,019$. Ook al geeft het steekproefresultaat ons een verschil van 2,7 (de daadwerkelijke uitkomst), omdat we een tweezijdige verwachting hadden moeten we rekening houden met dat de uitkomst aan beide kanten van de verdeling had kunnen vallen.

Stel dat we een eenzijdige verwachting hadden: mannen drinken meer dan vrouwen. En dat de uitkomst van de steekproef nog steeds hetzelfde was (een verschil van 2,7). In dat geval berekenen we de overschrijdingskans anders, omdat deze nu kans vertegenwoordigt op het verkrijgen van een steekproefresultaat minstens zo extreem *aan rechterzijde* de verdeling (onder de H_0). Bij dit voorbeeld gaat het om de rechterzijde, omdat we oorspronkelijk een *positief*

verschil verwachten in gemiddeldes: dat van mannen μ_1 is hoger dan dat van vrouwen μ_2.[6] De grafische weergave is dan als volgt.



Er zijn nu een aantal dingen veranderd. Omdat de overschrijdingskans nog maar voor één kant van de H_0-verdeling geldt, is deze de helft van de tweezijdige overschrijdingskans geworden. Dit betekent dat $p = 0,019/2 = 0,0095$. Ook is de kritieke grenswaarde verschoven. Je toetst nog steeds bij een significantieniveau van 0,05. Een eenzijdige hypothese brengt echter met zich mee dat je de nulhypothese alleen verwerpt als de uitkomst in het gebied valt waar je dit verwacht, in dit voorbeeld de rechterzijde. Bij tweezijdig toetsen is de 5% verdeeld over beiden kanten van de verdeling (2,5% links en 2,5% rechts). Bij eenzijdig toetsen wordt alle 5% als het ware aan de rechterkant geplaatst. Daardoor verandert de kritieke grenswaarde, deze correspondeert nu teruggerekend met 1,9 glazen alcohol.

De keuze voor eenzijdig of tweezijdig toetsen kan gevolgen hebben voor het vaststellen van statistische significantie, en uiteindelijk jouw conclusies. Stel je had een steekproef getrokken waarbij het verschil in gemiddeldes tussen mannen en vrouwen 2,0 glazen is. Bij een tweezijdige hypothese zou dit resultaat zich niet in het H_0-verwerpingsgebied bevinden, maar bij eenzijdig toetsen wel. In het eerste geval zou je de nulhypothese dus niet verwerpen, in het tweede geval wel.[7] Daarom is het belangrijk dat je *vooraf* aan een analyse duidelijk bent over de richting van je hypothese en gekozen significantieniveau, zodat je niet achteraf de resultaten gaat aanpassen

[6] De H_0 is hier dan $\mu_1 \leq \mu_2$ (zie ook Section 11.2).

[7] Bij een steekproefresultaat van bijvoorbeeld -2,5 glazen zou dit andersom zijn. Hopelijk kun je al bedenken waarom.

om een statistisch significant resultaat te krijgen.[8]

De uitleg hierboven heeft zich toegespitst op de methode van statistische significantie. Bij bhi's is het tevens relevant of je een eenzijdige of tweezijdige verwachting hebt, omdat de berekening van het bhi daar in principe op moet worden aangepast. In de praktijk gaan we bij bhi's echter bijna altijd uit van een tweezijdige toets, ook al hebben we een eenzijdige hypothese. Dat is niet helemaal statistisch correct, maar meestal zijn we geïnteresseerd in zowel de ondergrens als de bovengrens van het bhi.[9] Dit betekent dat we soms wat conservatiever toetsen op het verwerpen van de nulhypothese dan nodig, maar better be safe than sorry. En het houdt de interpretatie ook eenvoudiger (weer een win voor het bhi t.o.v. statistische significantie!).

11.4 Type-I en type-II fouten

Als laatste kijken we in dit hoofdstuk naar type-I en type-II fouten. Dit zijn fouten die kunnen voorkomen bij statistisch onderzoek waardoor we de verkeerde conclusie trekken over de nulhypothese.

Een type-I fout houdt in dat we de nulhypothese verwerpen terwijl deze eigenlijk waar is. Dit gebeurt aan de hand van statistisch significant resultaat. Stel we doen een hypothesetoets bij een significantieniveau van 5% en vinden dat de toets significant is en verwerpen vervolgens de nulhypothese. Onze redenering is doorgaans dat het onwaarschijnlijk is om een steekproefresultaat zo extreem (kans lager dan 5%) te vinden onder de H_0-verdeling, en dat we daarom de nulhypothese kunnen verwerpen. Echter, het kan zo zijn dat we een willekeurige steekproef hebben getrokken waarvan de uitkomst toevallig heel ver van het midden van de H_0-verdeling ligt (zie ook weer Steekproevenverdeling). Dit weerspiegelt dan geen verschil in de populatie, maar eerder een steekproef met veel afwijkende waarden.

Elk nadeel hebse voordeel, in ieder geval bij een type-I fout. We weten namelijk hoe groot de kans is op het maken van deze fout, gegeven dat de nulhypothese waar is. Die is namelijk hetzelfde als het significantieniveau α. Dat is namelijk de grens waarbij we de hypothese verwerpen. Dit betekent dat een lager significantieniveau, zoals 0,01 of zelfs 0,001, het risico op een type-I fout verkleint. Met een lager significantieniveau stellen we wel strengere eisen aan wanneer een nulhypothese kan worden verworpen. Dit is dus een trade-off.

Een type–II fout is juist wanneer we de nulhypothese *niet* verwerpen, terwijl dit wel zou moeten. De nulhypothese is in dit geval niet waar. Dit type fout heeft twee oorzaken voor die vaak met elkaar samenhangen. De eerste oorzaak is dat het om een heel klein verschil of effect gaat, wat middels hypothese toetsen moeilijk is waar te nemen. Bijvoorbeeld als het verschil in glazen alcohol tussen mannen en vrouwen in de populatie 0,2 is. We zullen dan relatief veel (hypothetische) steekproeven trekken die nul verschil vinden. De tweede oorzaak is een te laag

[8] Zulke praktijken worden ook wel *p-hacking* genoemd.

[9] Bij een eenzijdige toets met een bhi krijg je namelijk alleen een vaste onder- of bovengrens, afhankelijk van de richting van je hypothese.

aantal respondenten om een verschil goed waar te nemen. Zoals je in eerdere voorbeelden hebt gezien, leidt een lagere n tot bijvoorbeeld een breder bhi of een grotere kritieke grenswaarde. De kans dat we de nulhypothese niet verwerpen terwijl dat wel zou moeten neemt dan toe, bijvoorbeeld omdat nul zich in het bhi bevindt terwijl de populatieparameter niet nul is.

In tegenoverstelling tot een type-I fout weten we niet hoe groot de kans is op een type-II fout. We weten alleen dat risico kleiner wordt naarmate we meer data verzamelen.

Het bestaan van deze fouten wijst ons erop dat we resultaten van een statistisch onderzoek nooit als definitief moeten beschouwen. Het kan zijn dat we de nulhypothese onterecht verwerpen (type-I fout), maar ook andersom dat we nulhypothese niet verwerpen terwijl deze eigenlijk waar is (type-II fout). Dit impliceert verder dat het verwerpen van de nulhypothese niet automatisch betekent dat het tegenovergestelde waar is, en dat het niet verwerpen van de nulhypothese betekent dat de nulhypothese waar is of 'bewezen'. De statistische tools die je hier leert zijn daarmee slechts hulpmiddelen in het ontdekken van de waarheid, maar geven ons nooit 100% uitsluitsel.

11.5 Samenvatting

Dit hoofdstuk heeft diverse aspecten behandeld die relevant zijn bij toetsen van hypotheses, zowel voor de methode van statistische significantie als bhi's. De belangrijkste take-aways zijn:

- Bij het berekenen van een toetsingsresultaat moeten we rekening houden met de t-verdeling. Dit kan bij handmatige berekeningen worden opgezocht in de t-tabel, bij computermatige berekeningen houdt R hier automatisch rekening mee
- Het formuleren van hypotheses vraagt om precisie m.b.t. wat we onderzoeken en hoe we dat meten
- Het is voorafgaand aan analyse belangrijk om hypotheses duidelijk eenzijdig of tweezijdig te formuleren, dit heeft gevolgen voor hoe we de toets uitvoeren. Bij bhi's gaan we hier wat soepeler mee om.
- Bij hypothesetoetsing kunnen zowel type-I als type-II fouten optreden. Daarom moeten we resultaten altijd voorzichtig interpreteren, ook vanwege beperkingen die we in de rest van de cursus behandelen.

12 T-toets afhankelijke groepen

We zijn tot nu bezig geweest met allerlei zaken die komen kijken bij statistisch onderzoek. Je zou bijna vergeten waarom we dit doen: we willen leren over hoe de wereld in elkaar zit en onze onderzoeksvragen beantwoorden! Vanaf nu gaan we daarom meer praktisch aan de slag. We gaan kijken hoe we diverse relaties tussen dingen kunnen onderzoeken en of we daar wat zinnigs over kunnen zeggen. Overigens hebben we naast de technische aspecten van statistisch onderzoek ook inhoudelijk rondom drugs en uitgaan al aardig wat geleerd. Zo hebben we een schatting gemaakt van het xtc- en alcoholgebruik in de uitgaanderspopulatie, en hebben we onderzocht wat de gemiddelde verschillen zijn in alcoholconsumptie tussen mannen en vrouwen.

Onder Hypothese toetsen hebben we onderzocht wat het verschil is tussen twee groepen (mannen en vrouwen) op een numerieke hoeveelheid (aantal glazen alcohol). Daarbij nemen we een nominale variabele[1] om de groepen te bepalen en een kwantitatieve variabele om hun gemiddeldes op te vergelijken. Dit noemen we een t-toets voor onafhankelijke groepen.

In dit hoofdstuk gaan we naar een andere t-toets kijken: de **t-toets voor afhankelijke groepen**. Deze toets gebruiken we om een net iets ander type vraag te beantwoorden: wat is het verschil in het gemiddelde op *twee kwantitatieve variabelen binnen één groep.* Die groep kan bijvoorbeeld de populatie uitgaanders zijn als geheel, of alleen mannen *of* vrouwen. In plaats van één nominale variabele en één kwantitatieve variabele zoals bij de t-toets voor onafhankelijke groepen, staan bij de t-toets voor afhankelijke groepen twee kwantitatieve variabelen centraal in de analyse.[2]

We gaan de t-toets voor afhankelijke groepen uitwerken met een voorbeeld. Volgens traditie doen we dit eerst handmatig en daarna computermatig om inzicht te krijgen in het proces. Na alle voorgaande hoofdstukken kunnen we natuurlijk niet anders dan een betrouwbaarheidsinterval te berekenen.

[1] Dit kan in principe ook met een ordinale variabele, zolang je maar twee waardes (lees: groepen) selecteert.

[2] De terminologie rondom t-toetsen kan wat verwarrend zijn, omdat beide type t-toetsen het over 'groepen' hebben. Belangrijk om te onthouden is dat we bij 'onafhankelijke groepen' in principe tussen twee groepen vergelijken (zoals we het woord groepen normaliter gebruiken) en bij 'afhankelijke groepen' in principe binnen één groep vergelijken.

12.1 Beetje pips van de dips

Onder feestgangers is het een bekend verschijnsel: de dinsdagdip. Na een weekend feesten met (excessief) drugsgebruik voelen gebruikers zich vaak de dinsdag erna bijzonder matig. Dit uit zich in klachten als somberheid, vermoeidheid, en slecht concentratievermogen.[3] Drugs hebben echter verschillende effecten op gebruikers, wat impliceert dat de dinsdagdip voor de ene drug zwaarder kan aankomen dan voor de andere drug.

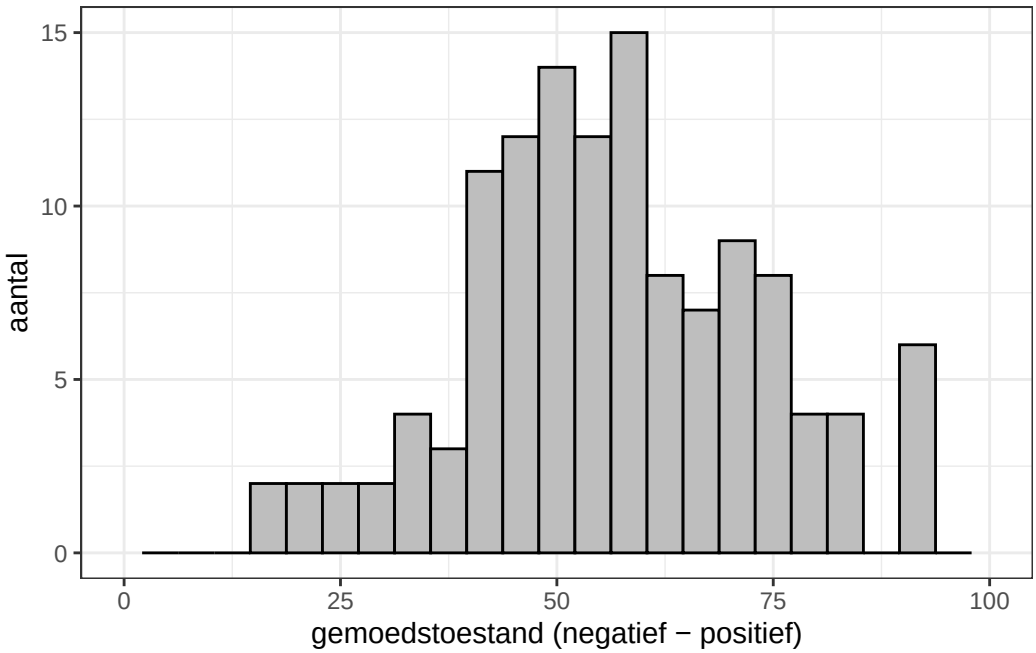
In dit voorbeeld gaan we kijken of uitgaanders een verschil in dinsdagdip ervaren voor xtc en 3-mmc.[4] We nemen daarbij de hele populatie van uitgaanders als startpunt. Aangezien we uitgaanders willen vergelijken die zowel xtc als 3-mmc hebben gebruikt, beperken we onze populatie tot deze specifieke groep gebruikers. De variabele `gemoed_dinsdag_na_xtc` hebben we al eerder gezien Histogram.[5] We gebruiken voor 3-mmc een zelfde soort variabele: `gemoed_dinsdag_na_mmc`. Laten net als bij de histogram van `gemoed_dinsdag_na_xtc` een histogram maken voor `gemoed_dinsdag_na_mmc`.

```
# histogram van gemoedstoestand op dinsdag na 3-mmc gebruik
ggplot(data_uitgaan, aes(x = gemoed_dinsdag_na_mmc)) +
  geom_histogram(bins = 25, fill = "grey", colour = "black") +
  theme_bw() +
  ylab("aantal") +
  xlab ("gemoedstoestand (negatief - positief)") +
  xlim(0, 100)
```

[3] De dinsdagdip is ingeburgerd begrip dat ook door verslavingsinstanties wordt gebruikt, zoals SGGZ.

[4] 3-MMC is een zogenoemde designerdrug die de laatste jaren populair is geworden onder uitgaande jongeren. Voor meer informatie: Trimbos.

[5] De $_d$ komt uit het Engels en staat voor *difference*.



Je ziet dat de meeste waarden zich bevinden zich tussen de 40 en 80.

12.1.1 Hypothese opstellen

Voor aanvang willen we specificeren wat we gaan toetsen. We zijn hier geïnteresseerd in de gemiddelde verschilscore tussen `gemoed_dinsdag_na_xtc` en `gemoed_dinsdag_na_mmc`. We hebben geen verwachting over de richting van het gemiddelde, of het positief of negatief is. Daarom kunnen we de nulhypothese als volgt formuleren:

H_0: Het gemiddelde verschil tussen gemoedstoestand op dinsdag na xtc- en 3-mmc-gebruik voor uitgaanders is nul.

Notatie: $\mu_d = 0$

Deze notatie hierboven is nieuw. μ_d staat voor het populatiegemiddelde van de verschilscore.[6]

12.1.2 Handmatige berekening

Eerst even wat uitleg over die verschilscore. Wat je vergelijkt bij een t-toets voor afhankelijke groepen is iets anders dan bij een t-toets voor onafhankelijke groepen. Bij de laatste bereken je eerst het gemiddelde op een variabele voor beide groepen, en vervolgens vergelijk je die twee gemiddeldes met elkaar. Je schat daarmee twee populatieparameters (twee gemiddeldes).

[6] De $_d$ komt uit het Engels en staat voor *difference*.

Bij t-toets voor afhankelijke groepen neem je eerst de verschilscore tussen de variabelen voor alle observaties en daar bereken je in principe het gemiddelde van. Hier schat je dan maar één populatieparameter.

> **i** Uitleg over berekening verschilscore
>
> Neem bijvoorbeeld twee respondenten.
> Respondent A scoort 80 op `gemoed_dinsdag_na_xtc` en 65 op `gemoed_dinsdag_na_mmc`.
> De verschilscore is dan $80 - 65 = 15$.
> Respondent B scoort 70 op `gemoed_dinsdag_na_xtc` en 75 op `gemoed_dinsdag_na_mmc`.
> De verschilscore is dan $70 - 75 = -5$.
> Deze verschilscores tel je dan bij elkaar op, waarna je het gemiddelde berekent.

Voor de berekening van het betrouwbaarheidsinterval is dit de formule bij deze t-toets:

$$\bar{d} \pm t_k \frac{s_d}{\sqrt{n}}$$

We gebruiken hier $\bar{d}$ om aan te geven dat het om het gemiddelde van de verschilscores gaat. s_d staat voor de standaardeviatie van die verschilscores. Dat maakt $s_d/\sqrt{n}$ de standaardfout en t_k de kritieke grenswaarde.

We hebben als eerste die verschilscores nodig. Die kunnen we makkelijk krijgen door een nieuwe variabele `verschil_xtc_mmc` aan te maken waarvoor we `gemoed_dinsdag_na_xtc` minus `gemoed_dinsdag_na_mmc` doen. We vragen ook meteen de beschrijvende statistieken op.

```
# variabele verschil_xtc_mmc aanmaken voor verschilscore
data_uitgaan$verschil_xtc_mmc <- data_uitgaan$gemoed_dinsdag_na_xtc - data_uitgaan$gemoed_di

# beschrijvende statistieken
summary(data_uitgaan$verschil_xtc_mmc)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
-48.000 -12.500   0.000   1.244  17.750  42.000     268
```

```
sd(data_uitgaan$verschil_xtc_mmc, na.rm = TRUE)
```

```
[1] 20.91993
```

```
valid.n(data_uitgaan$verschil_xtc_mmc) # aantal valide waarden
```

```
[1] 82
```

Deze statistieken geven al wat inzicht in `verschil_xtc_mmc`. Het gemiddelde is 1,2, wat niet heel groot is gezien dat het bereik op originele variabelen 0-100 is. De standaardeviatie is verder vrij groot (20,9) en het minimum (-48) en maximum (42) liggen ver uit elkaar. Verder hebben 82 respondenten een valide waarde op deze variabele. Dat betekent dat van de 350 respondenten in totaal van `data_uitgaan` er 82 zowel ooit xtc als 3-mmc hebben gebruikt.

We kunnen nu statistieken invullen in de formule. We moeten alleen nog de t_k weten. Het aan vrijheidsgraden bij deze toets is $df = n - 1 = 82 - 1 = 81$. De t-tabel toont dat $t_k = 1,990$. Nu kunnen we via de bekende weg alles uitrekenen met behulp van R.

```
# gedeelte achter +-
1.990*20.920/sqrt(82)
```

```
[1] 4.597353
```

```
# 95%-bhi berekenen
1.244-4.597
```

```
[1] -3.353
```

```
1.244+4.597
```

```
[1] 5.841
```

Het bhi is dus $[-3,35, 5,84]$.

12.1.3 Computerberekening

Met een paar regels code kunnen we dit resultaat ook krijgen met `t.test()`.

```
# t-toets uitvoeren voor afhankelijke groepen
t.test(data_uitgaan$gemoed_dinsdag_na_xtc, # eerste variabele
       data_uitgaan$gemoed_dinsdag_na_mmc, # tweede variabele
       paired = TRUE)
```

```
    Paired t-test

data:  data_uitgaan$gemoed_dinsdag_na_xtc and data_uitgaan$gemoed_dinsdag_na_mmc
t = 0.53843, df = 81, p-value = 0.5918
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -3.352710  5.840515
sample estimates:
mean difference
       1.243902
```

12.1.4 Interpretatie en conclusie

We laten onze befaamde interpretatie los op de uitkomst:

> We kunnen met 95% betrouwbaarheid stellen dat het gemiddelde verschil tussen gemoedstoestand op dinsdag na xtc- en 3-mmc-gebruik tussen de -3,35 en 5,84 ligt, gebaseerd op (hypothetische) herhaalde steekproeven en geen additionele relevante kennis.

We vinden dus dat de gemiddelde verschilscore negatief (-3,35) of positief (5,84) zou kunnen zijn. De potentiële populatieparameters zijn an sich niet heel groot; een verschil van 5 op een oorspronkelijk bereik van 0-100 stelt niet veel voor. De populatieparameters lijken zich vooral rondom nul te begeven.

Omdat nul ook binnen het bhi valt, concluderen we dat we de nulhypothese niet verwerpen.[7] Er lijkt dus geen wezenlijk verschil te zijn tussen de gemoedstoestand op dinsdag na het gebruik van xtc of 3-mmc. We kunnen er, bij gebrek aan ander bewijs, vanuit gaan dat de drugs een vergelijkbare kater geven.

12.2 Samenvatting

We hebben in dit hoofdstuk een t-toets voor afhankelijke groepen uitgevoerd door de gemoedstoestand op dinsdag van drugsgebruikers te vergelijken m.b.t. xtc en 3-mmc. Bij deze t-toets vergelijken we voor één groep de scores op twee kwantitatieve variabelen. Bij een t-toets voor onafhankelijke groepen vergelijken we juist twee groepen op één variabele. Het hoofdstuk toont verder dat wat we eerder geleerd hebben rondom betrouwbaarheidsintervallen ook hier goed toepasbaar is, ditmaal voor een gemiddelde verschilscore.

[7] Je kunt ook zien dat de p-waarde (0,59) veel hoger is dan het significantieniveau (0,05).

Part V

Colleges en practica

13 Collegeslides

Volgt

14 Opdrachten

Volgt

A Symbolen en formules

Hier vind je een overzicht van alle belangrijke symbolen en formules die we gebruiken.

Symbool	Formule	Betekenis
Algemeen		
$\sum_{i=1}^{n}$		Griekse hoofdletter sigma, staat voor 'sommatie': alles bij elkaar optellen. De i betekent dat je begint met tellen bij de eerste waarneming, de n dat je stopt bij de laatste.
α		Alpha, het significantieniveau
P		Populatieproportie
$\hat{p}$		Steekproefproportie
μ	$\mu = \frac{\sum_{i=1}^{N} x_i}{N}$	Mu, het gemiddelde in de *populatie* (vaak onbekend)
$\bar{x}$	$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$	Steekproefgemiddelde
σ^2	$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i-\mu)^2}{N}$	Sigma kwadraat, de variantie in een *populatie*
S^2	$S^2 = \frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{n-1}$	Steekproefvariantie
σ	$\sigma = \sqrt{\frac{\sum_{i=1}^{N}(x_i-\mu)^2}{N}}$	Sigma, de standaarddeviatie in een *populatie* (vaak onbekend)
s	$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{n-1}}$	Standaardafwijking in de steekproef
$s.e.$	$s.e. = \frac{s}{\sqrt{n}}$	Standaardfout
R	$R = x_{max} - x_{min}$	Range, oftewel bereik
z	$z = \frac{x-\bar{x}}{s}$	Z-score
Bhi's		
$\text{bhi}_{\hat{p}}$	$\text{bhi}_{\hat{p}} = \hat{p} \pm z \times \sigma_{\hat{p}}$	Bhi proportie
$\sigma_{\hat{p}}$	$\sigma_{\hat{p}} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	Standaardfout proporties

Symbool	Formule	Betekenis
$\text{bhi}_{\bar{x}}$	$\text{bhi}_{\bar{x}} = \bar{x} \pm z \times \sigma_{\bar{x}}$	Bhi gemiddelde
$\sigma_{\bar{x}}$	$\sigma_{\bar{x}} = \frac{s}{\sqrt{n}}$	Standaardfout gemiddeldes
$\text{bhi}_{\bar{d}}$	$\bar{d} \pm t_k \frac{s_d}{\sqrt{n}}$	Bhi t-toets verschillen